


LAPORAN TUGAS AKHIR I

**JUDUL SEMENTARA: EVALUASI KOMUNIKASI LATEN
PADA SISTEM MULTI-AGEN: PERBANDINGAN
FORMULASI REPRESENTASI LATEN TERHADAP
KOMUNIKASI BERBASIS TEKS**



Harun Yahya
22/505239/PA/21749

PEMBIMBING :

**PROGRAM SARJANA PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

DAFTAR ISI

DAFTAR ISI	
BAB I PENDAHULUAN	2
1.1. Latar Belakang	2
1.2. Rumusan Masalah	4
1.3. Pembatasan Masalah	5
1.4. Tujuan dan Manfaat Penelitian	6
1.5. Tinjauan Pustaka	7
1.6. Metodologi Penelitian	8
1.7. Sistematika Penulisan	8
BAB II LANDASAN TEORI	10
2.1. Probabilitas dan Variabel Acak	10
2.1.1. Ruang Sampel dan <i>Event</i>	10
2.1.2. Variabel Acak	10
2.1.3. Distribusi Probabilitas	10
2.1.4. <i>Probability Mass Function</i>	11
2.1.5. <i>Probability Density Function</i>	11
2.1.6. <i>Conditional Probability</i>	11
2.1.7. <i>Joint Probability</i>	11
2.1.8. <i>Marginal Probability</i>	11
2.1.9. <i>Independence</i>	11
2.1.10. <i>Expectation</i>	12
2.1.11. <i>Variance dan Covariance</i>	12
2.2. Distribusi Probabilitas yang Relevan	12
2.2.1. Bernoulli	12
2.2.2. Categorical	12
2.2.3. Multinomial	12
2.2.4. Gaussian	12
2.2.5. Gumbel	13
2.2.6. Dirichlet	14
2.3. Teori Informasi	14
2.3.1. <i>Information</i>	14
2.3.2. <i>Entropy</i>	14
2.3.3. <i>Normalized Entropy</i>	14
2.3.4. <i>Cross-Entropy</i>	14
2.3.5. <i>KL Divergence</i>	15
2.3.6. <i>Jensen-Shannon Divergence</i>	15

2.4. <i>Bayesian Inference</i>	15
2.4.1. <i>Prior</i>	15
2.4.2. <i>Likelihood</i>	15
2.4.3. <i>Evidence</i>	15
2.4.4. <i>Posterior</i>	15
2.4.5. <i>Bayesian Updating</i>	15
2.4.6. <i>Conjugate Prior</i>	16
2.4.7. <i>Posterior Predictive Distribution</i>	16
2.5. <i>Linear Algebra dan Representasi Vektor</i>	16
2.5.1. <i>Scalar, Vector, Matrix</i>	16
2.5.2. <i>Dot Product</i>	16
2.5.3. <i>Matrix Multiplication</i>	16
2.5.4. <i>Norm</i>	16
2.5.5. <i>Linear Combination</i>	17
2.5.6. <i>Convex Combination</i>	17
2.5.7. <i>Vector Space</i>	17
2.5.8. <i>Embedding Space</i>	17
2.6. <i>Machine Learning dan Neural Network</i>	17
2.6.1. <i>Model Parametrik</i>	17
2.6.2. <i>Parameter dan Hyperparameter</i>	17
2.6.3. <i>Forward Pass</i>	18
2.6.4. <i>Loss Function</i>	18
2.6.5. <i>Training vs Inference</i>	18
2.6.6. <i>Autoregressive Modeling</i>	18
2.7. <i>Language Model</i>	18
2.7.1. <i>Token dan Vocabulary</i>	18
2.7.2. <i>Tokenization</i>	18
2.7.3. <i>Next-Token Prediction</i>	18
2.7.4. <i>Language Model Probability</i>	19
2.7.5. <i>Logits</i>	19
2.7.6. <i>Softmax</i>	19
2.7.7. <i>Temperature</i>	19
2.7.8. <i>Greedy Decoding</i>	19
2.7.9. <i>Sampling</i>	19
2.7.10. <i>Top-k</i>	19
2.7.11. <i>Top-p (Nucleus Sampling)</i>	20
2.8. <i>Transformer</i>	20
2.8.1. <i>Arsitektur Transformer</i>	20
2.8.2. <i>Embedding</i>	20
2.8.3. <i>Positional Encoding</i>	20
2.8.4. <i>Self-Attention</i>	20
2.8.5. <i>Query, Key, Value</i>	20

2.8.6. <i>Scaled Dot-Product Attention</i>	20
2.8.7. <i>Multi-Head Attention</i>	21
2.8.8. <i>Feed-Forward Network</i>	21
2.8.9. <i>Residual Connection</i>	21
2.8.10. <i>Layer Normalization</i>	21
2.8.11. <i>Decoder-only Transformer</i>	21
2.8.12. <i>Causal Masking</i>	21
2.8.13. <i>KV Cache</i>	21
2.9. <i>Large Language Model dan Reasoning</i>	22
2.9.1. <i>LLM</i>	22
2.9.2. <i>Chain-of-Thought</i>	22
2.9.3. <i>Discrete Token Reasoning</i>	22
2.9.4. <i>Continuous Reasoning</i>	22
2.9.5. <i>Latent Representation</i>	22
2.9.6. <i>Hidden State</i>	22
2.9.7. <i>Latent Thought</i>	22
2.10. <i>Soft Thinking</i>	23
2.10.1. <i>Discrete Token Thinking</i>	23
2.10.2. <i>Soft Token</i>	23
2.10.3. <i>Soft Input</i>	23
2.10.4. <i>Probability Simplex</i>	23
2.10.5. <i>Weighted Embedding</i>	23
2.10.6. <i>Top-k/Top-p Truncation</i>	23
2.10.7. <i>Greedy Pitfall</i>	24
2.11. <i>Mixture of Inputs</i>	24
2.11.1. <i>Motivasi MoI</i>	24
2.11.2. <i>Entropy-scaled Prior</i>	24
2.11.3. <i>Dirichlet Prior</i>	24
2.11.4. <i>Multinomial Observation</i>	24
2.11.5. <i>Posterior Distribution</i>	24
2.11.6. <i>Posterior Mean</i>	25
2.11.7. <i>Mixing Weight</i>	25
2.11.8. <i>Mixture Embedding</i>	25
2.12. <i>Stochastic Soft Thinking</i>	26
2.12.1. <i>Randomness dan Exploration</i>	26
2.12.2. <i>Stochastic Soft Token</i>	26
2.12.3. <i>Dirichlet Sampling</i>	26
2.12.4. <i>Gumbel Distribution</i>	26
2.12.5. <i>Gumbel-Max Trick</i>	26
2.12.6. <i>Gumbel-Softmax</i>	26
2.12.7. <i>Temperature</i>	27
2.12.8. <i>Softness vs Randomness</i>	27

2.12.9. <i>Luce's Choice Axiom</i>	27
2.12.10. <i>Sampling Without Replacement</i>	27
2.12.11. <i>Test-time Scaling</i>	27
2.12.12. <i>Pass@k</i>	27
2.13. <i>Multi-Agent System</i>	28
2.13.1. <i>Agent</i>	28
2.13.2. <i>Multi-Agent System (MAS)</i>	28
2.13.3. <i>Sequential MAS</i>	28
2.13.4. <i>Hierarchical MAS</i>	28
2.13.5. <i>Agent Communication</i>	28
2.13.6. <i>Text-based Communication</i>	28
2.13.7. <i>Latent Communication</i>	28
2.14. <i>LatentMAS</i>	29
2.14.1. <i>Autoregressive Latent Thought</i>	29
2.14.2. <i>Hidden-State Recurrence</i>	29
2.14.3. <i>Latent Working Memory</i>	29
2.14.4. <i>KV-cache Transfer</i>	29
2.14.5. <i>Input-Output Alignment</i>	29
2.14.6. <i>Alignment Matrix</i>	29
2.14.7. <i>Ridge Regression</i>	30
2.14.8. <i>Wasserstein Distance</i>	30
2.14.9. <i>Expressiveness Theorem</i>	30
2.14.10. <i>Lossless Communication Theorem</i>	30
2.14.11. <i>Complexity Analysis</i>	31
2.15. <i>Konsep Matematis yang Menghubungkan Ketiga Metode</i>	31
2.15.1. <i>Discrete → Probability Distribution</i>	31
2.15.2. <i>Probability Distribution → Embedding</i>	31
2.15.3. <i>Embedding → Hidden Representation</i>	31
2.15.4. <i>Hidden Representation → Latent Thought</i>	32
2.15.5. <i>Stochasticity → Exploration</i>	32
2.15.6. <i>Latent Representation → Agent Communication</i>	32
2.16. <i>Pengujian Statistik</i>	32
2.16.1. <i>Uji McNemar</i>	32
2.16.2. <i>Uji Wilcoxon Signed-Rank</i>	33
2.16.3. <i>Interval Kepercayaan Bootstrap</i>	33
2.16.4. <i>Koreksi Perbandingan Berganda</i>	33
2.17. <i>Uji Cochran Q</i>	34
2.18. <i>Evaluasi Empiris Model Bahasa</i>	35
2.18.1. <i>Benchmark</i>	35
2.18.2. <i>Exact Match</i>	35
2.18.3. <i>Pass@1 dan Pengujian Unit</i>	36
2.18.4. <i>Keandalan Bentuk Keluaran</i>	36

2.18.5. Rancangan Berpasangan dan Verifikasi Sidik Jari	37
2.19. Faktor Alpha dan Evaluasinya	37
2.19.1. Faktor Alpha sebagai Ekspresi Simbolik	37
2.19.2. <i>Information Coefficient</i>	38
2.19.3. Metrik Portofolio	39
BAB III METODOLOGI PENELITIAN	40
3.1. Desain Penelitian	40
3.2. Objek Penelitian dan Formulasi Langkah Laten.	41
3.2.1. Proses Pembangkitan Langkah Laten.	41
3.3. Persamaan Langkah Laten Resmi LatentMAS.	43
3.3.1. Input–Output Alignment	43
3.3.2. Batas Jaminan Persamaan Raw	44
3.4. Reformulasi Langkah Laten sebagai Relaksasi Diskret.	45
3.4.1. Bentuk Umum.	45
3.5. Metode yang Dibandingkan	46
3.5.1. Soft.	46
3.5.2. Sample.	46
3.5.3. Gumbel	47
3.5.4. Mixture of Inputs	48
3.6. Proposisi Matematis untuk Penyatuan Metode.	49
3.6.1. Proposisi 1: MoI sebagai Kombinasi Konveks Soft dan Sample	49
3.6.2. Proposisi 2: Hubungan Gumbel dengan Sampling Diskret	50
3.6.3. Proposisi 3: Raw Berada di Luar Keluarga Relaksasi Diskret.	51
3.7. Konvensi Normalisasi	51
3.8. Implementasi MoI dan Perbedaan dengan Kode Rujukan.	52
3.9. Rancangan Komunikasi Multi-Agen	52
3.9.1. Struktur Agen	52
3.9.2. Sumbu Medium Komunikasi.	53
3.10. Model dan Lingkungan Eksperimen	54
3.11. Data dan Tugas Evaluasi.	54
3.11.1. GSM8K.	55
3.11.2. ARC-Challenge	55
3.11.3. HumanEval-Plus.	55
3.11.4. Generasi Faktor Simbolik	55
3.12. Protokol Pengambilan Sampel dan Pairing.	56
3.13. Hipotesis Penelitian.	56
3.13.1. Hipotesis H1: Pengaruh Keanggotaan Keluarga Relaksasi Disk-	
ret	56
3.13.2. Hipotesis H2: Presisi Simbolik	57
3.13.3. Hipotesis H3: Medium Komunikasi	57
3.14. Variabel Penelitian.	58

3.15. Metrik Evaluasi	58
3.15.1. Akurasi Jawaban.	58
3.15.2. Format Rate	59
3.15.3. Fidelitas Simbolik	59
3.15.4. Biaya Komputasi	59
3.16. Pengujian Geometris.	60
3.17. Analisis Statistik	60
3.17.1. Data Biner.	61
3.17.2. Data Kontinu atau Ordinal.	61
3.17.3. Interval Kepercayaan	61
3.17.4. Koreksi Multipisitas.	61
3.17.5. Prinsip Interpretasi	61
3.18. Prinsip Ketelitian Klaim	62
3.19. Batasan Rancangan Penelitian	63
3.20. Alur Pelaksanaan Penelitian.	64
BAB IV HASIL DAN PEMBAHASAN	65
4.1. Cakupan Data dan Verifikasi Praanalisis.	65
4.2. Hasil Lengan <i>Benchmark</i>	66
4.2.1. Uji Berpasangan dan Koreksi Multiplisitas	67
4.2.2. Homogenitas Kelima Persamaan Langkah Laten	68
4.2.3. Kontras Keluarga Relaksasi terhadap Ridge W_a	68
4.3. Disosiasi menurut Tuntutan Presisi Simbolik.	69
4.4. Efisiensi Medium Laten	70
4.5. Fidelitas Simbolik Keluaran	72
4.6. Bukti Mekanisme.	73
4.7. Lengan Faktor Simbolik	75
4.7.1. Artefak Medium Gabungan dan Pemulihannya.	75
4.7.2. Keandalan Keluaran Agen Penyusun	76
4.7.3. Mutu Ekspresi yang Dihasilkan	77
4.7.4. Beberapa Faktor Konkret.	78
4.7.5. Kedudukan terhadap Hipotesis H2	79
4.8. Batas Berlaku dan Ancaman Validitas.	79
BAB V KESIMPULAN DAN SARAN	81
5.1. Kesimpulan	81
5.1.1. Formulasi Representasi Laten dalam Satu Kerangka Matematis.	81
5.1.2. Pengaruh Formulasi terhadap Penalaran dan Presisi Simbolik	82
5.1.3. Efisiensi Komunikasi Laten.	83
5.1.4. Kemampuan Mempertahankan Muatan Simbolik pada Generasi Faktor	84
5.1.5. Kesimpulan Umum	85
5.2. Saran	86

DAFTAR PUSTAKA	88
BAB A Tabel Lengkap Sel Lengan <i>Benchmark</i>	92
BAB B Hasil Lengkap Uji Berpasangan	94
BAB C Transkrip Rantai Agen	97
BAB D Kartu Faktor	102
BAB E Implementasi Empat Persamaan Langkah Laten	105
BAB F Hiperparameter dan Lingkungan Eksekusi	107

BAB I

PENDAHULUAN

1.1. Latar Belakang

Model bahasa besar (*large language model*, LLM) semakin sering dijalankan bukan sebagai satu model tunggal, melainkan sebagai sistem *multi-agent*: beberapa salinan model diberi peran berbeda dan bekerja berurutan, saling meneruskan hasil pekerjaan hingga jawaban akhir terbentuk. Pembagian peran semacam itu terbukti memperbaiki mutu jawaban pada tugas yang menuntut perencanaan, pemeriksaan ulang, dan perbaikan bertahap.

Pada hampir seluruh sistem tersebut, medium yang menghubungkan antaragen adalah teks. Setiap agen harus mengubah penalaran internalnya menjadi untaian kata, lalu agen berikutnya menguraikan kembali untaian itu menjadi representasi internalnya sendiri. Proses bolak-balik tersebut menimbulkan dua persoalan. Pertama, biaya komputasi meningkat karena setiap penyerahan pekerjaan mengharuskan pembangkitan token yang panjang. Kedua, terdapat penyempitan kanal: representasi internal yang kaya harus dimampatkan menjadi barisan token diskret, dan hanya sebagian yang dapat dipulihkan oleh agen penerima [Zou dkk, 2025, Fu dkk, 2025].

Sebagai jawaban atas kedua persoalan itu, Zou dkk [2025] mengusulkan LatentMAS, kerangka kolaborasi *multi-agent* yang berlangsung sepenuhnya di ruang laten. Alih-alih bertukar teks, setiap agen menjalankan sejumlah langkah penalaran di ruang representasi kontinu, lalu menyerahkan memori kerjanya berupa *key-value cache* dari mekanisme *attention* [Vaswani dkk, 2017] kepada agen berikutnya. Pendekatan ini merupakan bagian dari paradigma penalaran laten yang lebih luas, yang memindahkan langkah penalaran dari barisan token diskret ke ruang representasi kontinu [Hao dkk, 2024, Chen dkk, 2025]. Pada sejumlah tolok ukur penalaran umum, kerangka tersebut dilaporkan menurunkan pemakaian token keluaran sebesar 70,8%–83,7% dan mempercepat inferensi hingga sekitar empat kali lipat, seka-

ligus mempertahankan atau memperbaiki akurasi.

Seluruh mekanisme tersebut bertumpu pada satu persamaan kecil. Karena langkah penalaran laten tidak menghasilkan token, keluaran satu langkah — yaitu *hidden state* lapisan terakhir — harus dipetakan kembali menjadi sesuatu yang dapat dibaca model sebagai masukan. LatentMAS menyelesaikannya dengan sebuah pemetaan linier yang diperoleh dari regresi *ridge* [Hoerl dan Kennard, 1970] atas kedua matriks embedding model. Pemetaan itu diperkenalkan sebagai penyelesaian rekayasa terhadap ketidaksesuaian ruang masukan dan keluaran, dan tidak pernah dibandingkan terhadap alternatif mana pun. Dengan kata lain, komponen yang menanggung seluruh beban mekanisme kolaborasi laten justru merupakan komponen yang paling sedikit diuji.

Pada saat yang sama, literatur penalaran laten untuk model tunggal telah menghasilkan beberapa cara lain membentuk masukan langkah berikutnya. Alih-alih memetakan *hidden state* secara linier, ketiganya terlebih dahulu mengubahnya menjadi distribusi peluang atas kosakata, lalu membentuk masukan sebagai gabungan berbobot embedding token. *Soft Thinking* memakai distribusi peluang itu secara langsung; *Stochastic Soft Thinking* [Zhang dkk, 2025] menambahkan derau Gumbel agar penalaran tidak terkunci pada token berpeluang tertinggi; sedangkan *Mixture of Inputs* [Zhuang dkk, 2025] menggabungkan distribusi tersebut dengan token hasil pengambilan sampel melalui pembobotan yang bergantung pada entropi. Ketiganya dirancang dan diuji untuk model tunggal yang bernalar sendiri, dan belum pernah dipindahkan ke konteks kolaborasi laten antar-agen.

Terdapat alasan teoretis untuk menduga bahwa pilihan persamaan tersebut berpengaruh, dan bahwa pengaruhnya tidak seragam antar jenis tugas. Ketiga cara alternatif di atas menghasilkan vektor yang selalu berada di dalam lambung konveks embedding token, yaitu wilayah yang memang pernah dilihat model selama pelatihan. Pemetaan linier *ridge* tidak memiliki kendala tersebut: hasilnya dapat mendarat di mana saja dalam ruang berdimensi sama. Apabila vektor yang diumpangkan berada jauh dari wilayah embedding yang sah, identitas token yang dibawanya dapat rusak. Kerusakan semacam itu masih dapat dipulihkan pada tugas yang jawabannya

pendek, tetapi tidak pada tugas yang menuntut setiap simbol ditulis persis, seperti pembangkitan kode atau penulisan ekspresi matematis.

Penelitian ini merumuskan kelima cara pembentukan langkah laten tersebut ke dalam satu kerangka matematis yang sama, sehingga keempatnya dapat dinyatakan sebagai pemilihan bobot pada simpleks peluang dan yang kelima dapat ditunjukkan berada di luar keluarga itu. Kelimanya kemudian dibandingkan secara terkendali pada kolaborasi *multi-agent* sekuensial, dengan seluruh komponen lain — topologi agen, *prompt*, model, dan soal — dijaga tetap. Pengujian dilakukan pada tiga tolok ukur penalaran umum yang mewakili tingkat tuntutan presisi simbolik yang berbeda, ditambah satu domain simbolik berupa pembangkitan ekspresi faktor alpha [Han dkk, 2026] sebagai pengujian eksternal. Seluruh eksperimen dijalankan pada model lokal Qwen3-8B [Yang dkk, 2025].

1.2. Rumusan Masalah

Berdasarkan latar belakang dan permasalahan yang telah diuraikan, penelitian ini dirumuskan ke dalam beberapa pertanyaan sebagai berikut.

1. Bagaimana berbagai formulasi pembentukan representasi laten dapat dinyatakan dalam suatu kerangka matematis yang seragam sehingga memungkinkan perbandingan terkendali antar-metode pada sistem multi-agen?
2. Bagaimana pengaruh formulasi representasi laten terhadap kemampuan penalaran dan fidelitas informasi simbolik pada kolaborasi multi-agen, dan apakah pengaruh tersebut berubah sesuai dengan tuntutan presisi simbolik tugas?
3. Apakah komunikasi antar-agen melalui KV-cache mampu mempertahankan kinerja penalaran yang sebanding dengan komunikasi berbasis teks dengan biaya token dan waktu inferensi yang lebih rendah, serta bagaimana pengaruh formulasi representasi laten terhadap efisiensi tersebut?
4. Sejauh mana representasi laten mampu mempertahankan informasi simbolik ketika digunakan untuk menghasilkan ekspresi faktor terstruktur, dan apakah

kualitas keluaran yang dihasilkan tetap dapat dievaluasi melalui pengujian terhadap data pasar?

1.3. Pembatasan Masalah

Agar penelitian tetap terarah dan tidak meluas di luar ruang lingkup yang ditetapkan, penelitian ini dibatasi pada hal-hal berikut.

1. Model bahasa yang digunakan adalah Qwen3-8B dengan inferensi lokal. Penelitian tidak menguji generalisasi terhadap ukuran maupun keluarga model bahasa lainnya.
2. Seluruh intervensi terhadap proses penalaran bersifat *training-free*. Tidak dilakukan perubahan bobot model, *fine-tuning*, maupun pembelajaran penguatan.
3. Sistem multi-agen menggunakan topologi rantai sekuensial dengan jumlah agen yang telah ditetapkan. Topologi hierarkis, bercabang, dan bentuk koordinasi multi-agen lainnya tidak dievaluasi.
4. Formulasi representasi laten yang dibandingkan dibatasi pada *raw*, *soft*, *sample*, *Gumbel-Softmax*, dan *Mixture of Inputs* (MoI).
5. Medium komunikasi utama yang dibandingkan adalah komunikasi berbasis teks dan komunikasi berbasis KV-cache, dengan konfigurasi agen tunggal digunakan sebagai acuan. Medium gabungan KV-cache dan teks digunakan secara terbatas sebagai kondisi pelengkap dan tidak menjadi dasar utama pengujian statistik.
6. Evaluasi kemampuan penalaran pada lengan utama dibatasi pada GSM8K, ARC-Challenge, dan HumanEval-Plus. Ketiga tugas digunakan untuk merepresentasikan tuntutan keluaran numerik, pilihan simbolik, dan pembangkitan kode.
7. Evaluasi simbolik tambahan menggunakan generasi ekspresi faktor terstruktur berbasis domain-specific language (DSL). Lengan ini digunakan sebagai

pengujian kemampuan mempertahankan muatan simbolik dan bukan sebagai penelitian mengenai strategi investasi.

8. Evaluasi faktor dilakukan melalui validitas ekspresi dan metrik kinerja faktor pada data pasar. Hasil *backtest* tidak ditafsirkan sebagai prediksi keuntungan investasi aktual.

1.4. Tujuan dan Manfaat Penelitian

Sejalan dengan rumusan masalah yang telah ditetapkan, penelitian ini bertujuan untuk:

1. Merumuskan berbagai pendekatan pembentukan representasi laten ke dalam suatu kerangka matematis yang seragam sehingga karakteristik dan perbedaan antar-metode dapat dibandingkan secara terkendali.
2. Menganalisis pengaruh formulasi representasi laten terhadap kemampuan penalaran pada sistem multi-agen serta mengidentifikasi hubungan antara formulasi tersebut dan kemampuan mempertahankan informasi simbolik pada tugas dengan tingkat tuntutan presisi yang berbeda.
3. Mengevaluasi efisiensi komunikasi antar-agen berbasis KV-cache dibandingkan dengan komunikasi berbasis teks berdasarkan kinerja penalaran, penggunaan token, dan waktu inferensi, serta menentukan kondisi formulasi representasi laten yang memungkinkan komunikasi laten mencapai kinerja yang sebanding dengan komunikasi teks.
4. Mengevaluasi kemampuan representasi laten dalam mempertahankan muatan simbolik pada tugas generasi ekspresi faktor terstruktur serta membandingkan keandalan dan kualitas ekspresi yang dihasilkan melalui evaluasi validitas ekspresi dan pengujian pada data pasar.

Manfaat yang diharapkan adalah sebagai berikut.

1. Menyediakan kerangka matematis yang menyatukan beberapa pendekatan penalaran laten yang selama ini dibahas terpisah, sehingga keduanya dapat diperbandingkan tanpa mengubah sistem di sekitarnya.
2. Memberikan bukti empiris mengenai kondisi tempat kolaborasi laten dapat dan tidak dapat diandalkan, khususnya pada keluaran yang menuntut ketepatan simbolik.
3. Menyediakan acuan kinerja dan biaya bagi penerapan kolaborasi laten pada model berukuran menengah yang dijalankan secara lokal.

1.5. Tinjauan Pustaka

Berikut beberapa literatur kunci yang menjadi acuan penelitian ini.

Zou dkk [2025] mengusulkan LatentMAS, kerangka kolaborasi *multi-agent* di ruang laten. Setiap agen membangkitkan pikiran laten melalui representasi lapisan terakhir, lalu meneruskan memori kerjanya berupa KV-cache kepada agen berikutnya tanpa melalui teks. Penelitian ini mengambil mekanisme tersebut sebagai objek yang diuji, khususnya persamaan pemetaan *hidden state* yang menjadi tumpuannya.

Zhang dkk [2025] menelaah mekanisme kerja *soft thinking* dan menunjukkan bahwa penalaran lunak yang deterministik cenderung terkunci pada token berpeluang tertinggi. Sebagai perbaikan, penulis mengusulkan penambahan derau Gumbel pada logit sebelum pembentukan bobot. Penelitian ini mengadopsi persamaan tersebut sebagai salah satu kondisi yang dibandingkan.

Zhuang dkk [2025] mengusulkan *Mixture of Inputs*, yang memperlakukan distribusi keluaran model sebagai *prior* dan token hasil pengambilan sampel sebagai observasi, lalu membentuk masukan berikutnya dari ekspektasi *posterior* keduanya. Bobot campurannya bergantung pada entropi distribusi, sehingga menyesuaikan diri terhadap tingkat keyakinan model.

Hao dkk [2024] dan survei Chen dkk [2025] menempatkan ketiga pendekatan di atas dalam paradigma penalaran laten yang lebih luas, yaitu pemindahan

langkah penalaran dari barisan token diskret ke ruang representasi kontinu.

Han dkk [2026] mengusulkan kerangka penemuan faktor alpha berbasis LLM yang memformulasikan pencarian faktor sebagai pembangkitan ekspresi simbolik dan mengevaluasinya melalui metrik seperti *information coefficient* dan kinerja portofolio. Penelitian ini memakai domain tersebut sebagai pengujian eksternal terhadap kemampuan kanal laten mempertahankan muatan simbolik, bukan sebagai upaya mengembangkan kembali kerangka tersebut.

Hoerl dan Kennard [1970] memperkenalkan regresi *ridge* sebagai penyelesaian teregularisasi bagi sistem persamaan yang berkondisi buruk. Bentuk tertutup penyelesaian tersebut merupakan dasar matriks pemetaan yang dipakai LatentMAS.

1.6. Metodologi Penelitian

Metodologi yang digunakan adalah studi literatur dan eksperimen terkendali. Studi literatur dilakukan dengan menelaah publikasi mengenai penalaran laten, kolaborasi *multi-agent*, dan evaluasi model bahasa, kemudian menurunkan persamaan tiap metode dari sumber aslinya. Eksperimen dilakukan dengan menjalankan sistem *multi-agent* pada beberapa tolok ukur dan satu domain simbolik, dengan seluruh kondisi memakai soal yang sama sehingga perbandingannya bersifat berpasangan. Analisis dilakukan menggunakan uji statistik nonparametrik yang sesuai untuk data berpasangan, disertai selang kepercayaan *bootstrap* dan koreksi terhadap perbandingan berganda. Seluruh komputasi dilakukan menggunakan bahasa Python.

1.7. Sistematika Penulisan

Penyusunan laporan ini mengacu pada sistematika berikut.

BAB I PENDAHULUAN

Bab ini berisi latar belakang, rumusan masalah, pembatasan masalah, tujuan dan manfaat penelitian, tinjauan pustaka, metodologi penelitian, dan sistematika penulisan.

BAB II LANDASAN TEORI

Bab ini menguraikan dasar teori yang digunakan, mencakup probabilitas dan distribusi yang relevan, teori informasi, inferensi Bayes, aljabar linear dan representasi vektor, arsitektur *transformer* beserta *KV-cache*, penalaran laten dan ketiga metode pembentukan representasi laten, sistem *multi-agent*, konsep evaluasi empiris model bahasa, faktor alpha beserta metrik evaluasinya, dan pengujian statistik yang dipakai.

BAB III METODOLOGI PENELITIAN

Bab ini menetapkan objek penelitian berupa persamaan langkah laten, menurunkan kelima persamaan yang dibandingkan ke dalam satu kerangka bersama, menyatakan rancangan dua sumbu eksperimen, hipotesis, data dan tugas evaluasi, protokol pengambilan sampel berpasangan, metrik, serta prosedur analisis statistik.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil eksperimen beserta pembahasannya, mencakup perbandingan akurasi antar-persamaan, keterbedaan hasil menurut jenis tugas, biaya komputasi medium laten, fidelitas simbolik keluaran, bukti mekanisme yang menjelaskan pola hasil, hasil pada domain faktor simbolik, serta batas berlaku seluruh temuan.

BAB V KESIMPULAN DAN SARAN

Bab ini memuat kesimpulan yang menjawab rumusan masalah beserta saran bagi penelitian selanjutnya.

BAB II

LANDASAN TEORI

Bab ini menyajikan konsep dan teori dasar yang menjadi landasan penelitian. Pembahasan meliputi probabilitas, distribusi relevan, teori informasi, inferensi Bayesian, aljabar linear, pembelajaran mesin, model bahasa, Transformer, penalaran dengan *Large Language Model* (LLM), *Soft Thinking*, *Mixture of Inputs* (MoI), *Stochastic Soft Thinking*, sistem multi-agen, LatentMAS, hubungan matematis antar metode, serta metode pengujian statistik. Setiap subbab dilengkapi dengan definisi, notasi, serta penurunan rumus utama yang digunakan dalam penelitian.

2.1. Probabilitas dan Variabel Acak

2.1.1. Ruang Sampel dan *Event*

Ruang sampel Ω adalah himpunan semua hasil yang mungkin dari suatu percobaan acak. *Event* A adalah subset dari Ω , $A \subseteq \Omega$. Probabilitas $P(A)$ memenuhi aksioma: $P(\Omega) = 1$, $0 \leq P(A) \leq 1$, dan untuk *event* saling lepas berlaku aditivitas.

2.1.2. Variabel Acak

Variabel acak X adalah fungsi $X : \Omega \rightarrow \mathbb{R}$ yang memetakan setiap hasil ke bilangan real. Variabel acak dapat bersifat diskrit atau kontinu.

2.1.3. Distribusi Probabilitas

Distribusi probabilitas variabel acak X menggambarkan peluang X mengambil nilai-nilai tertentu. Untuk kasus diskrit dinyatakan dengan *probability mass function* (PMF), untuk kontinu dengan *probability density function* (PDF).

2.1.4. Probability Mass Function

Untuk variabel diskrit, PMF $p(x)$ didefinisikan sebagai

$$p(x) = P(X = x), \quad \sum_x p(x) = 1. \quad (2.1)$$

2.1.5. Probability Density Function

Untuk variabel kontinu, PDF $f(x)$ memenuhi $f(x) \geq 0$ dan $\int_{-\infty}^{\infty} f(x) dx = 1$.

1. Probabilitas pada interval $[a, b]$ dihitung sebagai $\int_a^b f(x) dx$.

2.1.6. Conditional Probability

Probabilitas bersyarat A diberikan B didefinisikan sebagai

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0. \quad (2.2)$$

2.1.7. Joint Probability

Probabilitas gabungan dua variabel acak X dan Y dinyatakan dengan $P(X = x, Y = y)$ (diskrit) atau $f_{X,Y}(x, y)$ (kontinu).

2.1.8. Marginal Probability

Distribusi marginal diperoleh dengan menjumlahkan (diskrit) atau mengintegrasikan (kontinu) distribusi gabungan:

$$P(X = x) = \sum_y P(X = x, Y = y), \quad f_X(x) = \int f_{X,Y}(x, y) dy. \quad (2.3)$$

2.1.9. Independence

Dua variabel acak X dan Y dikatakan saling bebas jika

$$P(X = x, Y = y) = P(X = x)P(Y = y) \quad \text{atau} \quad f_{X,Y}(x, y) = f_X(x)f_Y(y). \quad (2.4)$$

2.1.10. Expectation

Nilai harapan $E[X]$ dihitung sebagai

$$E[X] = \sum_x x p(x) \quad \text{atau} \quad E[X] = \int x f(x) dx. \quad (2.5)$$

2.1.11. Variance dan Covariance

Variansi $\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2$. Kovariansi $\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$.

2.2. Distribusi Probabilitas yang Relevan

2.2.1. Bernoulli

Variabel acak $X \sim \text{Bernoulli}(p)$ mengambil nilai 1 dengan peluang p dan 0 dengan peluang $1 - p$. PMF: $P(X = x) = p^x(1 - p)^{1-x}$, $x \in \{0, 1\}$.

2.2.2. Categorical

Distribusi kategoris dengan V kategori memiliki parameter $p = (p_1, \dots, p_V)$, $p_i \geq 0$, $\sum_i p_i = 1$. PMF: $P(X = i) = p_i$. Vektor indikator y one-hot dengan $y_i = 1$ dan lainnya 0 dapat dinyatakan sebagai $Y \sim \text{Categorical}(p)$.

2.2.3. Multinomial

Distribusi Multinomial $\text{Mult}(n, p)$ menghitung frekuensi x_i dari setiap kategori dalam n percobaan independen. PMF:

$$P(X_1 = x_1, \dots, X_V = x_V) = \frac{n!}{x_1! \dots x_V!} \prod_{i=1}^V p_i^{x_i}, \quad \sum_i x_i = n. \quad (2.6)$$

2.2.4. Gaussian

Distribusi Normal $\mathcal{N}(\mu, \sigma^2)$ dengan PDF

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right). \quad (2.7)$$

2.2.5. Gumbel

Variabel acak $G \sim \text{Gumbel}(\mu, \beta)$ memiliki fungsi distribusi kumulatif

$$F_G(g) = \exp \left[-\exp \left(-\frac{g - \mu}{\beta} \right) \right], \quad \beta > 0 [Zhangdkk, 2025]. \quad (2.8)$$

Distribusi Gumbel standar ($\mu = 0, \beta = 1$) mempunyai sifat penting untuk *Gumbel-Max Trick*.

Gumbel-Max Trick. Diberikan probabilitas kategori $p_i > 0, \sum_i p_i = 1$. Bangkitkan $g_i \stackrel{\text{iid}}{\sim} \text{Gumbel}(0, 1)$. Maka

$$Y = \arg \max_i (\log p_i + g_i) \sim \text{Categorical}(p). \quad (2.9)$$

Bukti. Misalkan k adalah indeks tertentu. $P(Y = k) = P(\log p_k + g_k \geq \log p_i + g_i \ \forall i \neq k)$. Kondisikan pada g_k , peluang tersebut adalah $\prod_{i \neq k} P(g_i \leq \log p_k - \log p_i + g_k)$. Untuk $G \sim \text{Gumbel}(0, 1)$, berlaku $P(G \leq t) = \exp(-e^{-t})$. Maka

$$P(Y = k \mid g_k) = \prod_{i \neq k} \exp(-e^{-(\log p_k - \log p_i + g_k)}) = \exp \left(-\sum_{i \neq k} \frac{p_i}{p_k} e^{-g_k} \right). \quad (2.10)$$

Integralkan terhadap distribusi g_k dengan PDF $f(g_k) = e^{-g_k} \exp(-e^{-g_k})$:

$$P(Y = k) = \int_{-\infty}^{\infty} \exp \left(-\frac{1 - p_k}{p_k} e^{-g_k} \right) e^{-g_k} e^{-e^{-g_k}} dg_k. \quad (2.11)$$

Substitusi $u = e^{-g_k}$ memberikan $du = -e^{-g_k} dg_k$, sehingga $dg_k = -du/u$. Faktor e^{-g_k} pada pengintegral saling meniadakan dengan $1/u$ tersebut, dan karena $\frac{1-p_k}{p_k} + 1 = \frac{1}{p_k}$ kedua eksponen bergabung menjadi satu. Dengan demikian

$$P(Y = k) = \int_0^{\infty} \exp \left(-\frac{1 - p_k}{p_k} u \right) e^{-u} du = \int_0^{\infty} \exp \left(-\frac{u}{p_k} \right) du = p_k. \quad (2.12)$$

Dengan demikian, Gumbel-Max menghasilkan sampel sesuai distribusi p . ■

2.2.6. Dirichlet

Distribusi Dirichlet dengan parameter konsentrasi $\alpha = (\alpha_1, \dots, \alpha_V)$, $\alpha_i > 0$, didefinisikan pada simpleks Δ^{V-1} [Zhuang dkk, 2025]. PDF:

$$f(w; \alpha) = \frac{1}{B(\alpha)} \prod_{i=1}^V w_i^{\alpha_i-1}, \quad w_i \geq 0, \quad \sum_i w_i = 1, \quad (2.13)$$

dengan $B(\alpha)$ fungsi beta multinomial. Nilai harapan: $E[W_i] = \alpha_i / \sum_j \alpha_j$. Sifat konjugat terhadap Multinomial dibahas pada 2.4.6.

2.3. Teori Informasi

2.3.1. Information

Informasi diri (*self-information*) dari *event* dengan probabilitas p didefinisikan sebagai $I(p) = -\log p$.

2.3.2. Entropy

Entropi distribusi diskrit p adalah $H(p) = -\sum_i p_i \log p_i$, mengukur ketidakpastian rata-rata.

2.3.3. Normalized Entropy

Entropi ternormalisasi terhadap nilai maksimum $\log V$:

$$H = -\frac{1}{\log V} \sum_i p_i \log p_i, \quad 0 \leq H \leq 1 [Zhuang dkk, 2025]. \quad (2.14)$$

2.3.4. Cross-Entropy

Cross-entropy antara distribusi sebenarnya p dan distribusi aproksimasi q didefinisikan sebagai $H(p, q) = -\sum_i p_i \log q_i$.

2.3.5. *KL Divergence*

Divergensi Kullback–Leibler mengukur perbedaan dua distribusi:

$$D_{\text{KL}}(p\|q) = \sum_i p_i \log \frac{p_i}{q_i}. \quad (2.15)$$

2.3.6. *Jensen-Shannon Divergence*

Divergensi Jensen-Shannon merupakan simetrisasi KL:

$$\text{JSD}(p\|q) = \frac{1}{2}D_{\text{KL}}(p\|m) + \frac{1}{2}D_{\text{KL}}(q\|m), \quad m = \frac{p+q}{2}. \quad (2.16)$$

2.4. *Bayesian Inference*

2.4.1. *Prior*

Distribusi *prior* $P(\theta)$ menyatakan keyakinan awal tentang parameter θ .

2.4.2. *Likelihood*

Likelihood $P(\mathcal{D}|\theta)$ adalah probabilitas data $\mathcal{D}$ jika parameter adalah θ .

2.4.3. *Evidence*

Evidence atau *marginal likelihood* $P(\mathcal{D}) = \int P(\mathcal{D}|\theta)P(\theta)d\theta$.

2.4.4. *Posterior*

Distribusi *posterior* diperoleh melalui teorema Bayes:

$$P(\theta|\mathcal{D}) = \frac{P(\mathcal{D}|\theta)P(\theta)}{P(\mathcal{D})}. \quad (2.17)$$

2.4.5. *Bayesian Updating*

Pembaruan pengetahuan dilakukan dengan menggunakan *posterior* sebagai *prior* baru ketika data tambahan diterima.

2.4.6. Conjugate Prior

Distribusi *prior* disebut konjugat terhadap *likelihood* jika *posterior* berada dalam keluarga distribusi yang sama [Zhuang dkk, 2025]. Contoh utama: distribusi Dirichlet adalah konjugat bagi Multinomial.

Misalkan $w \sim \text{Dir}(\alpha)$ dan observasi $c = (c_1, \dots, c_V)$ dengan $n = \sum_i c_i$ berasal dari $\text{Mult}(n, w)$. Maka

$$P(c|w) \propto \prod_i w_i^{c_i}.$$

Posterior:

$$P(w|c) \propto \prod_i w_i^{\alpha_i + c_i - 1} \sim \text{Dir}(\alpha + c). \quad (2.18)$$

2.4.7. Posterior Predictive Distribution

Distribusi prediktif *posterior* untuk observasi baru $\tilde{x}$ adalah $P(\tilde{x}|\mathcal{D}) = \int P(\tilde{x}|\theta)P(\theta|\mathcal{D})d\theta$.

2.5. Linear Algebra dan Representasi Vektor

2.5.1. Scalar, Vector, Matrix

Skalar a , vektor $\mathbf{v} \in \mathbb{R}^n$, matriks $A \in \mathbb{R}^{m \times n}$.

2.5.2. Dot Product

Hasil kali titik $\mathbf{u} \cdot \mathbf{v} = \sum_i u_i v_i = \mathbf{u}^\top \mathbf{v}$.

2.5.3. Matrix Multiplication

Perkalian matriks $C = AB$ dengan $C_{ij} = \sum_k A_{ik} B_{kj}$.

2.5.4. Norm

Norma vektor $\|\mathbf{v}\|_2 = \sqrt{\sum_i v_i^2}$. Norma Frobenius matriks A :

$$\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2} = \sqrt{\text{tr}(A^\top A)}. \quad (2.19)$$

2.5.5. *Linear Combination*

Kombinasi linear vektor $\{\mathbf{v}_1, \dots, \mathbf{v}_K\}$ adalah $\sum_k c_k \mathbf{v}_k$ dengan koefisien $c_k \in \mathbb{R}$.

2.5.6. *Convex Combination*

Kombinasi konveks mensyaratkan $c_k \geq 0$ dan $\sum_k c_k = 1$. Himpunan semua kombinasi konveks dari titik-titik tersebut membentuk *convex hull*. Simpleks probabilitas Δ^{V-1} adalah himpunan semua vektor w dengan $w_i \geq 0$, $\sum_i w_i = 1$, sehingga setiap titik di dalamnya merupakan kombinasi konveks dari basis one-hot.

2.5.7. *Vector Space*

Ruang vektor dilengkapi dengan operasi penjumlahan dan perkalian skalar yang memenuhi aksioma tertentu.

2.5.8. *Embedding Space*

Ruang embedding adalah ruang vektor kontinu berdimensi d tempat representasi token (kata) dipetakan melalui matriks embedding W_{in} [Mikolov dkk, 2013]. Setiap baris $W_{\text{in}}[i]$ adalah vektor embedding token ke- i .

2.6. *Machine Learning dan Neural Network*

2.6.1. *Model Parametrik*

Model parametrik dinyatakan sebagai fungsi f_θ dengan parameter θ yang dipelajari dari data.

2.6.2. *Parameter dan Hyperparameter*

Parameter dipelajari selama pelatihan; *hyperparameter* ditentukan sebelum pelatihan (misalnya laju pembelajaran, koefisien regularisasi).

2.6.3. *Forward Pass*

Komputasi maju dari masukan hingga keluaran melalui lapisan-lapisan jaringan.

2.6.4. *Loss Function*

Fungsi kerugian $L(\theta)$ mengukur kesalahan model; diminimalkan saat pelatihan.

2.6.5. *Training vs Inference*

Pelatihan menyesuaikan θ menggunakan data; inferensi menggunakan model tetap untuk menghasilkan prediksi.

2.6.6. *Autoregressive Modeling*

Model autoregresif memprediksi token berikutnya berdasarkan token-token sebelumnya:

$$P(x_1, \dots, x_T) = \prod_{t=1}^T P(x_t \mid x_{<t}) [\text{Goodfellow et al., 2016}]. \quad (2.20)$$

2.7. *Language Model*

2.7.1. *Token dan Vocabulary*

Teks dipecah menjadi token (kata, subkata). *Vocabulary* V adalah himpunan semua token yang dikenal model.

2.7.2. *Tokenization*

Proses pemecahan teks menjadi deretan token sesuai *vocabulary*.

2.7.3. *Next-Token Prediction*

Model bahasa menghasilkan distribusi $P(x_t \mid x_{<t})$ untuk token berikutnya.

2.7.4. *Language Model Probability*

Probabilitas keseluruhan teks diberikan oleh rantai autoregresif di atas.

2.7.5. *Logits*

Hidden state terakhir $h \in \mathbb{R}^d$ dipetakan menjadi vektor logit $\ell = W_{\text{out}}h \in \mathbb{R}^V$.

2.7.6. *Softmax*

Distribusi token diperoleh dengan fungsi *softmax*:

$$p_i = \frac{e^{\ell_i}}{\sum_j e^{\ell_j}}, \quad p = \text{softmax}(\ell). \quad (2.21)$$

2.7.7. *Temperature*

Temperature $T > 0$ digunakan untuk mengontrol ketajaman distribusi:

$$p_i = \frac{e^{\ell_i/T}}{\sum_j e^{\ell_j/T}}. \quad (2.22)$$

$T \rightarrow 0$ membuat distribusi mendekati one-hot pada argmax; $T \rightarrow \infty$ mendekati seragam.

2.7.8. *Greedy Decoding*

Memilih token dengan probabilitas tertinggi setiap langkah ($T = 0$).

2.7.9. *Sampling*

Mengambil sampel token dari distribusi p dengan T tertentu.

2.7.10. *Top-k*

Hanya mempertimbangkan k token dengan probabilitas tertinggi; probabilitas lainnya dinolkan lalu dinormalisasi ulang.

2.7.11. *Top-p (Nucleus Sampling)*

Memilih himpunan token terkecil yang massa probabilitas kumulatifnya $\geq p$; sisanya dinolkan.

2.8. *Transformer*

2.8.1. *Arsitektur Transformer*

Transformer terdiri dari lapisan *self-attention* dan *feed-forward network* yang disusun secara berulang, dengan normalisasi dan koneksi residual [Vaswani dkk, 2017].

2.8.2. *Embedding*

Token masukan dipetakan menjadi vektor embedding melalui W_{in} .

2.8.3. *Positional Encoding*

Informasi posisi ditambahkan ke embedding agar model mengenali urutan token [Su dkk, 2024].

2.8.4. *Self-Attention*

Mekanisme atensi yang mengaitkan setiap token dengan seluruh token dalam sekuens.

2.8.5. *Query, Key, Value*

Setiap token menghasilkan vektor Q, K, V melalui proyeksi linear dari *hidden state*.

2.8.6. *Scaled Dot-Product Attention*

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V [\text{Vaswanidkk}, 2017]. \quad (2.23)$$

2.8.7. *Multi-Head Attention*

Mekanisme atensi dijalankan secara paralel dengan beberapa *head*, lalu hasilnya digabung [Ainslie dkk, 2023].

2.8.8. *Feed-Forward Network*

Setiap posisi diproses dengan MLP dua lapis (umumnya dengan aktivasi nonlinier).

2.8.9. *Residual Connection*

Menambahkan masukan lapisan ke keluarannya: $\text{Output} = \text{Layer}(x) + x$.

2.8.10. *Layer Normalization*

Normalisasi pada dimensi fitur untuk menstabilkan pelatihan.

2.8.11. *Decoder-only Transformer*

Arsitektur yang hanya menggunakan dekoder Transformer; kausal mask memastikan prediksi hanya bergantung pada token sebelumnya.

2.8.12. *Causal Masking*

Masker segitiga bawah mencegah setiap token memperhatikan token di depannya pada *self-attention*.

2.8.13. *KV Cache*

Key dan *Value* dari langkah sebelumnya disimpan dalam cache untuk menghindari komputasi ulang saat pembangkitan autoregresif [Zou dkk, 2025]. Untuk lapisan l , KV-cache adalah pasangan $(K^{(l)}, V^{(l)})$.

2.9. *Large Language Model dan Reasoning*

2.9.1. LLM

Model bahasa berskala besar dengan miliaran parameter, dilatih pada korpus teks masif.

2.9.2. *Chain-of-Thought*

Teknik penalaran dengan menghasilkan langkah-langkah perantara dalam bahasa alami sebelum jawaban akhir [Guo dkk, 2024].

2.9.3. *Discrete Token Reasoning*

Penalaran yang setiap langkahnya direpresentasikan sebagai token diskrit yang didekode.

2.9.4. *Continuous Reasoning*

Penalaran yang menggunakan representasi kontinu (misalnya *hidden state* atau *embedding*) tanpa menghasilkan token eksplisit [Chen dkk, 2025].

2.9.5. *Latent Representation*

Representasi tersembunyi dalam ruang kontinu yang menyandikan informasi konteks.

2.9.6. *Hidden State*

Vektor $h_t \in \mathbb{R}^d$ pada lapisan terakhir Transformer setelah memproses token ke- t .

2.9.7. *Latent Thought*

Proses berpikir dalam ruang laten kontinu, di mana setiap langkah menggunakan representasi laten sebagai masukan [Hao dkk, 2024].

2.10. *Soft Thinking*

2.10.1. *Discrete Token Thinking*

Model konvensional memilih satu token diskrit pada setiap langkah; informasi distribusi penuh dibuang.

2.10.2. *Soft Token*

Soft token mempertahankan seluruh distribusi probabilitas $p = \text{softmax}(\ell/T)$ di atas *vocabulary* [Zhang dkk, 2025]. Vektor p berada pada simpleks probabilitas Δ^{V-1} .

2.10.3. *Soft Input*

Alih-alih memberikan embedding satu token, *soft input* menggunakan ekspektasi embedding terhadap distribusi p :

$$\tilde{z}_{\text{soft}} = \sum_{i=1}^V p_i W_{\text{in}}[i]. \quad (2.24)$$

Karena $p \in \Delta^{V-1}$, $\tilde{z}_{\text{soft}}$ merupakan kombinasi konveks dari baris-baris W_{in} .

2.10.4. *Probability Simplex*

Simpleks Δ^{V-1} adalah himpunan titik dengan koordinat nonnegatif yang berjumlah satu [Zhang dkk, 2025].

2.10.5. *Weighted Embedding*

Setiap token diberi bobot sesuai probabilitasnya untuk membentuk representasi kontinu yang kaya informasi.

2.10.6. *Top-k/Top-p Truncation*

Distribusi dapat dipotong dengan Top-k atau Top-p sebelum menghitung *soft token*.

2.10.7. *Greedy Pitfall*

Pendekodean *greedy* dapat mengabaikan alternatif bernilai tinggi, menyebabkan teks repetitif atau kurang kreatif.

2.11. *Mixture of Inputs*

2.11.1. Motivasi MoI

MoI menggabungkan token hasil sampling dengan informasi distribusi penuh untuk mendapatkan representasi yang seimbang antara eksplorasi dan eksploitasi ketidakpastian.

2.11.2. *Entropy-scaled Prior*

Misalkan p adalah distribusi token. Entropi ternormalisasi $H = -\frac{1}{\log V} \sum_i p_i \log p_i \in [0, 1]$ mengukur ketidakpastian.

2.11.3. *Dirichlet Prior*

Parameter prior Dirichlet untuk bobot campuran w ditetapkan sebagai $\alpha = Hp$. Jumlah konsentrasi $\sum_i \alpha_i = H$ mencerminkan tingkat kepercayaan pada distribusi p : ketidakpastian tinggi memberikan konsentrasi lebih besar.

2.11.4. *Multinomial Observation*

Satu token sampel $Y \sim \text{Categorical}(p)$ dianggap sebagai observasi *pseudo-count* $c = (\beta + 1 - H)e_Y$, dengan e_Y vektor one-hot dan $\beta \geq 0$ parameter *pseudo-count*.

2.11.5. *Posterior Distribution*

Karena Dirichlet konjugat terhadap Multinomial, *posterior* setelah mengamati c adalah

$$w \mid y \sim \text{Dir}(\alpha + c) = \text{Dir}(Hp + (\beta + 1 - H)e_Y). \quad (2.25)$$

2.11.6. Posterior Mean

Nilai harapan *posterior* untuk setiap komponen i adalah

$$E[w_i | y] = \frac{\alpha_i + c_i}{\sum_j (\alpha_j + c_j)}. \quad (2.26)$$

Jumlah parameter *posterior*: $\sum_j (\alpha_j + c_j) = H + (\beta + 1 - H) = \beta + 1$. Sehingga

$$w_i = \frac{Hp_i + (\beta + 1 - H)(e_Y)_i}{\beta + 1}. \quad (2.27)$$

Dalam notasi vektor,

$$w_{\text{moi}} = \frac{Hp + (\beta + 1 - H)e_Y}{\beta + 1}. \quad (2.1)$$

2.11.7. Mixing Weight

Persamaan (2.1) menunjukkan bahwa w_{moi} adalah kombinasi konveks dari distribusi *soft* p dan sampel one-hot e_Y :

$$w_{\text{moi}} = \lambda p + (1 - \lambda)e_Y, \quad \lambda = \frac{H}{\beta + 1}. \quad (2.28)$$

Karena $0 \leq H \leq 1$ dan $\beta \geq 0$, maka $0 \leq \lambda \leq 1$. Ini membuktikan bahwa MoI menginterpolasi antara *soft* dan *discrete sample*.

2.11.8. Mixture Embedding

Representasi embedding MoI diperoleh sebagai kombinasi konveks embedding token:

$$\tilde{z}_{\text{moi}} = \sum_i w_{\text{moi},i} W_{\text{in}}[i] = \lambda \tilde{z}_{\text{soft}} + (1 - \lambda) W_{\text{in}}[Y]. \quad (2.2)$$

2.12. *Stochastic Soft Thinking*

2.12.1. *Randomness dan Exploration*

Penyisipan keacakan membantu eksplorasi representasi laten, menghindari jalan buntu deterministik.

2.12.2. *Stochastic Soft Token*

Token lunak yang diperoleh dari distribusi acak yang parameterisasinya berasal dari logit model.

2.12.3. *Dirichlet Sampling*

Membangkitkan titik pada simpleks dengan distribusi Dirichlet.

2.12.4. *Gumbel Distribution*

Telah dijelaskan pada 2.2.5. Sifat Gumbel-Max digunakan untuk sampling kategoris terdiferensialkan.

2.12.5. *Gumbel-Max Trick*

Sudah diuraikan beserta buktinya di 2.2.5: $\arg \max_i (\log p_i + g_i) \sim \text{Categorical}(p)$.

2.12.6. *Gumbel-Softmax*

Operasi $\arg \max$ tidak terdiferensialkan, maka digantikan oleh *softmax* dengan temperatur $\tau > 0$:

$$w_i^{\text{gumbel}} = \frac{\exp((\log p_i + g_i)/\tau)}{\sum_j \exp((\log p_j + g_j)/\tau)}. \quad (2.3)$$

Dengan $p = \text{softmax}(\ell)$, bentuk di atas ekuivalen dengan $\text{softmax}((\ell + g)/\tau)$ karena $\log p_i = \ell_i - \log \sum_j e^{\ell_j}$, dan konstanta penormalan saling menghilangkan.

Konvergensi ke one-hot. Misalkan $k = \arg \max_i (\log p_i + g_i)$ unik. Maka

untuk $i \neq k$,

$$\frac{w_i}{w_k} = \exp \left(\frac{(\log p_i + g_i) - (\log p_k + g_k)}{\tau} \right) \xrightarrow{\tau \rightarrow 0^+} 0. \quad (2.29)$$

Akibatnya $w_k \rightarrow 1$ dan $w_i \rightarrow 0$ untuk $i \neq k$. Jadi $w^{\text{gumbel}} \rightarrow e_k$, yang secara distribusi setara dengan sampel dari p berdasarkan Gumbel-Max. Dengan demikian Gumbel-Softmax menghasilkan aproksimasi kontinu dari sampling kategoris.

2.12.7. *Temperature*

Temperatur τ mengontrol tingkat *softness*: kecil mendekati diskrit, besar mendekati seragam.

2.12.8. *Softness vs Randomness*

Softness (kehalusan distribusi) dan *randomness* (keacakan) dapat divariasikan secara independen melalui T dan τ .

2.12.9. *Luce's Choice Axiom*

Aksioma pemilihan Luce menyatakan bahwa rasio peluang dua alternatif tidak bergantung pada alternatif lain; dipenuhi oleh *softmax*.

2.12.10. *Sampling Without Replacement*

Teknik mengambil beberapa token tanpa pengembalian, relevan untuk eksplorasi.

2.12.11. *Test-time Scaling*

Meningkatkan komputasi saat inferensi (misalnya jumlah langkah laten) untuk meningkatkan performa.

2.12.12. *Pass@k*

Metrik keberhasilan jika jawaban benar muncul dalam k sampel pertama.

2.13. *Multi-Agent System*

2.13.1. *Agent*

Entitas yang memproses informasi, memiliki memori, dan menghasilkan aksi (teks atau representasi laten).

2.13.2. *Multi-Agent System (MAS)*

Sistem yang terdiri dari beberapa agen yang berinteraksi untuk menyelesaikan tugas.

2.13.3. *Sequential MAS*

Agen bekerja secara berurutan; keluaran agen sebelumnya menjadi masukan agen berikutnya.

2.13.4. *Hierarchical MAS*

Agen disusun dalam hierarki, misalnya perencana, kritikus, penyuling.

2.13.5. *Agent Communication*

Pertukaran informasi antar agen melalui medium tertentu (teks, representasi laten, atau kombinasi).

2.13.6. *Text-based Communication*

Agen berkomunikasi dengan menghasilkan teks dalam bahasa alami.

2.13.7. *Latent Communication*

Agen berkomunikasi dengan mentransfer representasi laten (misalnya *hidden state* atau KV-cache) tanpa dekoding ke teks.

2.14. LatentMAS

2.14.1. Autoregressive Latent Thought

LatentMAS menjalankan langkah penalaran laten secara autoregresif: setiap langkah menghasilkan vektor laten yang diumpankan kembali sebagai masukan.

2.14.2. Hidden-State Recurrence

Misalkan h_t adalah *hidden state* setelah langkah ke- t . Fungsi transformasi Φ memetakan h_t menjadi representasi laten $z_t = \Phi(h_t)$ yang digunakan sebagai *input embedding* langkah berikutnya:

$$h_{t+1} = f_{\theta}(z_t \mid \text{KV}_{1:t}). \quad (2.30)$$

2.14.3. Latent Working Memory

Seluruh rangkaian langkah laten membentuk memori kerja laten yang disimpan dalam KV-cache.

2.14.4. KV-cache Transfer

KV-cache dari agen sebelumnya dapat diteruskan ke agen berikutnya sebagai memori kerja, sehingga komunikasi laten terjadi tanpa teks.

2.14.5. Input-Output Alignment

Agar *hidden state* dapat digunakan sebagai *input embedding*, diperlukan pemetaan dari ruang keluaran (logit) ke ruang embedding masukan.

2.14.6. Alignment Matrix

Dicari matriks $W_a \in \mathbb{R}^{d \times d}$ sehingga hW_a mendekati representasi yang sesuai di ruang embedding.

2.14.7. Ridge Regression

Masalah *alignment* dirumuskan sebagai regresi linear dengan regularisasi *ridge*:

$$J(W_a) = \|W_{\text{out}}W_a - W_{\text{in}}\|_F^2 + \lambda\|W_a\|_F^2, \quad \lambda > 0. \quad (2.4)$$

Penurunan solusi. Turunan terhadap W_a :

$$\frac{\partial J}{\partial W_a} = 2W_{\text{out}}^\top(W_{\text{out}}W_a - W_{\text{in}}) + 2\lambda W_a. \quad (2.31)$$

Menyamakan dengan nol menghasilkan persamaan normal teregularisasi:

$$(W_{\text{out}}^\top W_{\text{out}} + \lambda I)W_a = W_{\text{out}}^\top W_{\text{in}}. \quad (2.32)$$

Dengan asumsi matriks dalam kurung invertibel, solusi *ridge*:

$$W_a = (W_{\text{out}}^\top W_{\text{out}} + \lambda I)^{-1} W_{\text{out}}^\top W_{\text{in}}. \quad (2.5)$$

Matriks ini meminimalkan kesalahan rekonstruksi embedding dari *hidden state*.

2.14.8. Wasserstein Distance

Digunakan untuk mengukur kesamaan distribusi laten dalam beberapa analisis teoretis.

2.14.9. Expressiveness Theorem

Teorema dalam LatentMAS yang menyatakan bahwa representasi laten mampu mengekspresikan sembarang distribusi token.

2.14.10. Lossless Communication Theorem

Teorema yang menjamin bahwa komunikasi berbasis KV-cache tidak kehilangan informasi dibandingkan komunikasi teks.

2.14.11. Complexity Analysis

Analisis kompleksitas komputasi menunjukkan penghematan token dan inferensi lebih efisien dibandingkan rantai pemikiran tekstual.

Representasi Laten LatentMAS. Setelah memperoleh W_a , *hidden state* diproyeksikan:

$$\tilde{z}_{\text{raw}} = hW_a. \quad (2.33)$$

Untuk menjaga magnitudo setara dengan embedding, dilakukan normalisasi dengan rata-rata norma embedding $\rho = \frac{1}{V} \sum_i \|W_{\text{in}}[i]\|_2$:

$$\boxed{z_{\text{raw}} = \rho \frac{hW_a}{\|hW_a\|_2}}. \quad (2.6)$$

Inilah representasi langkah laten yang digunakan dalam metode *raw*.

2.15. Konsep Matematis yang Menghubungkan Ketiga Metode

2.15.1. Discrete $\rightarrow$ Probability Distribution

Token diskrit yang dipilih secara *greedy* atau *sampling* mengabaikan distribusi penuh p . Mempertahankan p memungkinkan representasi yang lebih informatif.

2.15.2. Probability Distribution $\rightarrow$ Embedding

Distribusi $p \in \Delta^{V-1}$ dipetakan ke ruang embedding melalui kombinasi konveks $\tilde{z} = \sum_i p_i W_{\text{in}}[i]$. Ini menghasilkan titik di *convex hull* embedding token.

2.15.3. Embedding $\rightarrow$ Hidden Representation

Embedding tersebut diumpankan ke Transformer untuk menghasilkan *hidden state* baru.

2.15.4. Hidden Representation → Latent Thought

Hidden state diproses oleh Φ menjadi representasi laten z_t , membentuk siklus penalaran kontinu.

2.15.5. Stochasticity → Exploration

Penambahan keacakan melalui Gumbel atau sampling Dirichlet menciptakan eksplorasi dalam ruang representasi.

2.15.6. Latent Representation → Agent Communication

Representasi laten (KV-cache atau embedding) dapat ditransfer antar agen, memungkinkan komunikasi efisien tanpa dekoding teks.

Keterkaitan metode: Semua metode *soft*, *sample*, *gumbel*, *moi* menghasilkan representasi sebagai kombinasi konveks dari embedding token, karena vektor bobot w selalu berada pada simpleks Δ^{V-1} . Metode *raw* (LatentMAS) menggunakan pemetaan linear langsung dari *hidden state* tanpa melalui simpleks. Dengan demikian, perbedaan fundamental terletak pada cara menghasilkan bobot w (untuk keluarga relaksasi diskret) atau transformasi linear W_a (untuk *raw*). Formulasi ini menyatukan pandangan teoretis terhadap langkah laten.

2.16. Pengujian Statistik

Untuk membandingkan performa metode secara berpasangan pada data yang sama, digunakan beberapa uji statistik yang sesuai dengan jenis data dan desain eksperimen.

2.16.1. Uji McNemar

Uji McNemar digunakan untuk data biner berpasangan (benar/salah) dari dua metode pada sampel yang identik. Misalkan n_{01} = banyaknya soal yang dijawab benar oleh metode A tetapi salah oleh B, dan n_{10} sebaliknya. Statistik uji (dengan

koreksi kontinuitas):

$$\chi^2 = \frac{(|n_{01} - n_{10}| - 1)^2}{n_{01} + n_{10}} \sim \chi^2(1) \text{ di bawah } H_0. \quad (2.34)$$

Nilai p kecil menunjukkan perbedaan signifikan.

2.16.2. Uji Wilcoxon *Signed-Rank*

Untuk metrik kontinu atau ordinal (misalnya skor, jumlah token), uji Wilcoxon Signed-Rank menguji median selisih nol. Langkah: hitung selisih d_i antara dua metode untuk setiap subjek, buang nol, peringkat nilai mutlaknya, lalu jumlahkan peringkat bertanda:

$$W = \sum_{i=1}^n \text{sgn}(d_i) R_i. \quad (2.35)$$

Di bawah H_0 , distribusi W simetris di sekitar nol; untuk sampel besar digunakan aproksimasi normal.

2.16.3. Interval Kepercayaan *Bootstrap*

Untuk memperoleh interval kepercayaan perbedaan metrik tanpa asumsi distribusi, digunakan *bootstrap* persentil: ambil B sampel ulang dengan pengembalian, hitung statistik $\hat{\theta}_b^*$, lalu interval kepercayaan $100(1 - \alpha)\%$ adalah persentil $\alpha/2$ dan $1 - \alpha/2$ dari distribusi bootstrap.

2.16.4. Koreksi Perbandingan Berganda

Jika banyak uji dilakukan bersamaan, probabilitas kesalahan tipe I meningkat. Koreksi Bonferroni membagi tingkat signifikansi α dengan jumlah uji m : $\alpha_{\text{adj}} = \alpha/m$. Alternatif lain meliputi metode Holm atau Benjamini-Hochberg.

Dengan landasan teori ini, metode, derivasi, dan alat evaluasi yang digunakan dalam penelitian telah diuraikan secara menyeluruh, siap mendukung perumusan metode pada bab selanjutnya.

2.17. Uji Cochran Q

Uji McNemar membandingkan tepat dua perlakuan. Apabila terdapat $k > 2$ perlakuan biner yang dikenakan pada blok yang sama, diperlukan uji yang menguji kesamaan seluruh perlakuan sekaligus. Uji Cochran Q merupakan perluasan McNemar untuk keadaan tersebut.

Misalkan $x_{ij} \in \{0, 1\}$ menyatakan hasil perlakuan ke- j pada blok ke- i , dengan $i = 1, \dots, n$ dan $j = 1, \dots, k$. Definisikan jumlah keberhasilan tiap perlakuan dan tiap blok,

$$G_j = \sum_{i=1}^n x_{ij}, \quad L_i = \sum_{j=1}^k x_{ij}. \quad (2.36)$$

Hipotesis nolnya menyatakan bahwa peluang keberhasilan sama untuk seluruh perlakuan,

$$H_0 : \pi_1 = \pi_2 = \dots = \pi_k. \quad (2.37)$$

Gagasan uji ini adalah membandingkan keragaman antar-perlakuan terhadap keragaman yang masih mungkin muncul setelah pengaruh blok dikeluarkan. Blok dengan $L_i = 0$ atau $L_i = k$ tidak membawa informasi karena seluruh perlakuan memberi hasil sama, dan blok semacam itu tidak menyumbang pada penyebut. Statistik ujinya adalah

$$Q = \frac{(k-1) \left(k \sum_{j=1}^k G_j^2 - \left(\sum_{j=1}^k G_j \right)^2 \right)}{k \sum_{i=1}^n L_i - \sum_{i=1}^n L_i^2}. \quad (2.38)$$

Pembilang Persamaan 2.38 sebanding dengan ragam G_j antar perlakuan: apabila seluruh perlakuan menghasilkan jumlah keberhasilan yang sama, maka $k \sum_j G_j^2 = (\sum_j G_j)^2$ dan pembilangnya nol. Penyebutnya menghitung banyaknya blok yang tidak seragam, sehingga Q membesar hanya apabila perbedaan antar-perlakuan besar relatif terhadap jumlah blok yang memang membedakan perlakuan.

Di bawah H_0 dan untuk n yang cukup besar,

$$Q \xrightarrow{d} \chi_{k-1}^2, \quad (2.39)$$

sehingga H_0 ditolak apabila Q melampaui kuantil χ^2 dengan derajat bebas $k - 1$. Untuk $k = 2$, Persamaan 2.38 tereduksi menjadi statistik McNemar tanpa koreksi kontinuitas, sehingga kedua uji tersebut konsisten satu sama lain.

2.18. Evaluasi Empiris Model Bahasa

2.18.1. *Benchmark*

Benchmark adalah himpunan soal baku beserta jawaban rujukan dan prosedur penilaian yang disepakati, yang dipakai untuk membandingkan beberapa sistem pada dasar yang sama. Sebuah *benchmark* terdiri atas tiga komponen: himpunan soal, definisi jawaban benar, dan aturan penskoran. Keterbandingan antar-penelitian bergantung pada ketiganya, bukan hanya pada nama himpunan datanya.

Sebuah *benchmark* dinyatakan jenuh apabila sistem-sistem yang dibandingkan sudah mencapai skor yang berdekatan sehingga perbedaan antar sistem tidak lagi terukur. Keadaan tersebut relevan ketika hasil pengujian menunjukkan perbedaan yang kecil pada satu tugas tetapi besar pada tugas lain.

2.18.2. *Exact Match*

Untuk soal dengan jawaban tunggal, penilaian dilakukan dengan mencocokkan jawaban yang diekstrak dari keluaran model terhadap jawaban rujukan. Misalkan $\hat{a}_i$ jawaban model pada soal ke- i dan a_i jawaban rujukan, maka

$$EM = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[\text{norm}(\hat{a}_i) = \text{norm}(a_i)], \quad (2.40)$$

dengan $\text{norm}(\cdot)$ suatu prosedur penormalan, misalnya membuang spasi berlebih atau menyeragamkan format bilangan. Prosedur penormalan merupakan bagian dari definisi metrik: dua penelitian yang memakai penormalan berbeda tidak

menghasilkan angka yang sebanding.

2.18.3. *Pass@1* dan Pengujian Unit

Untuk tugas pembangkitan kode, kebenaran tidak dapat dinilai dengan pencocokan teks karena satu spesifikasi dapat diwujudkan oleh banyak program yang berbeda. Penilaian dilakukan dengan mengeksekusi program terhadap sehimpunan pengujian unit. Program dinyatakan benar apabila seluruh pengujian lulus tanpa galat waktu jalan. Dengan satu sampel keluaran per soal,

$$\text{pass@1} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[\text{seluruh pengujian unit soal ke-}i \text{ lulus}]. \quad (2.41)$$

Metrik ini bersifat ”semua atau tidak sama sekali” pada tingkat soal. Satu pengenalan yang salah tulis sudah cukup membuat seluruh program gagal, sehingga tugas semacam ini menuntut ketepatan simbolik yang jauh lebih tinggi daripada tugas berjawaban pendek.

2.18.4. Keandalan Bentuk Keluaran

Kegagalan sistem pembangkit dapat berasal dari dua sumber yang berbeda: jawaban yang salah, atau keluaran yang tidak berbentuk sehingga jawabannya tidak dapat diekstrak sama sekali. Untuk memisahkan keduanya didefinisikan laju keluaran berbentuk sah,

$$\text{format rate} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[\text{keluaran soal ke-}i \text{ dapat diurai}]. \quad (2.42)$$

Kedua metrik tersebut tidak saling menggantikan. Sistem dapat memperbaiki laju keluaran berbentuk sah tanpa memperbaiki ketepatan jawaban, dan sebaliknya. Melaporkan keduanya secara terpisah mencegah perbaikan keandalan terbaca sebagai perbaikan kemampuan bernalar.

2.18.5. Rancangan Berpasangan dan Verifikasi Sidik Jari

Apabila beberapa perlakuan dibandingkan pada himpunan soal yang berbeda, selisih skornya bercampur dengan perbedaan tingkat kesulitan soal. Rancangan berpasangan menghilangkan sumber keragaman tersebut dengan mengenakan seluruh perlakuan pada soal yang sama, sehingga perbandingan dapat dilakukan pada tingkat soal.

Dalam praktik komputasi, kesamaan soal biasanya dijamin dengan memakai *seed* pengambilan sampel yang sama. Jaminan tersebut lemah karena perubahan versi pustaka atau urutan pemuatan data dapat mengubah subsampel tanpa mengubah *seed*. Karena itu kesamaan soal diperiksa langsung melalui sidik jari, yaitu ringkasan deterministik atas daftar indeks soal yang benar-benar dikerjakan tiap perlakuan. Dua perlakuan hanya diperbandingkan secara berpasangan apabila sidik jarinya identik.

2.19. Faktor Alpha dan Evaluasinya

2.19.1. Faktor Alpha sebagai Ekspresi Simbolik

Faktor alpha adalah fungsi yang memetakan data pasar historis menjadi satu skor untuk tiap saham pada tiap hari perdagangan. Skor tersebut dimaksudkan berkorelasi dengan imbal hasil masa depan sehingga dapat dipakai memeringkat saham. Faktor dinyatakan sebagai ekspresi simbolik atas sehimpunan variabel dasar (harga buka, tinggi, rendah, tutup, volume, dan imbal hasil) yang dirangkai memakai pustaka fungsi tertentu.

Himpunan variabel dan fungsi yang diperbolehkan beserta aturan perangkaiannya membentuk sebuah *domain-specific language* (DSL). Ekspresi yang melanggar aturan DSL — nama fungsi yang tidak terdaftar, jumlah argumen yang tidak sesuai, atau tanda kurung yang tidak seimbang — tidak dapat dievaluasi sama sekali. Sifat ini menjadikan pembangkitan faktor sebagai tugas dengan tuntutan ketepatan simbolik yang tinggi, setara dengan pembangkitan kode.

2.19.2. Information Coefficient

Daya prediksi sebuah faktor diukur melalui korelasi antara skor faktor dan imbal hasil yang terealisasi. Karena hubungan keduanya tidak harus linear dan distribusi imbal hasil berekor tebal, dipakai korelasi peringkat Spearman. Untuk hari perdagangan ke- t dengan N_t saham,

$$IC_t = \rho_{\text{Spearman}}(f_t, r_{t+1}), \quad (2.43)$$

dengan f_t vektor skor faktor pada hari t dan r_{t+1} vektor imbal hasil satu hari ke depan. Nilai rata-rata deret harian tersebut disebut RankIC,

$$\overline{IC} = \frac{1}{T} \sum_{t=1}^T IC_t. \quad (2.44)$$

Kestabilan sinyal diukur melalui rasio informasi deret tersebut,

$$ICIR = \frac{\overline{IC}}{s_{IC}}, \quad s_{IC}^2 = \frac{1}{T-1} \sum_{t=1}^T (IC_t - \overline{IC})^2. \quad (2.45)$$

Dengan mengasumsikan IC_t saling bebas, pengujian $H_0 : \mathbb{E}[IC_t] = 0$ memakai statistik

$$t = ICIR\sqrt{T}, \quad (2.46)$$

sehingga faktor dengan $|t| \geq 1,96$ dinyatakan memiliki daya prediksi yang berbeda dari nol pada taraf 5%. Perlu dicatat bahwa asumsi kebebasan antar-hari tidak sepenuhnya terpenuhi pada data pasar, sehingga statistik tersebut cenderung optimistis.

Tanda IC tidak menentukan kegunaan sebuah faktor, karena faktor dengan korelasi negatif dapat dipakai dengan membalik arah posisinya. Karena itu perbandingan mutu antar-sistem memakai $|IC|$.

2.19.3. Metrik Portofolio

RankIC mengukur korelasi peringkat, tetapi tidak menyatakan hasil yang diperoleh apabila sinyal tersebut benar-benar diperdagangkan. Untuk itu skor faktor diterjemahkan menjadi portofolio: pada tiap hari, saham dengan skor tertinggi dibeli dan saham dengan skor terendah dijual dalam proporsi yang sama, sehingga posisi bersihnya nol. Imbal hasil harian portofolio tersebut dinyatakan sebagai R_t .

Dari deret R_t diturunkan empat besaran. Imbal hasil tahunan diperoleh dengan menskalakan rata-rata harian terhadap banyaknya hari perdagangan dalam setahun, D ,

$$\text{ARR} = D \cdot \frac{1}{T} \sum_{t=1}^T R_t, \quad \sigma_{\text{tahunan}} = \sqrt{D} \cdot s_R. \quad (2.47)$$

Rasio Sharpe menyatakan imbal hasil per satuan risiko, dengan suku bunga bebas risiko diambil nol,

$$\text{Sharpe} = \frac{\text{ARR}}{\sigma_{\text{tahunan}}}. \quad (2.48)$$

Penurunan terdalam (*maximum drawdown*) mengukur kerugian terbesar yang pernah dialami dari puncak sebelumnya. Dengan kurva ekuitas kumulatif $C_t = \prod_{s \leq t} (1 + R_s)$,

$$\text{MDD} = \min_t \left(\frac{C_t}{\max_{s \leq t} C_s} - 1 \right). \quad (2.49)$$

Perputaran posisi mengukur besarnya perubahan bobot portofolio antar hari,

$$\text{turnover} = \frac{1}{T-1} \sum_{t=2}^T \frac{1}{2} \sum_j |w_{j,t} - w_{j,t-1}|, \quad (2.50)$$

dengan $w_{j,t}$ bobot saham ke- j pada hari t . Besaran ini dilaporkan karena biaya transaksi sebanding dengannya; perputaran yang tinggi menandakan bahwa hasil sebelum biaya dapat berubah banyak setelah biaya diperhitungkan.

BAB III

METODOLOGI PENELITIAN

3.1. Desain Penelitian

Penelitian ini menggunakan pendekatan eksperimen kuantitatif untuk menguji pengaruh formulasi persamaan langkah laten terhadap kinerja kolaborasi multi-agen berbasis *large language model* (LLM). Fokus penelitian tidak diletakkan pada perubahan arsitektur multi-agen, perancangan *prompt*, maupun perubahan mekanisme komunikasi antar-agen secara umum, melainkan pada fungsi pemetaan yang digunakan untuk mengubah *hidden state* keluaran model menjadi representasi yang dapat digunakan kembali sebagai masukan pada langkah laten berikutnya.

Objek utama penelitian dinyatakan sebagai fungsi

$$\Phi : \mathbb{R}^d \rightarrow \mathbb{R}^d,$$

dengan d menyatakan dimensi *hidden state* model. Fungsi tersebut menerima *hidden state* terakhir pada suatu langkah laten dan menghasilkan vektor yang diberikan kepada model melalui parameter `inputs_embeds`. Dengan demikian, penelitian mengisolasi persamaan langkah laten sebagai variabel utama yang dibandingkan, sementara komponen lain dari sistem dijaga tetap.

Rancangan penelitian dibangun berdasarkan dua sumbu eksperimen. Sumbu pertama mengatur *cara pembentukan representasi laten*, sedangkan sumbu kedua mengatur *medium komunikasi antar-agen*. Pemisahan kedua sumbu tersebut diperlukan agar pengaruh formulasi Φ dapat dibedakan dari pengaruh penggunaan komunikasi laten melalui KV-cache.

Secara umum, alur penelitian terdiri atas:

1. menentukan *backbone* LLM yang digunakan

2. membentuk persamaan langkah laten untuk setiap metode yang dibandingkan
3. menjalankan rangkaian agen dengan medium komunikasi yang telah ditentukan
4. mengevaluasi keluaran pada beberapa jenis tugas dengan tuntutan presisi simbolik yang berbeda
5. mengukur akurasi, keandalan keluaran, fidelitas simbolik, dan biaya komputasi
6. melakukan pengujian statistik berpasangan terhadap hasil eksperimen; dan
7. menarik kesimpulan berdasarkan hipotesis yang telah ditentukan sebelum evaluasi utama

Rancangan ini tidak ditujukan untuk menunjukkan bahwa satu metode tertentu selalu lebih baik daripada metode lainnya. Sebaliknya, pengujian dirancang untuk menentukan apakah terdapat perbedaan yang secara sistematis dapat dikaitkan dengan *keanggotaan representasi laten pada lambung konveks ruang embedding*, sebagaimana dirumuskan pada bagian berikut.

3.2. Objek Penelitian dan Formulasi Langkah Laten

3.2.1. Proses Pembangkitan Langkah Laten

Pada suatu langkah laten, model telah memproses konteks dan menghasilkan *hidden state* terakhir

$$h_t \in \mathbb{R}^d.$$

Berbeda dengan pembangkitan token autoregresif biasa yang langsung memilih sebuah token dari distribusi probabilitas, penelitian ini membentuk suatu representasi laten

$$z_t = \Phi(h_t), \tag{3.1}$$

kemudian menggunakan z_t sebagai *input embedding* untuk *forward pass* berikutnya:

$$h_{t+1} = f_{\theta}(z_t \mid \text{KV}_{1:t}). \quad (3.2)$$

Proses tersebut diulangi sebanyak m langkah. Dalam penelitian ini digunakan

$$m = 10. \quad (3.3)$$

Representasi yang dihasilkan pada setiap langkah tidak diterjemahkan menjadi token teks. Sebaliknya, representasi tersebut langsung digunakan sebagai masukan kontinu pada langkah berikutnya. Dengan demikian, satu langkah laten tidak identik dengan satu token teks.

Mekanisme ini mengikuti prinsip dasar LatentMAS, yaitu melakukan *latent thought generation* menggunakan representasi lapisan terakhir dan menyimpan hasil pemrosesan tersebut dalam KV-cache yang dapat diteruskan kepada agen berikutnya. LatentMAS menggunakan KV-cache sebagai memori kerja yang menyimpan representasi *key* dan *value* pada setiap lapisan Transformer.

Dalam implementasi penelitian, setiap *latent step* terdiri atas empat operasi utama, yaitu:

1. mengambil *last hidden state* h_t
2. menerapkan fungsi Φ untuk menghasilkan z_t
3. memasukkan z_t sebagai *virtual token* melalui `inputs_embeds`; dan
4. menjalankan *forward pass* untuk memperoleh h_{t+1}

Dengan demikian, fungsi Φ merupakan titik yang membedakan metode-metode yang dibandingkan dalam penelitian ini.

3.3. Persamaan Langkah Laten Resmi LatentMAS

3.3.1. Input–Output Alignment

LatentMAS menggunakan pemetaan linier untuk mengubah *hidden state* keluaran model ke ruang embedding masukan [Zou dkk, 2025]. Misalkan

$$W_{\text{in}} \in \mathbb{R}^{V \times d}$$

merupakan matriks embedding masukan dan

$$W_{\text{out}} \in \mathbb{R}^{V \times d}$$

merupakan matriks pada *language-model head*, dengan V merupakan ukuran kosakata.

Matriks pemetaan $M \in \mathbb{R}^{d \times d}$ diperoleh melalui permasalahan *ridge regression*

$$M = \arg \min_M \left\{ \|W_{\text{out}}M - W_{\text{in}}\|_F^2 + \lambda \|M\|_F^2 \right\}, \quad (3.4)$$

dengan $\lambda = 10^{-5}$. Bentuk tertutupnya adalah

$$M = (W_{\text{out}}^\top W_{\text{out}} + \lambda I)^{-1} W_{\text{out}}^\top W_{\text{in}}. \quad (3.5)$$

Persamaan tersebut merupakan formulasi *realignment matrix* yang digunakan LatentMAS untuk menghubungkan ruang keluaran dan ruang masukan model.

Hasil pemetaan kemudian dinormalisasi terhadap magnitudo rata-rata embedding masukan. Dengan

$$\rho = \frac{1}{V} \sum_{i=1}^V \|W_{\text{in}}[i]\|, \quad (3.6)$$

fungsi langkah laten yang digunakan sebagai *baseline* dirumuskan sebagai

$$\Phi_{\text{raw}}(h) = \rho \frac{hM}{\|hM\|}. \quad (3.7)$$

Pada penelitian ini formulasi tersebut disebut sebagai metode *raw*.

3.3.2. Batas Jaminan Persamaan Raw

Persamaan *ridge* tersebut mengoptimalkan kedekatan

$$W_{\text{out}}M \approx W_{\text{in}}.$$

Namun, objektif tersebut secara langsung mengoptimalkan pemetaan pada baris-baris W_{out} . Sementara itu, argumen aktual dari Φ_{raw} merupakan *hidden state* yang dihasilkan oleh aliran komputasi Transformer.

Oleh karena itu, terdapat perbedaan antara:

1. kemampuan M merekonstruksi embedding masukan dari baris W_{out} ; dan
2. kemampuan M menghasilkan representasi yang tetap berada pada wilayah representasi masukan ketika diberikan *hidden state* aktual sebagai input

Perbedaan tersebut menjadi dasar pengujian geometris penelitian. Pada Qwen3-8B, pengukuran awal menunjukkan

$$\frac{\|M - I\|_F}{\|I\|_F} = 1,04, \quad (3.8)$$

sedangkan rata-rata kemiripan kosinus antara h dan hM adalah sekitar 0,011. Selain itu, nilai rata-rata kemiripan kosinus antara $W_{\text{in}}[i]$ dan $W_{\text{out}}[i]$ adalah sekitar 0,0041. Pengukuran terhadap kedekatan keluaran Φ_{raw} dengan embedding token menghasilkan rata-rata maksimum kemiripan kosinus sekitar 0,31.

Hasil tersebut tidak digunakan sebagai bukti bahwa KV-cache kehilangan informasi. Sebaliknya, interpretasi metodologis penelitian ini adalah bahwa potensi kehilangan informasi perlu dipisahkan antara *mekanisme pembentukan representasi laten* dan *mekanisme pengiriman KV-cache*. Kerangka penelitian secara eksplisit

menempatkan Φ , bukan KV-cache, sebagai komponen yang diuji.

3.4. Reformulasi Langkah Laten sebagai Relaksasi Diskret

3.4.1. Bentuk Umum

Untuk memperoleh perbandingan yang terkendali antara beberapa metode, penelitian ini merumuskan langkah laten sebagai pembentukan distribusi bobot pada kosakata.

Dari *hidden state* h , diperoleh logit

$$\ell = W_{\text{out}}h, \quad (3.9)$$

kemudian distribusi probabilitas token dihitung sebagai

$$p = \text{softmax}\left(\frac{\ell}{T}\right), \quad (3.10)$$

dengan suhu

$$T = 0,7. \quad (3.11)$$

Selanjutnya didefinisikan simpleks probabilitas

$$\Delta^{V-1} = \left\{ w \in \mathbb{R}^V \mid w_i \geq 0, \sum_{i=1}^V w_i = 1 \right\}. \quad (3.12)$$

Sebuah metode langkah laten dimasukkan ke dalam keluarga relaksasi diskret apabila representasinya dapat ditulis sebagai

$$\tilde{z} = \sum_{i=1}^V w_i W_{\text{in}}[i], \quad w \in \Delta^{V-1}. \quad (3.13)$$

Setelah pembentukan $\tilde{z}$, seluruh metode dinormalisasi menggunakan konvensi yang sama:

$$\Phi(h) = \rho \frac{\tilde{z}}{\|\tilde{z}\|}. \quad (3.14)$$

Dengan formulasi tersebut, perbedaan antar-metode tidak lagi terutama terletak pada ruang representasi yang digunakan, melainkan pada *aturan pembentukan bobot* w .

3.5. Metode yang Dibandingkan

Empat metode dalam keluarga relaksasi diskret digunakan bersama satu metode *baseline* di luar keluarga tersebut.

3.5.1. Soft

Pada metode *soft*, bobot langsung menggunakan distribusi probabilitas model:

$$w_{\text{soft}} = p. \quad (3.15)$$

Representasi laten menjadi

$$\tilde{z}_{\text{soft}} = \sum_{i=1}^V p_i W_{\text{in}}[i]. \quad (3.16)$$

Formulasi ini mengikuti definisi *Soft Thinking*, yaitu menggunakan distribusi probabilitas token sebagai *soft token* dan menghasilkan *soft input* melalui kombinasi berbobot embedding token. Karena seluruh bobot tidak negatif dan berjumlah satu, representasi tersebut merupakan kombinasi konveks embedding token.

3.5.2. Sample

Metode *sample* digunakan sebagai kontrol diskret. Token

$$y \sim \text{Cat}(p) \quad (3.17)$$

dipilih dari distribusi p , kemudian bobot direpresentasikan menggunakan

vektor satuan

$$w_{\text{sample}} = e_y. \quad (3.18)$$

Dengan demikian,

$$\tilde{z}_{\text{sample}} = W_{\text{in}}[y]. \quad (3.19)$$

Metode ini merepresentasikan pembentukan input sebagaimana proses autoregresif diskret, yaitu memilih satu token dan menggunakan embedding token tersebut sebagai masukan berikutnya.

3.5.3. Gumbel

Metode *gumbel* menggunakan derau Gumbel independen

$$g_i \stackrel{\text{iid}}{\sim} \text{Gumbel}(0, 1) \quad (3.20)$$

dan membentuk

$$w_{\text{gumbel}} = \text{softmax}\left(\frac{\ell + g}{\tau}\right) [Zhangdkk, 2025]. \quad (3.21)$$

Pada penelitian ini suhu Gumbel disamakan dengan suhu distribusi, yaitu $\tau = T = 0,7$, dan derau ditambahkan pada logit sebelum pembagian suhu. Nilai tersebut merupakan setelan produksi harness penelitian ini dan berbeda dari nilai baku $\tau = 0,5$ yang dipakai paper sumber; simpangan tersebut dinyatakan agar hasilnya tidak dibaca sebagai replikasi setelan paper. Satu konsekuensi teknis perlu dicatat: karena derau ditambahkan pada ℓ yang belum dibagi T , distribusi limit ketika $\tau \rightarrow 0$ adalah $\text{Cat}(\text{softmax}(\ell))$, yaitu pengambilan sampel pada suhu satu, bukan pada suhu T seperti metode *sample*.

Formulasi tersebut berasal dari Stochastic Soft Thinking yang menggunakan Gumbel-Softmax untuk memasukkan stokastisitas ke dalam proses *soft reasoning*.

Paper tersebut menunjukkan bahwa pendekatan *soft thinking* deterministik dapat didominasi oleh sinyal token dengan probabilitas tertinggi dan mengusulkan stokastisitas untuk mengurangi perilaku *greedy*. Dalam konteks penelitian ini, Gumbel tidak diperkenalkan sebagai metode baru. Kontribusinya adalah menempatkan mekanisme tersebut sebagai salah satu aturan pembentukan w dalam kerangka langkah laten multi-agen yang sama.

3.5.4. Mixture of Inputs

Metode *Mixture of Inputs* (MoI) menggabungkan informasi distribusi p dengan token yang diperoleh melalui proses sampling [Zhuang dkk, 2025].

Misalkan

$$y \sim \text{Cat}(p) \quad (3.22)$$

dan H merupakan entropi ternormalisasi:

$$H = -\frac{\sum_{i=1}^V p_i \log p_i}{\log V}. \quad (3.23)$$

Dengan parameter β , bobot MoI dirumuskan sebagai

$$w_{\text{moi}} = \frac{Hp + (\beta + 1 - H)e_y}{\beta + 1}. \quad (3.24)$$

Pada penelitian ini digunakan

$$\beta = 1. \quad (3.25)$$

MoI pada sumber aslinya dibangun dengan interpretasi Bayesian, yaitu distribusi keluaran dipandang sebagai prior sedangkan token hasil sampling dipandang sebagai observasi. Ekspektasi posterior kemudian digunakan untuk membentuk embedding campuran.

3.6. Proposisi Matematis untuk Penyatuan Metode

3.6.1. Proposisi 1: MoI sebagai Kombinasi Konveks Soft dan Sample

Bobot MoI dapat ditulis ulang sebagai

$$w_{\text{moi}} = \frac{H}{\beta + 1}p + \frac{\beta + 1 - H}{\beta + 1}e_y. \quad (3.26)$$

Dengan mendefinisikan

$$\alpha = \frac{H}{\beta + 1}, \quad (3.27)$$

diperoleh

$$w_{\text{moi}} = \alpha w_{\text{soft}} + (1 - \alpha)w_{\text{sample}}. \quad (3.28)$$

Karena

$$0 \leq H \leq 1$$

dan $\beta \geq 0$, maka

$$0 \leq \alpha \leq 1.$$

Selanjutnya, karena w_{soft} dan w_{sample} merupakan anggota Δ^{V-1} , serta simpleks probabilitas bersifat konveks, maka

$$w_{\text{moi}} \in \Delta^{V-1}.$$

Dengan demikian, MoI merupakan kombinasi konveks antara representasi *soft* dan representasi *sample*.

Pada $\beta = 1$,

$$\alpha = \frac{H}{2}, \quad (3.29)$$

sehingga kontribusi distribusi p tidak pernah melebihi satu setengah dari total bobot. Hal ini menunjukkan bahwa MoI tetap lebih dekat secara struktural kepada token hasil sampling dibandingkan kepada *soft distribution* penuh.

3.6.2. Proposisi 2: Hubungan Gumbel dengan Sampling Diskret

Gumbel-Max Trick menyatakan bahwa

$$\arg \max_i (\ell_i + g_i)$$

menghasilkan sampel dari distribusi kategorikal yang berasal dari *softmax* logit. Oleh sebab itu, ketika temperatur Gumbel-Softmax mendekati nol,

$$\tau \rightarrow 0,$$

maka

$$w_{\text{gumbel}} \rightarrow e_y,$$

dengan

$$y \sim \text{Cat}(\text{softmax}(\ell)). \quad (3.30)$$

Dengan demikian, *gumbel* memiliki hubungan kontinu terhadap *sample*. Pada temperatur yang semakin tinggi, distribusi menjadi semakin halus.

Proposisi ini menunjukkan bahwa *soft*, *sample*, dan *gumbel* tidak perlu dipandang sebagai tiga mekanisme yang sepenuhnya terpisah. Ketiganya dapat ditempatkan dalam ruang yang sama berdasarkan bentuk bobot w .

3.6.3. Proposisi 3: Raw Berada di Luar Keluarga Relaksasi Diskret

Untuk metode *raw*, representasi sebelum normalisasi adalah

$$\tilde{z}_{\text{raw}} = hM. \quad (3.31)$$

Berbeda dengan metode yang menggunakan $w \in \Delta^{V-1}$, tidak terdapat kendala bahwa koefisien representasi terhadap embedding token harus tidak negatif dan berjumlah satu.

Dengan demikian,

$$\tilde{z}_{\text{raw}} \not\equiv \sum_i w_i W_{\text{in}}[i], \quad w \in \Delta^{V-1},$$

dalam arti bahwa fungsi objektif pembentukan M tidak memaksakan representasi tersebut sebagai kombinasi konveks embedding token.

Perbedaan mendasar antara *raw* dan empat metode lainnya bukan terletak pada linearitas, karena keduanya dapat melibatkan operasi linear. Perbedaan lainnya terletak pada *kendala konveksitas*. Metode *soft*, *sample*, *gumbel*, dan *moi* menghasilkan titik pada lambung konveks embedding masukan, sedangkan *raw* tidak memiliki kendala tersebut.

3.7. Konvensi Normalisasi

Agar perbandingan antar-metode tidak dipengaruhi oleh perbedaan magnitudo vektor, seluruh representasi laten dinormalisasi menggunakan target magnitudo yang sama:

$$\Phi(h) = \rho \frac{\tilde{z}}{\|\tilde{z}\|}. \quad (3.32)$$

Dengan demikian, perbedaan eksperimen diarahkan pada *arah representasi laten*, bukan panjang vektornya.

Secara geometris, seluruh metode dibandingkan pada bola berjari-jari ρ . Pa-

da empat metode keluarga relaksasi diskret, arah vektor dibatasi oleh kombinasi konveks embedding token, sedangkan metode *raw* tidak memiliki batas konveks tersebut.

Konvensi ini merupakan keputusan *experimental harness* penelitian, bukan karakteristik asli seluruh paper sumber. Oleh karena itu, interpretasi hasil akan dibatasi pada kondisi normalisasi yang telah ditetapkan dalam eksperimen.

3.8. Implementasi MoI dan Perbedaan dengan Kode Rujukan

MoI dalam penelitian ini diimplementasikan berdasarkan persamaan matematis metode sebagaimana didefinisikan pada paper sumber. Namun, implementasi penelitian tidak diklaim sebagai reproduksi bit-identik terhadap kode rujukan MoI.

Perbedaan utama terdapat pada normalisasi entropi. Pada penelitian ini, entropi menggunakan ukuran kosakata penuh,

$$\log V,$$

karena distribusi logit diperoleh langsung dari *output embedding* model. Sementara itu, kode rujukan MoI menggunakan distribusi terbatas yang tersedia melalui *top-20 log probabilities*, sehingga normalisasinya menggunakan $\log 20$. Dengan demikian, persamaan yang digunakan tetap mengikuti definisi matematis MoI, tetapi detail implementasinya berbeda.

Perbedaan tersebut dicatat secara eksplisit untuk mencegah interpretasi yang berlebihan terhadap hasil. Penelitian dapat menyatakan bahwa *rumus MoI diimplementasikan sesuai definisi matematis paper*, tetapi tidak menyatakan bahwa kode yang digunakan identik dengan implementasi referensi.

3.9. Rancangan Komunikasi Multi-Agen

3.9.1. Struktur Agen

Sistem multi-agen menggunakan rantai sekuensial dengan empat peran:

Planner → Critic → Refiner → Judger.

Struktur tersebut dipertahankan sama pada setiap kondisi eksperimen. Perubahan hanya dilakukan pada representasi yang digunakan untuk meneruskan informasi antar-agen.

Pada lengan faktor simbolik digunakan rantai sekuensial tiga peran, yaitu Proposal → Innovate → Construct, yang menghasilkan hipotesis, memperluasnya menjadi variasi konstruksi, lalu menuliskan ekspresi DSL akhir. Perbedaan panjang rantai antar-lengan tidak memengaruhi keabsahan perbandingan karena setiap lengan dibandingkan hanya di dalam dirinya sendiri: seluruh kondisi Sumbu A pada satu lengan memakai rantai yang sama persis.

Pendekatan ini mengikuti prinsip LatentMAS yang menggunakan struktur *sequential multi-agent system* untuk menguji pertukaran informasi antar-agen. Dalam LatentMAS, komunikasi laten dilakukan dengan meneruskan KV-cache dari agen sebelumnya kepada agen berikutnya.

3.9.2. Sumbu Medium Komunikasi

Eksperimen menggunakan tiga medium utama dan satu kontrol:

Tabel 3.1 Medium komunikasi antar-agen yang diuji beserta informasi yang diteruskan pada setiap medium.

Medium	Informasi yang diteruskan	Langkah laten	Fungsi utama
text	teks keluaran agen sebelumnya	tidak ada	kontrol komunikasi tekstual
kv_and_text	KV-cache dan teks	ada	komunikasi gabungan
kv	KV-cache	ada	komunikasi laten
baseline	tidak ada agen perantara	tidak ada	kontrol satu agen

Pada medium `text`, agen menghasilkan teks dan teks tersebut digunakan sebagai masukan agen berikutnya. Tidak terdapat proses langkah laten sehingga Φ tidak digunakan.

Hal ini menghasilkan konsekuensi metodologis penting. Karena Sumbu A tidak aktif pada medium `text`, empat varian Φ tidak menghasilkan kondisi eksperimen yang berbeda. Oleh karena itu, kondisi `text` dijalankan *satu kali*, bukan

empat kali. Pengulangan hasil yang identik sebagai empat observasi akan menciptakan pseudo-replikasi dan menyebabkan analisis statistik memperlakukan satu kondisi sebagai empat pengamatan independen.

Pada medium k_v , agen perantara tidak menghasilkan keluaran teks untuk diteruskan. Informasi diteruskan melalui KV-cache yang memuat representasi konteks dan langkah laten. LatentMAS mendefinisikan memori kerja agen sebagai kumpulan KV-cache pada seluruh lapisan Transformer dan meneruskannya dengan menggabungkan cache agen sebelumnya ke cache agen berikutnya.

3.10. Model dan Lingkungan Eksperimen

Eksperimen utama menggunakan *Qwen3-8B* sebagai *backbone* LLM. Pemilihan model ini didasarkan pada kebutuhan penelitian untuk menguji fungsi re-alignment pada kondisi ketika W_{in} dan W_{out} tidak *tied*. Pada *Qwen3-4B*, kedua matriks tersebut berbagi bobot sehingga matriks realignment mendekati identitas dan formulasi *raw* menjadi hampir tidak memberikan perubahan. Oleh sebab itu, *Qwen3-8B* dipilih sebagai *backbone* penelitian.

Penggunaan satu *backbone* dilakukan secara sengaja. Tujuannya adalah mengisolasi pengaruh persamaan langkah laten tanpa memasukkan variasi tambahan akibat perbedaan keluarga atau ukuran model.

Dengan demikian, penelitian ini *tidak* dirancang untuk menguji generalisasi metode lintas ukuran maupun lintas keluarga LLM.

3.11. Data dan Tugas Evaluasi

Evaluasi dirancang untuk mencakup tugas dengan tuntutan presisi simbolik yang berbeda. Pemilihan tugas tidak hanya bertujuan mengukur kemampuan penalaran secara umum, tetapi juga menguji apakah efek formulasi Φ berubah ketika representasi harus mempertahankan informasi simbolik secara lebih presisi.

3.11.1. GSM8K

GSM8K digunakan sebagai tugas penalaran matematika dengan jawaban numerik. Dataset tersebut berisi persoalan matematika berbentuk soal cerita yang membutuhkan penalaran multi-langkah.

Karakteristik utama GSM8K dalam penelitian ini adalah keluaran akhir relatif pendek dan dapat dievaluasi melalui kesetaraan numerik.

3.11.2. ARC-Challenge

ARC-Challenge digunakan untuk menguji pertanyaan pilihan ganda yang membutuhkan penalaran dan pemilihan jawaban yang tepat. Evaluasi dilakukan berdasarkan kecocokan pilihan jawaban.

3.11.3. HumanEval-Plus

HumanEval-Plus digunakan sebagai tugas generasi kode. Berbeda dari jawaban numerik atau pilihan ganda, keluaran kode harus memenuhi aturan sintaksis dan perilaku fungsional yang diuji melalui *unit test*. Oleh karena itu, kesalahan pada satu komponen simbolik tertentu dapat menyebabkan keseluruhan keluaran gagal memenuhi pengujian.

LatentMAS sendiri mengevaluasi tugas kode dengan menjalankan kode yang dihasilkan terhadap *unit tests* dalam lingkungan terisolasi. Sampel dinyatakan benar apabila seluruh pengujian berhasil tanpa *runtime error*.

3.11.4. Generasi Faktor Simbolik

Sebagai domain tambahan, penelitian menggunakan tugas generasi ekspresi faktor simbolik yang terinspirasi dari alur *alpha mining*. QuantaAlpha memformulasikan *alpha mining* sebagai pencarian fungsi faktor f dari ruang ekspresi yang menghasilkan sinyal prediktif terhadap *future return*.

Dalam konteks penelitian ini, domain tersebut digunakan sebagai pengujian eksternal terhadap kemampuan kanal mempertahankan muatan simbolik. Ekspresi faktor dibangun menggunakan domain-specific language (DSL), sehingga kesalah-

an pada operator, argumen, urutan fungsi, atau struktur ekspresi dapat menyebabkan ekspresi tidak dapat dievaluasi.

Domain ini tidak digunakan untuk menyatakan bahwa penelitian mengembangkan kembali algoritma QuantaAlpha. QuantaAlpha digunakan sebagai sumber konteks domain dan sebagai motivasi penggunaan ekspresi faktor simbolik; fokus penelitian tetap pada persamaan langkah laten dan komunikasi multi-agen.

3.12. Protokol Pengambilan Sampel dan Pairing

Seluruh perbandingan dirancang secara berpasangan. Setiap kondisi eksperimen menghadapi himpunan soal yang sama sehingga perbedaan performa dapat dibandingkan pada tingkat item, bukan hanya pada tingkat agregat dataset.

Untuk setiap tugas digunakan *subsample* dengan `sample_seed` yang sama pada seluruh kondisi yang dibandingkan. Kesamaan tersebut diverifikasi melalui *fingerprint* data, bukan hanya diasumsikan dari penggunaan *seed* yang sama.

Apabila *fingerprint* antar-kondisi tidak sesuai, pasangan tersebut dikeluarkan dari analisis perbandingan.

Rancangan berpasangan memiliki dua keuntungan utama. Pertama, variasi tingkat kesulitan soal dikontrol karena kondisi yang dibandingkan memperoleh soal yang sama. Kedua, analisis statistik dapat memanfaatkan informasi mengenai apakah perubahan performa terjadi pada item yang sama.

3.13. Hipotesis Penelitian

3.13.1. Hipotesis H1: Pengaruh Keanggotaan Keluarga Relaksasi Diskret

Hipotesis pertama menyatakan bahwa performa langkah laten lebih berkaitan dengan apakah representasi yang dihasilkan berada dalam keluarga

$$\tilde{z} = \sum_i w_i W_{\text{in}}[i], \quad w \in \Delta^{V-1}, \quad (3.33)$$

daripada dengan pilihan spesifik aturan pembentukan w .

Dengan demikian, dirumuskan:

H1: Metode yang menghasilkan representasi pada lambung konveks embedding memiliki karakteristik performa yang berbeda dari metode *raw* yang tidak dibatasi oleh lambung konveks.

Prediksi yang telah ditentukan adalah bahwa *raw* akan tertinggal dibandingkan anggota keluarga, sedangkan perbedaan antaranggota keluarga relatif kecil dan tidak signifikan secara statistik.

Hipotesis ini secara sengaja bukan hipotesis bahwa salah satu dari *soft*, *sample*, *gumbel*, atau *moi* merupakan metode terbaik.

3.13.2. Hipotesis H2: Presisi Simbolik

Hipotesis kedua menyatakan bahwa pengaruh representasi yang berada di luar wilayah embedding token akan semakin terlihat ketika tugas semakin bergantung pada presisi simbolik.

Urutan prediksi yang ditetapkan sebelum evaluasi utama adalah

$$\text{GSM8K} < \text{ARC-Challenge} < \text{HumanEval+}.$$

GSM8K digunakan sebagai tugas dengan jawaban numerik pendek, ARC-Challenge menggunakan simbol pilihan jawaban, sedangkan HumanEval-Plus menuntut keluaran kode yang harus memenuhi pengujian eksekusi.

Hipotesis ini memisahkan dua konsep yang sering digabungkan dalam evaluasi LLM, yaitu kemampuan mempertahankan *gagasan umum (gist)* dan kemampuan mempertahankan *identitas simbol secara tepat*.

3.13.3. Hipotesis H3: Medium Komunikasi

Hipotesis ketiga menyatakan bahwa komunikasi melalui KV-cache dapat mengurangi token keluaran secara substansial tanpa kehilangan akurasi yang berarti apabila formulasi Φ berada dalam keluarga relaksasi diskret.

H3: Medium k_v memberikan pengurangan biaya token dibanding-

an medium `text`, sementara akurasi tetap berada pada tingkat yang sebanding selama persamaan langkah laten berada dalam keluarga relaksasi diskret.

Hipotesis ini dapat ditolak apabila penggunaan `kv` menghasilkan penurunan akurasi yang bermakna dibandingkan `text`.

3.14. Variabel Penelitian

Variabel penelitian dapat dirangkum sebagai berikut.

Tabel 3.2 Variabel penelitian dan operasionalisasinya.

Jenis	Variabel	Operasionalisasi
Independen	formulasi Φ	<code>raw</code> , <code>soft</code> , <code>sample</code> , <code>gumbel</code> , <code>moi</code>
Independen	medium komunikasi	<code>text</code> , <code>kv_and_text</code> , <code>kv</code>
Independen	jenis tugas	GSM8K, ARC-Challenge, HumanEval-Plus, faktor simbolik
Konstan	backbone	Qwen3-8B
Konstan	latent steps	$m = 10$
Konstan	suhu distribusi	$T = 0,7$
Konstan	parameter MoI	$\beta = 1$
Konstan	regularisasi raw	$\lambda = 10^{-5}$
Dependen	kinerja jawaban	<code>exact-match</code> / <code>pass@1</code>
Dependen	keandalan	<code>format rate</code>
Dependen	fidelitas simbolik	<code>recall</code> , <code>exact match</code> , <code>error/korupsi simbol</code>
Dependen	biaya	token keluaran dan waktu inferensi
Dependen	faktor simbolik	validitas ekspresi dan RankIC

3.15. Metrik Evaluasi

Evaluasi tidak hanya menggunakan akurasi karena satu nilai akurasi dapat menggabungkan beberapa mekanisme kegagalan yang berbeda.

3.15.1. Akurasi Jawaban

Untuk tugas dengan keluaran yang dapat dibandingkan secara langsung digunakan *exact match*. Untuk tugas kode digunakan keberhasilan pengujian sebagai ukuran *pass@1* atau ukuran yang ekuivalen dengan satu sampel keluaran.

Pada GSM8K, jawaban dianggap benar apabila nilai numeriknya sama dengan jawaban referensi. Pada tugas pilihan ganda, jawaban dibandingkan berda-

sarkan pilihan yang benar. Prosedur tersebut mengikuti protokol evaluasi LatentMAS.

3.15.2. Format Rate

`format_rate` digunakan untuk membedakan kegagalan akibat keluaran yang tidak memiliki format yang dapat dievaluasi dari kegagalan akibat jawaban yang salah.

Pemisahan tersebut penting karena peningkatan format yang valid tidak identik dengan peningkatan kemampuan penalaran.

3.15.3. Fidelitas Simbolik

Fidelitas simbolik digunakan untuk mengukur apakah informasi yang seharusnya dipertahankan secara simbolik tetap dapat diterima pada tahap berikutnya.

Metrik yang digunakan mencakup:

- *recall* simbol
- *exact match*
- tingkat halusinasi simbol
- tingkat korupsi token; dan
- pada kasus lintas-bahasa, kemunculan karakter yang tidak diharapkan pada keluaran

Pengukuran ini dimaksudkan untuk memberikan bukti langsung mengenai jenis informasi yang hilang, bukan sekadar menunjukkan bahwa skor akhir berubah.

3.15.4. Biaya Komputasi

Efisiensi diukur melalui:

1. jumlah token keluaran per soal; dan

2. waktu inferensi per soal

Pengukuran token merupakan metrik penting karena salah satu motivasi utama LatentMAS adalah menghindari pertukaran *chain-of-thought* tekstual antar-agen. LatentMAS melaporkan pengurangan penggunaan token yang besar dibandingkan komunikasi berbasis teks.

3.16. Pengujian Geometris

Selain evaluasi tugas, dilakukan analisis geometris terhadap representasi yang dihasilkan oleh setiap metode.

Ukuran utama adalah kedekatan representasi laten terhadap embedding token, yang dapat dinyatakan melalui

$$s(z) = \max_i \cos(z, W_{\text{in}}[i]). \quad (3.34)$$

Nilai tersebut digunakan untuk mengukur apakah representasi laten memiliki arah yang dekat dengan setidaknya satu embedding token.

Pada pengukuran awal Qwen3-8B, nilai rata-rata untuk metode *raw* berada sekitar 0,31, sedangkan *soft* sekitar 0,93 dan *gumbel* sekitar 0,98.

Analisis geometris ini tidak digunakan untuk menyimpulkan bahwa kedekatan terhadap token tertentu secara otomatis menyebabkan jawaban benar. Fungsinya adalah menyediakan ukuran mekanistik yang menghubungkan formulasi matematis dengan perilaku empiris.

Dengan demikian, penelitian membedakan dua jenis bukti:

1. *bukti geometris*, yaitu lokasi representasi pada ruang embedding; dan
2. *bukti fungsional*, yaitu pengaruh lokasi tersebut terhadap hasil tugas

3.17. Analisis Statistik

Karena setiap kondisi menerima soal yang sama, analisis statistik dilakukan menggunakan pendekatan berpasangan.

3.17.1. Data Biner

Untuk data biner seperti benar/salah dan format valid/tidak valid digunakan *uji McNemar eksak*.

Uji tersebut hanya mempertimbangkan pasangan yang memberikan hasil berbeda antar-kondisi. Pendekatan eksak digunakan karena jumlah pasangan dis-kordan dapat relatif kecil.

3.17.2. Data Kontinu atau Ordinal

Untuk metrik kontinu atau ordinal seperti *recall* dan RankIC digunakan *Wilcoxon signed-rank test*. Pengujian ini dipilih karena tidak memerlukan asumsi distribusi normal dan sesuai dengan struktur data berpasangan.

3.17.3. Interval Kepercayaan

Setiap perbandingan dilengkapi dengan *interval kepercayaan bootstrap 95%*. Nilai *p* tidak digunakan sebagai satu-satunya dasar interpretasi karena pada ukuran sampel yang kecil nilai tersebut dapat memberikan gambaran yang tidak lengkap mengenai besarnya efek.

3.17.4. Koreksi Multipisitas

Karena terdapat banyak perbandingan antar-metode dan tugas, pengujian dilakukan dengan koreksi terhadap *multiple comparisons*. Kerangka penelitian menetapkan penggunaan prosedur seperti Holm atau Benjamini–Hochberg.

Secara khusus, terdapat 21 pasangan perbandingan pada tiga tugas utama sehingga dapat muncul hingga 63 pengujian. Tanpa koreksi, probabilitas munculnya temuan signifikan secara kebetulan akan meningkat.

3.17.5. Prinsip Interpretasi

Hasil yang tidak signifikan dilaporkan sebagai *tidak signifikan*. Istilah seperti ”cenderung lebih baik” tidak digunakan untuk menggantikan hasil yang gagal mencapai tingkat signifikansi yang ditentukan.

Prinsip tersebut penting terutama untuk H1. Hipotesis H1 justru memprediksi bahwa beberapa varian dalam keluarga relaksasi diskret dapat memberikan performa yang serupa. Oleh karena itu, tidak ditemukannya perbedaan signifikan antar-varian bukan merupakan kegagalan eksperimen, tetapi merupakan salah satu kemungkinan hasil yang relevan terhadap hipotesis.

3.18. Prinsip Ketelitian Klaim

Penelitian ini menerapkan prinsip bahwa kebenaran suatu pernyataan harus dipahami berdasarkan *ruang lingkup rujukannya*, bukan hanya berdasarkan kebenaran literal kalimat.

Sebagai ilustrasi, pernyataan "cokelat itu manis" dapat benar apabila yang dimaksud adalah produk cokelat yang telah diberi gula. Namun, pernyataan yang sama dapat menghasilkan pemahaman yang salah apabila konteks yang dimaksud adalah buah kakao dalam keadaan alaminya. Dengan kata lain, sebuah pernyataan dapat mengandung fakta yang benar tetapi tetap menghasilkan kesimpulan yang menyesatkan apabila konteks yang diperlukan tidak dinyatakan.

Prinsip yang sama diterapkan dalam penelitian ini. Sebagai contoh, pernyataan bahwa suatu mekanisme "mempertahankan informasi" harus selalu disertai keterangan mengenai *informasi apa, pada tahap mana, dan dalam arti apa* informasi tersebut dipertahankan.

Oleh karena itu, penelitian ini membedakan:

1. *fidelitas komunikasi KV*, yaitu kemampuan KV-cache meneruskan representasi yang telah tersimpan
2. *fidelitas pembentukan langkah laten*, yaitu kemampuan Φ menghasilkan representasi yang sesuai dengan ruang input model; dan
3. *fidelitas tugas*, yaitu kemampuan sistem mempertahankan informasi yang relevan hingga menghasilkan keluaran yang benar

LatentMAS memberikan dasar teoritis bahwa transfer working memory melalui KV-cache dapat mempertahankan representasi yang diterima agen sebelumnya

ketika kondisi model dan cache sesuai. Karena itu, penelitian ini tidak menyebut KV-cache sebagai mekanisme yang "lossy" tanpa kualifikasi. Fokus pengujian adalah apakah proses pembentukan $z_t = \Phi(h_t)$ sebelum representasi tersebut masuk ke KV-cache menghasilkan distorsi yang relevan terhadap tugas.

Dengan prinsip ini, klaim penelitian dibatasi pada kondisi eksperimen yang benar-benar diuji.

3.19. Batasan Rancangan Penelitian

Beberapa batasan ditetapkan secara sengaja.

Pertama, eksperimen utama hanya menggunakan Qwen3-8B. Oleh karena itu, hasil tidak digunakan untuk menyatakan generalisasi terhadap seluruh ukuran atau keluarga LLM.

Kedua, penelitian tidak menguji evolusi agen, *reinforcement learning*, maupun pelatihan parameter model. Fokus penelitian dibatasi pada intervensi *training-free* terhadap persamaan langkah laten.


Ketiga, penelitian tidak menganggap Gumbel-Softmax, Soft Thinking, atau MoI sebagai penemuan baru. Ketiga pendekatan tersebut telah diperkenalkan dalam penelitian terdahulu. Kontribusi penelitian terletak pada penyatuan formulasi matematisnya dan pemindahan mekanisme tersebut ke konteks kolaborasi laten multi-agen. Keempat, medium `kv_and_text` diperlakukan sebagai kondisi pelengkap pada kedua lengan, bukan sebagai kondisi utama. Pada lengan *benchmark* medium tersebut dijalankan pada subsampel kecil sebagai pemasok transkrip lampiran, sedangkan pada lengan faktor simbolik hanya sebagian ekspresi yang diambil sebagai bahan pemeriksaan kualitatif. Karena itu kesimpulan utama mengenai perbandingan medium dibatasi pada kondisi `text`, `kv`, dan agen tunggal, yaitu kondisi yang memiliki dukungan data memadai.

Kelima, hasil pada domain faktor simbolik tidak ditafsirkan sebagai prediksi keuntungan investasi. QuantaAlpha sendiri menempatkan *alpha mining* sebagai proses pencarian faktor dan mengevaluasinya melalui metrik seperti IC, ARR, dan MDD. Penelitian ini hanya menggunakan domain tersebut sebagai pengujian ke-

mampuan mempertahankan ekspresi simbolik.

3.20. Alur Pelaksanaan Penelitian

Secara keseluruhan, penelitian dilaksanakan melalui tahapan berikut:



Tahap pertama menetapkan Qwen3-8B sebagai *backbone*. Tahap kedua membentuk lima kondisi persamaan langkah laten, yaitu *raw*, *soft*, *sample*, *gumbel*, dan *moi*. Tahap ketiga menerapkan normalisasi magnitudo yang sama. Tahap keempat menjalankan sepuluh langkah laten pada setiap agen yang menggunakan komunikasi laten. Tahap kelima meneruskan informasi melalui medium `text`, `kv_and_text`, atau `kv`.

Selanjutnya, keluaran sistem dievaluasi menggunakan metrik akurasi, keandalan format, fidelitas simbolik, dan biaya. Hasil setiap kondisi kemudian dipasangkan berdasarkan soal yang sama dan dianalisis menggunakan pengujian statistik yang sesuai.

Interpretasi akhir dilakukan dengan menghubungkan tiga tingkat bukti, yaitu:

formulasi matematis → geometri representasi → kinerja tugas.

Dengan demikian, apabila suatu perbedaan performa ditemukan, penelitian tidak hanya menanyakan *metode mana yang memperoleh skor lebih tinggi*, tetapi juga *apakah perbedaan tersebut konsisten dengan perbedaan struktur matematis representasi laten yang digunakan*.

BAB IV

HASIL DAN PEMBAHASAN

Bab ini melaporkan hasil eksperimen yang dirancang pada Bab III. Penyajian disusun menurut urutan pertanyaan penelitian: perbandingan lima persamaan langkah laten pada medium komunikasi KV (4.2.), keterbedaan hasil tersebut menurut jenis tugas (4.3.), biaya komputasi medium laten (4.4.), fidelitas simbolik keluaran (4.5.), bukti mekanisme yang menjelaskan pola tersebut (4.6.), dan penerapannya pada tugas generasi faktor simbolik (4.7.). Bagian penutup menyatakan batas berlaku seluruh temuan (4.8.).

4.1. Cakupan Data dan Verifikasi Praanalisis

Seluruh angka pada bab ini berasal dari satu matriks eksperimen yang dijalankan pada 10 Agustus 2026 memakai model Qwen/Qwen3-8B dengan $m = 10$ langkah laten dan rantai empat agen (*planner*, *critic*, *refiner*, *judger*). Lengan *benchmark* mencakup tiga tugas, masing-masing dengan tujuh perlakuan, sehingga terdapat 21 sel utama. Setiap sel dievaluasi pada 100 soal.

Tiga verifikasi dijalankan sebelum analisis dilakukan. Pertama, kesamaan soal antar-sel diperiksa melalui sidik jari indeks soal: pada ketiga tugas, ketujuh sel terbukti mengerjakan himpunan soal yang identik, sehingga syarat uji berpasangan terpenuhi. Kedua, konsistensi metadata run diperiksa (model, jumlah langkah laten, suhu, *seed* pengambilan sampel); tidak ditemukan penyimpangan. Ketiga, kelengkapan berkas keluaran diperiksa terhadap daftar sel yang direncanakan.

Verifikasi ketiga menemukan satu celah data yang perlu dinyatakan. Sel *agen tunggal* pada GSM8K dijalankan sebelum mekanisme pengumpul transkrip dipasang, sehingga agregat pemakaian tokennya hilang bersama lingkungan komputasi yang telah dihapus. Akurasi dan waktu total sel tersebut tetap tercatat pada metadata dan tetap dilaporkan; hanya kolom tokennya yang kosong pada Tabel 4.1.

Sel tersebut berperan sebagai acuan, bukan bagian dari perbandingan persamaan langkah laten, sehingga celah ini tidak memengaruhi satu pun pengujian hipotesis pada bab ini.

Perlu dinyatakan pula bahwa medium *kv_and_text* pada lengan *benchmark* hanya dijalankan pada lima soal per sel sebagai pemasok transkrip untuk lampiran, bukan sebagai sel eksperimen. Sel-sel tersebut memakai subsampel soal yang berbeda dari sel utama, karena itu dikeluarkan dari seluruh tabel dan pengujian pada bab ini, dan hanya muncul pada Lampiran C. Konsekuensinya, perbandingan medium komunikasi pada lengan *benchmark* berlaku untuk tiga perlakuan — teks, KV, dan agen tunggal — bukan untuk keempat medium yang dirancang.


4.2. Hasil Lengan *Benchmark*

Tabel 4.1 Hasil lengan *benchmark*: akurasi, biaya token, dan waktu untuk tujuh perlakuan pada tiga tugas ($n = 100$ soal identik per tugas, Qwen3-8B, $m = 10$ langkah laten). Kolom SELISIH membandingkan rerata empat anggota keluarga relaksasi terhadap *raw* pada medium KV.

Tugas	Metrik	Acuan		Medium KV					Selisih
		Tunggal	Teks	raw	soft	gumbel	sample	moi	
GSM8K	Akurasi	0,92	0,90	0,83	0,88	0,91	0,86	0,92	+0,062
	Token	—	845	212	192	197	187	190	
	Waktu (dtk)	15,7	49,2	19,7	14,5	28,1	16,5	15,9	
ARC-C	Akurasi	0,91	0,93	0,89	0,94	0,91	0,94	0,91	+0,035
	Token	271	1081	219	154	154	146	145	
	Waktu (dtk)	20,3	76,0	20,6	14,0	15,9	13,3	15,3	
HumanEval+	Akurasi	0,72	0,76	0,42	0,69	0,71	0,74	0,72	+0,295
	Token	122	997	177	122	131	126	122	
	Waktu (dtk)	10,9	69,3	17,8	11,4	14,9	12,4	14,1	

Tabel 4.1 menyajikan akurasi, biaya token keluaran per soal, dan waktu per soal untuk ketujuh perlakuan. Gambar 4.1 menampilkan ketiga metrik yang sama dalam bentuk grafis.

Pola akurasi berbeda tajam antar-tugas. Pada GSM8K dan ARC-C, ketujuh perlakuan berada dalam rentang sempit: 0,83–0,92 pada GSM8K dan 0,89–0,94 pada ARC-C. Pada HumanEval+, enam perlakuan berada dalam rentang 0,69–0,76, sementara satu perlakuan — persamaan langkah laten resmi *raw* pada medium KV — mencapai 0,42 saja.



Gambar 4.1 Akurasi, biaya token, dan waktu per soal pada medium KV untuk lima persamaan langkah laten. Garis putus-putus menandai medium teks dan garis titik-titik menandai agen tunggal. Panel (b) dan (c) mencantumkan penghematan sel KV terbaik terhadap medium teks.

4.2.1. Uji Berpasangan dan Koreksi Multiplisitas

Setiap pasangan perlakuan dalam satu tugas diuji dengan uji McNemar eksak pada hasil benar/salah per soal, disertai selang kepercayaan *bootstrap* 95% untuk selisih akurasi. Terdapat 21 pasangan per tugas, sehingga seluruhnya 63 pengujian. Karena jumlah pengujian sebesar itu menjamin munculnya temuan palsu bila dibaca pada taraf nominal, nilai p dikoreksi dengan prosedur Holm dan Benjamini–Hochberg.

Pada taraf nominal $\alpha = 0,05$ terdapat 8 pasangan signifikan. Setelah koreksi Holm tersisa 6 pasangan, dan koreksi Benjamini–Hochberg memberikan himpunan yang sama. Dua pasangan yang gugur adalah pasangan GSM8K dengan $p = 0,049$, yaitu tepat di ambang, yang memang tidak bertahan terhadap koreksi apa pun.

Tabel 4.2 Seluruh pasangan yang tetap signifikan setelah koreksi Holm atas 63 uji McNemar eksak. Tak satu pun pasangan pada GSM8K dan ARC-C bertahan; seluruh pasangan yang bertahan berasal dari HumanEval+ dan melibatkan **raw** pada medium KV.

Tugas	Pasangan	Δ	SK 95%	p	p_{Holm}
HumanEval+	raw/kv vs sample/kv	-0,320	[-0,42; -0,22]	$1,9 \times 10^{-8}$	$1,2 \times 10^{-6}$
HumanEval+	moi/kv vs raw/kv	+0,300	[+0,20; +0,40]	$6,9 \times 10^{-8}$	$4,3 \times 10^{-6}$
HumanEval+	raw/baseline vs raw/kv	+0,300	[+0,20; +0,40]	$2,3 \times 10^{-7}$	$1,4 \times 10^{-5}$
HumanEval+	raw/kv vs raw/text	-0,340	[-0,45; -0,22]	$3,1 \times 10^{-7}$	$1,9 \times 10^{-5}$
HumanEval+	gumbel/kv vs raw/kv	+0,290	[+0,19; +0,40]	$1,1 \times 10^{-6}$	$6,4 \times 10^{-5}$
HumanEval+	raw/kv vs soft/kv	-0,270	[-0,37; -0,17]	$3,5 \times 10^{-6}$	$2,0 \times 10^{-4}$

Tabel 4.2 memuat keenam pasangan yang bertahan. Seluruhnya berasal dari HumanEval+, dan seluruhnya melibatkan **raw** pada medium KV. Tidak ada satu pun pasangan pada GSM8K maupun ARC-C yang bertahan, dan tidak ada satu pun

pasangan antar-anggota keluarga relaksasi yang bertahan pada tugas mana pun.

4.2.2. Homogenitas Kelima Persamaan Langkah Laten

Uji berpasangan di atas menjawab pertanyaan pasangan-demi-pasangan. Pertanyaan yang lebih pokok — apakah kelima persamaan langkah laten berbeda sama sekali pada suatu tugas — dijawab dengan uji Cochran Q , yaitu uji untuk k sampel biner berpasangan. Hasilnya disajikan pada Tabel 4.3.

Tabel 4.3 Uji Cochran Q atas 5 persamaan langkah laten pada medium KV ($n = 100$ soal berpasangan).

Tugas	Q	db	p
GSM8K	7,40	4	0,1163
ARC-C	6,71	4	0,1518
HumanEval+	65,67	4	< 0,0001

Hipotesis nol kesamaan kelima persamaan tidak dapat ditolak pada GSM8K ($p = 0,116$) maupun ARC-C ($p = 0,152$), tetapi ditolak sangat kuat pada HumanEval+ ($Q = 65,67$; $p < 0,0001$). Dengan kata lain, pada dua tugas penalaran umum pilihan persamaan langkah laten tidak dapat dibedakan dari derau, sedangkan pada tugas pembangkitan kode ia menentukan.

4.2.3. Kontras Keluarga Relaksasi terhadap Ridge W_a

Karena hipotesis penelitian menyangkut keanggotaan pada keluarga relaksasi diskret dan bukan keunggulan satu varian, kontras utama dihitung antara rerata keempat anggota keluarga (`soft`, `gumbel`, `sample`, `moi`) dan persamaan resmi `raw`, pada tingkat soal. Hasilnya disajikan pada Tabel 4.4.

Tabel 4.4 Kontras akurasi antara rerata keluarga relaksasi diskret dan ridge W_a (`raw`) pada medium KV, dengan selang kepercayaan *bootstrap* 95%.

Tugas	<code>raw</code>	Keluarga	Δ dan SK 95%
GSM8K	0,83	0,892	+0,062 [−0,005; +0,135]
ARC-C	0,89	0,925	+0,035 [−0,003; +0,080]
HumanEval+	0,42	0,715	+0,295 [+0,205; +0,388]

Pada GSM8K dan ARC-C, selang kepercayaan memuat nol, sehingga keunggulan keluarga relaksasi tidak dapat dinyatakan. Pada HumanEval+, selisihnya

+0,295 dengan selang kepercayaan yang jauh dari nol.


4.3. Disosiasi menurut Tuntutan Presisi Simbolik

Ketiga hasil di atas menunjuk pada satu kesimpulan yang sama: kerugian akibat memakai persamaan langkah laten resmi tidak seragam antar-tugas, melainkan terkonsentrasi pada tugas yang menuntut ketepatan simbol. Untuk mengujinya secara langsung, selisih Δ_t pada Tabel 4.4 dibandingkan antar-tugas. Karena ketiga tugas memakai soal yang berbeda, perbandingan antar-tugas bersifat tak-berpasangan dan selang kepercayaan selisihnya dihitung dengan *bootstrap* independen per tugas.

Tabel 4.5 Perbandingan besar kerusakan Δ antar-tugas. Tugas dengan kerusakan lebih besar disebut lebih dulu pada tiap baris.

Pasangan tugas	$\Delta\Delta$	SK 95%	p
GSM8K vs ARC-C	+0,027	$[-0,055; +0,113]$	0,5422
HumanEval+ vs ARC-C	+0,260	$[+0,157; +0,360]$	< 0,0001
HumanEval+ vs GSM8K	+0,232	$[+0,115; +0,347]$	0,0002

Tabel 4.5 dan Gambar 4.2 menunjukkan bahwa kerusakan pada HumanEval+ berbeda secara meyakinkan dari kerusakan pada kedua tugas lain, sedangkan GSM8K dan ARC-C tidak dapat dibedakan satu sama lain.



Gambar 4.2 Selisih akurasi antara rerata keluarga relaksasi diskret dan ridge W_a pada ketiga tugas, dengan selang kepercayaan *bootstrap* 95%.

Temuan ini mengonfirmasi sebagian hipotesis H2 pada Bab III. Bagian yang

terkonfirmasi adalah disosiasi itu sendiri: tugas dengan tuntutan presisi simbolik tertinggi — pembangkitan kode yang harus lolos eksekusi — mengalami kerusakan yang jauh lebih besar daripada tugas berjawaban pendek. Bagian yang tidak terkonfirmasi adalah urutan tiga tingkat yang diramalkan: GSM8K dan ARC-C tidak berbeda satu sama lain ($p = 0,542$), sehingga yang didukung data adalah perbedaan dua tingkat, bukan tiga.

Perlu dicatat bahwa urutan ini diramalkan pada dokumen rancangan eksperimen sebelum sel *benchmark* dijalankan, berdasarkan pengukuran kapasitas kanal simbolik yang dibahas pada 4.6.. Statusnya karena itu adalah ramalan yang kemudian diuji, bukan penjelasan yang disusun setelah melihat angka.

Satu pembacaan alternatif perlu ditutup di sini. Kerusakan pada HumanEval+ dapat saja berasal dari medium KV, bukan dari persamaan langkah laten. Namun pembacaan itu tidak sejalan dengan data: pada tugas yang sama, empat perlakuan lain yang juga memakai medium KV mencapai 0,69–0,74, yakni setara dengan agen tunggal (0,72) dan medium teks (0,76). Yang membedakan sel yang runtuh dari keenam sel lainnya bukan mediumnya, melainkan persamaan langkah latennya.

4.4. Efisiensi Medium Laten

Klaim utama kerangka LatentMAS [Zou dkk, 2025] bersifat efisiensi: kolaborasi laten dilaporkan menurunkan pemakaian token keluaran 70,8%–83,7% dan mempercepat inferensi $4\times$ – $4,3\times$ dibanding kolaborasi berbasis teks. Karena penelitian ini menjalankan kedua medium pada pipeline yang sama, klaim tersebut dapat diuji ulang secara langsung.

Tabel 4.6 menunjukkan penghematan token keluaran 75,0%–87,8% dan percepatan $\times 1,8$ – $\times 6,1$ terhadap medium teks. Rentang penghematan token memuat dan sedikit melampaui rentang yang dilaporkan paper asal, sehingga klaim efisiensi kerangka tersebut terrepikasi pada perangkat keras, model, dan implementasi yang berbeda.


Mekanisme penghematannya terbaca langsung dari jumlah panggilan mo-

Tabel 4.6 Efisiensi medium KV relatif terhadap medium teks, per persamaan langkah laten. Penghematan token dihitung atas token keluaran per soal; percepatan atas waktu dinding per soal. Kolom akurasi diulang dari Tabel 4.1 supaya biaya dan mutu terbaca pada satu baris.

Tugas	Langkah laten	Akurasi	Penghematan token	Percepatan
ARC-C	raw	0,89	79,7%	$\times 3,7$
ARC-C	soft	0,94	85,7%	$\times 5,4$
ARC-C	gumbel	0,91	85,7%	$\times 4,8$
ARC-C	sample	0,94	86,5%	$\times 5,7$
ARC-C	moi	0,91	86,6%	$\times 5,0$
GSM8K	raw	0,83	75,0%	$\times 2,5$
GSM8K	soft	0,88	77,2%	$\times 3,4$
GSM8K	gumbel	0,91	76,7%	$\times 1,8$
GSM8K	sample	0,86	77,8%	$\times 3,0$
GSM8K	moi	0,92	77,5%	$\times 3,1$
HumanEval+	raw	0,42	82,3%	$\times 3,9$
HumanEval+	soft	0,69	87,8%	$\times 6,1$
HumanEval+	gumbel	0,71	86,9%	$\times 4,7$
HumanEval+	sample	0,74	87,4%	$\times 5,6$
HumanEval+	moi	0,72	87,8%	$\times 4,9$

del: pada medium teks setiap soal memicu 400 panggilan berkeluaran teks untuk 100 soal (empat agen per soal), sedangkan pada medium KV hanya 100 panggilan, karena tiga agen perantara menyerahkan pekerjaan lewat KV-cache tanpa pernah memverbalkan penalarannya.

Gambar 4.3 menempatkan akurasi dan biaya token pada satu bidang. Pada GSM8K dan ARC-C, sel KV dengan persamaan dari keluarga relaksasi menempati kuadran yang diinginkan: akurasi setara medium teks dengan biaya token sekitar seperlima hingga sepertujuh. Pada HumanEval+, sel `raw` terpisah jelas dari kelompok tersebut.



Gambar 4.3 Akurasi terhadap biaya token keluaran per soal (skala logaritmik). Titik berwarna adalah medium KV dengan lima persamaan langkah laten; penanda kelabu adalah medium teks dan agen tunggal.

Perlu dinyatakan bahwa keunggulan biaya ini tidak disertai keunggulan akurasi. Terhadap medium teks, akurasi sel KV terbaik lebih tinggi pada ARC-C (0,94 vs 0,93) dan GSM8K (0,92 vs 0,90), tetapi lebih rendah pada HumanEval+ (0,74 vs 0,76); tak satu pun selisih tersebut signifikan. Rumusan yang didukung data adalah kesetaraan akurasi pada biaya yang jauh lebih rendah, bukan keunggulan akurasi.

4.5. Fidelitas Simbolik Keluaran

Akurasi menggabungkan dua hal yang perlu dipisahkan: apakah jawaban benar, dan apakah keluaran berbentuk sah. Keduanya dilaporkan terpisah.

Tingkat keluaran berformat sah (*format rate*) berada pada 0,96–1,00 di seluruh 21 sel utama, sehingga tidak ada perlakuan yang gagal secara struktural. Nilai terendah dijumpai pada `soft` di HumanEval+ (0,96) dan `sample` di GSM8K (0,97).

Ukuran kedua lebih informatif. Karena seluruh tugas berbahasa Inggris, kemunculan aksara Tionghoa di dalam jawaban menandai token dari ruang bahasa lain yang menyusup ke keluaran — bentuk kerusakan identitas token yang dapat diperiksa secara langsung. Tabel 4.7 melaporkan cacahnya.

Tabel 4.7 Jumlah jawaban yang memuat aksara Tionghoa pada tugas berbahasa Inggris, dari 100 jawaban per sel.

Tugas	Tunggal	Teks	<code>raw</code>	<code>soft</code>	<code>gumbel</code>	<code>sample</code>	<code>moi</code>
GSM8K	—	0	2	0	0	0	1
ARC-C	0	0	3	1	1	0	0
HumanEval+	0	0	1	0	0	0	0
Jumlah	0	0	6	1	1	0	1

Cacah keseluruhan kecil dan tidak memungkinkan pengujian formal, tetapi arahnya konsisten: enam dari sembilan kejadian berasal dari `raw`, sedangkan medium teks dan agen tunggal — keduanya tanpa langkah laten — tidak pernah mengalaminya. Pada satu jawaban sel `raw` ARC-C, frasa "the effects of a hypoxic event ." tercatat dengan kata terakhirnya tergantikan oleh padanan dua-aksara Tionghoa, yaitu substitusi token di tengah kalimat yang mempertahankan makna tetapi merusak bentuk keluaran.

Contoh yang paling menjelaskan berasal dari HumanEval+, tempat kerusakannya berakibat fatal karena keluarannya harus dieksekusi. Salah satu jawaban `raw` memuat penggalan `'No' #Count.digits.in` yang diikuti dua aksara Tionghoa. Dua bentuk kerusakan tampak sekaligus pada satu baris: spasi antar-kata tergantikan tanda titik, dan token dari ruang bahasa lain menyusup di tengah pengenalan. Pada tugas berjawaban pendek kerusakan semacam itu masih dapat dipulihkan oleh agen berikutnya; pada kode, satu pengenalan yang salah membuat seluruh program gagal dieksekusi. Inilah bentuk konkret dari disosiasi yang diukur pada 4.3.. Daftar lengkap cuplikan yang terekam disajikan pada Lampiran C.

Pola yang sama muncul kembali, dalam bentuk yang jauh lebih parah, pada lengan faktor (4.7.).

4.6. Bukti Mekanisme


Bagian ini menghubungkan pola akurasi di atas dengan sifat geometris persamaan langkah laten yang diuraikan pada Bab III.

Tabel 4.8 Geometri vektor langkah laten pada Qwen3-8B. Kolom terakhir adalah kosinus terhadap baris matriks embedding masukan yang paling dekat; nilai 1 berarti vektor tepat berimpit dengan embedding sebuah token.

Langkah laten	Bentuk	Anggota (★)	$\max_i \cos(\Phi(h), W_{\text{in}}[i])$
<code>raw</code>	$\rho hM/\ hM\ $	tidak	0,312 [0,16; 0,38]
<code>soft</code>	$w = p$	ya	0,927 [0,78; 1,00]
<code>gumbel</code>	$w = \text{softmax}((\ell + g)/T)$	ya	0,985 [0,86; 1,00]
<code>sample</code>	$w = e_y$	ya	1,000 [1,00; 1,00]

$\|M - I\|_F/\|I\|_F = 1,04$; $\cos(h, hM)$ rerata = 0,0112; $\cos(W_{\text{in}}[i], W_{\text{out}}[i])$ rerata = 0,0041.

Tabel 4.8 melaporkan kosinus antara vektor langkah laten dan baris matriks embedding masukan yang paling dekat dengannya. Anggota keluarga relaksasi menghasilkan vektor yang sangat dekat dengan embedding token nyata: 0,927 untuk `soft`, 0,985 untuk `gumbel`, dan tepat 1,000 untuk `sample` — nilai terakhir memang harus demikian, karena bobot campurannya adalah vektor satuan sehingga hasilnya persis satu baris embedding yang diskalakan. Sebaliknya, `raw` menghasilkan 0,312, yaitu vektor yang tidak menyerupai embedding token mana pun.



Gambar 4.4 Kosinus terhadap embedding token terdekat untuk empat persamaan langkah laten pada Qwen3-8B. Batang menunjukkan rerata atas sepuluh langkah laten; garis vertikal menunjukkan rentang minimum–maksimum.

Tiga besaran pendukung pada catatan kaki Tabel 4.8 melengkapi gambarannya. Simpangan relatif matriks realignment terhadap identitas adalah 1,04, sehingga M benar-benar memutar vektor dan bukan sekadar menskalakannya. Kosinus antara *hidden state* dan hasil pemetaannya hanya 0,0112, yaitu nyaris tegak lurus. Kosinus antara baris embedding masukan dan baris embedding keluaran yang bersesuaian hanya 0,0041, yang menjelaskan mengapa pemetaan tersebut harus memutar sejauh itu.

Perlu ditekankan bahwa keadaan ini bergantung pada model. Pada Qwen3-4B kedua matriks embedding berbagi bobot (*tied embeddings*) sehingga M mendekati identitas dan persamaan `raw` praktis tidak melakukan apa pun. Pada Qwen3-8B keduanya terpisah. Penelitian ini dipatok pada Qwen3-8B justru karena pada model dengan embedding terikat tidak ada yang dapat diperbaiki, dan seluruh perbandingan menjadi hampa.

Bukti kedua berasal dari pengukuran kapasitas kanal laten yang dilakukan sebelum lengan *benchmark* dijalankan. Pada kanal laten murni yang membawa muatan simbolik berupa nama fungsi, persamaan `raw` memberikan *recall* 0,000 — nol mutlak, bukan sekadar rendah — sedangkan keempat anggota keluarga relaksasi berada pada 0,34–0,38 dengan $m = 10$ dan 0,72–0,87 dengan $m = 40$. Perbedaan

antar-anggota keluarga tidak signifikan pada $n = 20$.

Ketiga potongan bukti tersebut menyusun satu penjelasan yang runtut. Persamaan resmi menempatkan vektor laten di luar lambung konveks embedding, tempat perilaku model tidak terdefinisi. Akibatnya identitas token diskret rusak, yang terlihat sebagai *recall* nol pada kanal simbolik dan sebagai aksara asing yang menyusup ke jawaban. Tugas yang toleran terhadap lintasan penalaran yang kabur — soal cerita berjawaban satu bilangan, soal pilihan berjawaban satu huruf — dapat pulih dari kerusakan itu; tugas yang menuntut setiap pengenalan ditulis persis tidak dapat.

Penjelasan ini juga menunjukkan letak kekeliruan penafsiran yang mudah terjadi. Teorema pemeliharaan informasi pada kerangka LatentMAS menyangkut *pengangkutan* KV antar-agen, dan tidak ada pada data ini yang membantahnya. Yang bermasalah adalah *pembangkitan* vektor laten oleh persamaan langkah laten. Kedua hal itu terpisah, dan hanya yang kedua yang diperbaiki oleh keluarga relaksasi diskret.

4.7. Lengan Faktor Simbolik

Sebagaimana ditetapkan pada Bab III, lengan faktor simbolik diperlakukan sebagai kondisi pelengkap, bukan sebagai sel eksperimen penuh. Fungsinya adalah menguji kanal yang sama pada muatan yang seluruhnya berupa simbol, yaitu ekspresi DSL yang harus dapat diurai dan dievaluasi. Bagian ini melaporkan tiga hal: keandalan keluaran agen penyusun ekspresi, mutu ekspresi yang dihasilkan, dan beberapa faktor konkret sebagai bukti kualitatif.

4.7.1. Artefak Medium Gabungan dan Pemulihannya

Pemeriksaan awal menemukan bahwa pada medium gabungan KV dan teks, keluaran agen penyusun tidak dapat diurai sama sekali sehingga sel-sel tersebut tercatat menghasilkan nol ekspresi. Pembacaan keluaran mentahnya menunjukkan bahwa penyebabnya bukan kegagalan model: keluarannya kehilangan tepat prefiks pembuka objek JSON, sedangkan sisanya utuh dan sah. Kehilangan tersebut terjadi

pada seluruh panggilan di empat dari lima sel medium gabungan, yaitu pola yang sistematis dan bukan ragam acak.

Karena bentuk kehilangannya tetap, prefiks tersebut dapat dikembalikan secara deterministik. Aturan pemulihan diterapkan seragam ke seluruh sel, dan secara empiris tidak pernah aktif pada sel yang keluarannya sudah normal: dari 77 panggilan pada medium teks dan medium KV, tak satu pun memerlukan pemulihan. Sifat itu penting karena berarti aturan tersebut tidak dapat mengubah sel yang sehat, sehingga penerapannya tidak menguntungkan atau merugikan satu metode pun. Setelah pemulihan, keempat sel tersebut menghasilkan 30–37 ekspresi unik, dengan 16–29 di antaranya lolos *gate* mutu.

Penyebab teknis kehilangan prefiks tersebut tidak ditelusuri sampai tuntas dan dicatat sebagai keterbatasan. Konsekuensi metodologisnya dinyatakan di sini: angka medium gabungan pada lengan faktor tidak dipakai untuk membandingkan medium, melainkan hanya untuk menunjukkan bahwa keluaran modelnya memang ekspresi yang sah.

4.7.2. Keandalan Keluaran Agen Penyusun

Ukuran yang paling langsung pada lengan ini tidak memerlukan data pasar sama sekali, yaitu apakah keluaran agen penyusun dapat diurai menjadi objek yang sah. Ukuran tersebut merupakan padanan *format rate* pada lengan *benchmark*, tetapi dengan tuntutan yang lebih ketat karena keluarannya harus memuat ekspresi DSL yang lengkap.

Tabel 4.9 menunjukkan pola yang sejajar dengan temuan pada HumanEval+. Medium teks dan mode `soft` pada medium KV tidak pernah gagal. Ketiga anggota keluarga relaksasi lainnya gagal pada 29%–40% panggilan. Persamaan `resmi raw` gagal pada 14 dari 18 panggilan, yaitu 78%.

Kegagalan pada `raw` juga berbeda secara kualitatif. Keluarannya bukan sekadar terpotong, melainkan rusak di tingkat kata: kunci JSON tertulis sebagai `"factor"` dan `"hypo"`, sementara kalimat hipotesisnya kehilangan spasi dan mengulang suku kata, seperti pada penggalan `"abnormallylyhigh-volumeolumedayssin`

Tabel 4.9 Keluaran agen *construct* pada lengan faktor simbolik. Kolom GAGAL adalah panggilan yang keluarannya tidak dapat diurai menjadi objek JSON yang sah; kolom PULIH adalah panggilan yang hanya kehilangan prefiks pembuka objek dan dapat dipulihkan secara deterministik.

Medium	Metode	Panggilan	Utuh	Pulih	Gagal	Gagal (%)
teks	raw	12	12	0	0	0
kv	raw	18	4	0	14	78
kv	soft	7	7	0	0	0
kv	gumbel	16	10	0	6	38
kv	sample	10	6	0	4	40
kv	moi	14	10	0	4	29
kv+teks	raw	15	5	0	10	67
kv+teks	soft	12	0	12	0	0
kv+teks	gumbel	12	0	12	0	0
kv+teks	sample	12	0	12	0	0
kv+teks	moi	18	0	14	4	22

`small-capstocksocks`". Bentuk kerusakan ini identik dengan yang terekam pada lengan *benchmark* (4.5.), yakni hilangnya identitas token pada tingkat sub-kata. Pada tugas berjawaban pendek kerusakan tersebut jarang berakibat fatal; pada ekspresi DSL, satu nama fungsi yang rusak membuat seluruh ekspresi tidak dapat diurai.

4.7.3. Mutu Ekspresi yang Dihasilkan

Tabel 4.10 Korpus ekspresi yang benar-benar diserahkan sistem ujung-ke-ujung pada medium `text` dan `kv` (enam jalannya per sel). Ekspresi disebut hidup bila RankIC-nya terdefinisi dan skornya tidak konstan.

Medium	Metode	Ekspresi	Dapat dievaluasi	$ \text{RankIC} $	$ t \geq 1,96$
teks	raw	36	20	0,0184	12
kv	raw	11	3	0,0050	2
kv	soft	33	25	0,0173	17
kv	gumbel	30	26	0,0162	14
kv	sample	22	21	0,0185	16
kv	moi	28	22	0,0171	12

Tabel 4.10 melaporkan korpus yang benar-benar diserahkan sistem ujung-ke-ujung pada medium teks dan medium KV. Perbedaan produktivitasnya besar: `raw` menghasilkan 11 ekspresi dengan 3 di antaranya dapat dievaluasi, sedangkan keempat anggota keluarga relaksasi menghasilkan 22–33 ekspresi dengan 21–26 dapat dievaluasi. Dengan kata lain, pada jumlah jalan yang sama, persamaan resmi

menghasilkan sekitar sepertujuh ekspresi yang berguna dibanding alternatifnya.

Rerata $|\text{RankIC}|$ ekspresi yang hidup berada pada 0,0162–0,0185 untuk medium teks dan keempat anggota keluarga relaksasi, sedangkan *raw* hanya mencapai 0,0050. Perlu ditekankan bahwa angka *raw* dihitung dari tiga ekspresi saja, sehingga selisih tersebut tidak layak diuji secara formal dan tidak diklaim signifikan. Yang didukung data adalah pernyataan yang lebih sederhana dan lebih kuat: pada lengan ini persamaan resmi sebagian besar gagal menghasilkan ekspresi yang dapat dinilai sama sekali.

4.7.4. Beberapa Faktor Konkret

Tabel 4.11 Faktor dengan statistik- t RankIC terbesar pada tiap sel medium yang menghasilkan ekspresi hidup, beserta metrik *backtest* portofolio desil *long-short*. Angka *backtest* tidak boleh dibaca sebagai ramalan keuntungan; lihat batas berlaku.

Sel	Ekspresi	RankIC	t	ARR	Sharpe	MD
teks/raw	<code>RANK(TS_ARGMAX(\$return, 20 ... (\$volume, 30)</code>	+0,0383	+6,59	+0,298	+2,30	-0,08
kv/gumbel	<code>TS_QUANTILE(\$volume, 20, 0 ... ume, 20, 0.1)</code>	-0,0394	-5,80	-0,361	-2,45	-0,37
kv/moi	<code>INV(LOG(SUMAC(\$volume, 10) ... \$return, 30)</code>	-0,0346	-5,36	-0,202	-1,60	-0,22
kv/sample	<code>TS_MAD(TS_SUM(\$volume, 5), ... eturn, 5), 5)</code>	-0,0194	-5,19	-0,209	-2,49	-0,26
kv/soft	<code>TS_QUANTILE(\$volume, 20, 0 ... E(\$return, 1)</code>	-0,0310	-5,66	-0,269	-2,68	-0,28

Tabel 4.11 menyajikan satu faktor dengan statistik- t terbesar dari setiap sel yang menghasilkan ekspresi hidup, lengkap dengan metrik portofolio desil *long-short*. Faktor-faktor tersebut memiliki $|t|$ antara 5 dan 7, yang menunjukkan daya prediksi yang berbeda dari nol pada jendela yang diuji.

Tiga catatan pembacaan perlu disertakan. Pertama, tanda RankIC tidak menentukan kegunaan sebuah faktor, karena faktor berkorelasi negatif dapat dipakai dengan membalik arah posisi; nilai ARR dan Sharpe yang negatif pada tabel merupakan konsekuensi langsung dari konvensi arah tersebut, bukan penanda faktor yang buruk. Kedua, angka *backtest* berasal dari simulasi kasar tanpa *slippage*, tanpa batas likuiditas, dan dengan penyeimbangan ulang harian penuh, sehingga tidak boleh dibaca sebagai ramalan keuntungan. Ketiga, seluruh angka dihitung pada jendela yang sama untuk semua metode, sehingga perbandingan antar-metode tetap sah meskipun angka mutlaknya terbatas.

Ekspresi hasil pemulihan pada medium gabungan juga dinilai untuk sebagian kecil sampel guna memastikan bahwa keluarannya memang ekspresi yang berfungsi. Sebagai contoh, ekspresi `RANK(TS_ZSCORE(TS_ARGMAX($volume, 5), 20))` dari sel `moi` memberikan RankIC 0,0147 dengan $t = 4,49$, sedangkan `RANK($return) / TS_MAD($volume, 15)` dari sel `sample` memberikan RankIC 0,0310 dengan $t = 4,21$. Keduanya menunjukkan bahwa keluaran yang semula tercatat sebagai kegagalan total sebenarnya memuat ekspresi yang sah dan bermuatan sinyal.

4.7.5. Kedudukan terhadap Hipotesis H2

Hipotesis H2 pada Bab III meramalkan bahwa kerusakan akibat persamaan resmi meningkat seiring tuntutan presisi simbolik tugas, dengan domain faktor simbolik berada pada ujung paling menuntut. Hasil pada lengan ini sejalan dengan ramalan tersebut: pada tugas berjawaban pendek selisihnya tidak signifikan, pada pembangkitan kode selisihnya 0,295, dan pada pembangkitan ekspresi DSL persamaan resmi gagal pada 78% panggilan sehingga sebagian besar keluarannya tidak sampai pada tahap penilaian.

Perbandingan pada lengan ini bersifat deskriptif dan tidak diuji secara formal, karena jumlah jalan per sel kecil dan satuan pengamatannya berbeda dari lengan *benchmark*. Karena itu lengan faktor dilaporkan sebagai bukti pendukung yang arahnya konsisten, bukan sebagai pengujian mandiri terhadap H2.

4.8. Batas Berlaku dan Ancaman Validitas

Sejumlah batas perlu dinyatakan agar kesimpulan bab ini tidak dibaca melampaui dukungan datanya.

1. Satu *backbone*. Seluruh angka diperoleh pada Qwen3-8B. Sebagaimana dibahas pada 4.6., hasilnya bergantung pada apakah kedua matriks embedding model terikat atau tidak, sehingga generalisasi lintas ukuran maupun lintas keluarga model tidak diuji dan tidak diklaim.
2. Satu *seed*. Setiap sel dijalankan satu kali. Ragam antar-*seed* karena itu ti-

dak terukur, dan selang kepercayaan yang dilaporkan hanya mencakup ragam antar-soal.

3. Subsampel 100 soal. Angka akurasi tidak sebanding langsung dengan angka yang dilaporkan atas himpunan uji penuh.
4. Medium *kv_and_text* tidak diuji. Sebagaimana dinyatakan pada 4.1., medium tersebut hanya berjalan pada lima soal per sel sebagai pemasok lampiran.
5. Urutan tiga tingkat tidak terkonfirmasi. Data mendukung perbedaan dua tingkat (kode versus selebihnya), bukan urutan $GSM8K < ARC-C < HumanEval+$ yang diramalkan.
6. *Backtest* bersifat kasar. Sebagaimana dinyatakan pada 4.7., simulasi portofolio berjalan tanpa *slippage*, tanpa batas likuiditas, dan tanpa aturan suspensi bursa, dengan penyeimbangan ulang harian penuh.

Di luar batas-batas tersebut, satu kekuatan rancangan perlu dicatat. Perbandingan antar-perlakuan tetap sah meskipun angka mutlaknya terbatas, karena seluruh perlakuan dinilai oleh pipeline yang sama persis, pada soal yang sama persis, dengan verifikasi kesamaan soal yang dilakukan secara mekanis dan bukan diasumsikan.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berdasarkan hasil eksperimen dan pembahasan pada Bab IV, penelitian ini mengevaluasi penggunaan representasi laten sebagai media penalaran dan komunikasi pada sistem multi-agen melalui perbandingan lima formulasi langkah laten, yaitu *raw*, *soft*, *sample*, *Gumbel-Softmax*, dan *Mixture of Inputs* (MoI). Evaluasi dilakukan pada dua lengan eksperimen, yaitu lengan *benchmark* untuk mengukur kemampuan penalaran dan efisiensi komunikasi serta lengan faktor simbolik untuk menguji kemampuan mempertahankan informasi berbentuk ekspresi terstruktur. Berdasarkan hasil tersebut, kesimpulan penelitian dapat dirumuskan sebagai berikut.

5.1.1. Formulasi Representasi Laten dalam Satu Kerangka Matematis

Berbagai formulasi langkah laten yang digunakan dalam penelitian dapat dinyatakan dalam kerangka umum

$$z = \sum_{i=1}^V w_i W_{\text{in}}[i], \quad w \in \Delta^{V-1},$$

untuk keluarga metode yang menghasilkan kombinasi konveks embedding token. Dalam kerangka tersebut, perbedaan utama antara *soft*, *sample*, *Gumbel-Softmax*, dan *Mixture of Inputs* terletak pada aturan pembentukan bobot (w), sedangkan persamaan *raw* pada LatentMAS tidak memiliki pembatasan bahwa koefisien harus tidak negatif dan berjumlah satu. Dengan demikian, *raw* berada di luar keluarga relaksasi diskret yang dibandingkan.

Pada MoI, bobot dapat dinyatakan sebagai kombinasi distribusi prediksi dan token hasil sampling. Dengan parameter ($\beta = 1$), bobot MoI berada pada kelu-

arga kombinasi konveks antara representasi *soft* dan representasi hasil sampling. Gumbel-Softmax juga menghasilkan interpolasi antara distribusi kontinu dan kecenderungan menuju token diskret, tetapi melalui manipulasi logit dan parameter suhu.

Perbedaan geometris tersebut konsisten dengan hasil pengukuran representasi. Kosinus antara langkah laten dan embedding token terdekat mencapai 0,927 pada *soft*, 0,985 pada Gumbel, dan 1,000 pada *sample*, sedangkan *raw* hanya mencapai 0,312. Hasil ini menunjukkan bahwa anggota keluarga relaksasi menghasilkan representasi yang secara geometris lebih dekat dengan ruang embedding token dibandingkan persamaan *raw*.

5.1.2. Pengaruh Formulasi terhadap Penalaran dan Presisi Simbolik

Hasil lengan *benchmark* menunjukkan bahwa pengaruh formulasi langkah laten tidak seragam untuk seluruh jenis tugas. Pada GSM8K dan ARC-Challenge, kelima formulasi menghasilkan kinerja yang relatif berdekatan dan tidak menunjukkan perbedaan yang cukup kuat untuk menyimpulkan bahwa salah satu formulasi secara umum lebih unggul. Sebaliknya, pada HumanEval-Plus, *raw* menunjukkan penurunan kinerja yang jelas dengan akurasi (0,42), sementara formulasi lainnya berada pada rentang (0,69)–(0,74).

Pengujian berpasangan menunjukkan bahwa perbedaan signifikan yang bertahan setelah koreksi multipisitas hanya melibatkan *raw* pada HumanEval-Plus. Tidak ditemukan perbedaan signifikan antaranggota keluarga relaksasi. Dengan demikian, hasil penelitian lebih mendukung pengaruh *keanggotaan keluarga formulasi* daripada keunggulan salah satu metode relaksasi tertentu.

Pengaruh tersebut juga bergantung pada tuntutan presisi simbolik tugas. Perbedaan kerusakan antara HumanEval-Plus dan GSM8K maupun antara HumanEval-Plus dan ARC-Challenge signifikan, sedangkan GSM8K dan ARC-Challenge tidak berbeda secara meyakinkan. Oleh karena itu, data tidak mendukung urutan tiga tingkat tuntutan simbolik yang dirumuskan sebelumnya, tetapi mendukung perbedaan dua kelompok, yaitu tugas pembangkitan kode dan kedua tugas penalaran

lainnya.

Temuan tersebut diperkuat oleh pengamatan terhadap fidelitas simbolik. Kejadian korupsi token lebih banyak ditemukan pada *raw*, termasuk kemunculan karakter yang tidak diharapkan serta kerusakan pada tingkat sub-kata. Pada tugas yang membutuhkan keluaran simbolik secara presisi, kerusakan semacam ini lebih mudah menyebabkan kegagalan keseluruhan dibanding pada tugas dengan jawaban pendek.

Dengan demikian, kelemahan yang ditemukan bukan menunjukkan bahwa komunikasi melalui KV-*cache* secara inheren kehilangan informasi. Bukti yang diperoleh justru menunjukkan bahwa masalah utama berada pada formulasi yang digunakan untuk membentuk representasi laten sebelum representasi tersebut dimasukkan ke dalam KV-*cache*.

5.1.3. Efisiensi Komunikasi Laten

Komunikasi antar-agen melalui KV-*cache* menunjukkan pengurangan biaya yang substansial dibandingkan komunikasi berbasis teks. Penghematan token keluaran mencapai 75,0%–87,8%, sedangkan percepatan waktu inferensi mencapai $1,8\times$ – $6,1\times$. Rentang penghematan token tersebut mencakup rentang 70,8%–83,7% yang dilaporkan oleh *LatentMAS*, sehingga temuan efisiensi kerangka komunikasi laten dapat direplikasi pada implementasi, perangkat keras, dan konfigurasi eksperimen penelitian ini.

Penghematan terutama berasal dari berkurangnya keluaran teks antar-agen. Pada medium teks, setiap agen perantara harus menghasilkan keluaran tekstual yang kemudian diproses oleh agen berikutnya. Pada medium KV-*cache*, representasi internal diteruskan secara langsung sehingga proses verbalisasi penalaran antar-agen dapat dihilangkan.

Namun, efisiensi tersebut tidak secara otomatis berarti peningkatan akurasi. Pada ketiga tugas, medium KV dengan formulasi keluarga relaksasi menghasilkan kinerja yang secara umum sebanding dengan medium teks, tanpa menunjukkan keunggulan akurasi yang konsisten. Oleh karena itu, temuan penelitian lebih tepat

dirumuskan sebagai

$$\boxed{\text{akurasi sebanding} + \text{biaya komunikasi lebih rendah}}$$

daripada sebagai keunggulan akurasi komunikasi laten terhadap komunikasi teks.

Efisiensi tersebut juga bergantung pada formulasi representasi laten. Pada HumanEval-Plus, penggunaan *raw* menghasilkan akurasi (0,42) pada medium KV, jauh di bawah medium teks sebesar (0,76) dan bahkan di bawah konfigurasi agen tunggal sebesar (0,72). Dengan demikian, efisiensi tidak dapat dipandang sebagai sifat medium KV-cache saja, tetapi sebagai sifat gabungan antara medium komunikasi dan formulasi representasi laten yang mengisinya.

5.1.4. Kemampuan Mempertahankan Muatan Simbolik pada Generasi Faktor

Lengan faktor simbolik memberikan pengujian tambahan terhadap kemampuan representasi laten dalam membawa informasi yang harus dipertahankan dalam bentuk simbolik dan terstruktur. Pada lengan ini, *raw* menunjukkan tingkat kegagalan keluaran yang paling tinggi: 14 dari 18 panggilan tidak menghasilkan ekspresi yang dapat diurai, atau sebesar 78%. Sebaliknya, anggota keluarga relaksasi menghasilkan keluaran yang lebih dapat diandalkan, dengan tingkat kegagalan berada pada kisaran 29%–40% untuk metode yang mengalami kegagalan.

Perbedaan tersebut berlanjut pada jumlah ekspresi yang dapat dievaluasi. *Raw* menghasilkan 11 ekspresi dengan hanya 3 ekspresi yang dapat dievaluasi, sedangkan anggota keluarga relaksasi menghasilkan 22–33 ekspresi dengan 21–26 ekspresi yang dapat dievaluasi. Rerata ($|\text{RankIC}|$) pada ekspresi yang dapat dievaluasi berada pada kisaran (0,0162)–(0,0185) untuk medium teks dan anggota keluarga relaksasi, sedangkan *raw* menghasilkan (0,0050) berdasarkan hanya tiga ekspresi.

Hasil tersebut memberikan bukti tambahan bahwa kemampuan kanal laten dalam mempertahankan muatan simbolik sangat dipengaruhi oleh formulasi repre-

sentasi yang digunakan. Akan tetapi, karena jumlah jalan pada lengan faktor relatif kecil dan satuan pengamatannya berbeda dari lengan *benchmark*, hasil ini diperlakukan sebagai bukti pendukung dan tidak digunakan sebagai dasar pengujian statistik formal.

Nilai *backtest* pada lengan faktor tidak ditafsirkan sebagai prediksi keuntungan investasi. Penggunaannya terbatas pada pengujian apakah ekspresi simbolik yang berhasil dibawa melalui sistem dapat dieksekusi dan menghasilkan sinyal yang dapat dievaluasi secara kuantitatif.

5.1.5. Kesimpulan Umum

Secara keseluruhan, penelitian menunjukkan bahwa representasi laten dapat digunakan sebagai media komunikasi antar-agen yang jauh lebih efisien daripada komunikasi berbasis teks tanpa harus mengorbankan kinerja penalaran pada tugas yang diuji, tetapi keberhasilan tersebut tidak hanya ditentukan oleh medium komunikasinya. Formulasi pembentukan representasi laten menjadi komponen penting yang menentukan apakah informasi yang diteruskan tetap berada pada bentuk yang dapat diproses secara efektif oleh model.

Keluarga formulasi yang menghasilkan kombinasi konveks embedding token, yaitu *soft*, *sample*, *Gumbel-Softmax*, dan MoI, menunjukkan perilaku yang relatif konsisten pada ketiga *benchmark* serta lebih mampu mempertahankan informasi simbolik dibandingkan formulasi *raw* pada tugas dengan tuntutan presisi simbolik tinggi. Sebaliknya, persamaan *raw* yang digunakan dalam LatentMAS menunjukkan kelemahan terutama ketika keluaran menuntut ketepatan identitas simbol.

Dengan demikian, temuan utama penelitian bukan bahwa satu metode relaksasi tertentu merupakan formulasi terbaik, melainkan bahwa **pemilihan ruang representasi tempat langkah laten dibentuk merupakan faktor penting dalam keberhasilan latent collaboration**. Medium KV-cache menyediakan jalur komunikasi yang efisien, sedangkan formulasi langkah laten menentukan apakah informasi yang dimasukkan ke jalur tersebut tetap dapat digunakan secara efektif oleh

agen berikutnya.

5.2. Saran

Beberapa arah lanjutan dapat ditempuh berdasarkan batas yang dinyatakan pada Bab IV.

1. *Pengulangan lintas seed dan perbesaran sampel.* Setiap sel pada penelitian ini dijalankan satu kali sehingga ragam antar-*seed* tidak terukur. Pengulangan dengan beberapa *seed* akan memisahkan efek metode dari ragam pembangkitan, terutama untuk selisih kecil pada GSM8K dan ARC-Challenge yang saat ini dilaporkan sebagai tidak signifikan.
2. *Pengujian lintas backbone.* Penelitian ini mengidentifikasi keterikatan matriks embedding (*tied embeddings*) sebagai variabel yang menentukan apakah matriks *realignment* bekerja atau tidak. Variabel tersebut dapat diuji langsung dengan membandingkan model yang matriksnya terikat dan tidak terikat pada ukuran yang sebanding.
3. *Pengujian medium gabungan pada ukuran sampel memadai.* Medium gabungan KV dan teks belum diuji sebagai kondisi penuh. Selain itu, penyebab hilangnya prefiks keluaran pada lengan faktor perlu ditelusuri sampai ke akar implementasinya, karena pada penelitian ini bentuk kegagalannya dipulihkan tanpa dijelaskan.
4. *Pengujian langsung hipotesis mekanistik.* Kerangka pada Bab III memungkinkan pembentukan persamaan antara yang berada pada jarak terkendali dari lambung konveks, misalnya melalui interpolasi antara persamaan resmi dan bobot *soft*. Apabila akurasi bergerak secara monoton mengikuti jarak tersebut, hubungan antara geometri representasi dan kinerja tugas menjadi terbukti secara kausal, bukan sekadar konsisten.
5. *Perluasan topologi dan domain.* Rantai agen pada penelitian ini bersifat sekuensial dengan panjang tetap. Topologi hierarkis, jumlah agen yang berbeda,

dan lengan faktor simbolik yang dijalankan sebagai kondisi penuh — termasuk lapisan evolusi yang sengaja tidak diaktifkan di sini — merupakan perluasan yang wajar.

6. *Penilaian ekonomi yang lebih ketat pada domain faktor.* Metrik *backtest* pada penelitian ini dihitung tanpa *slippage*, tanpa batas likuiditas, dan dengan penyeimbangan ulang harian penuh. Penilaian yang memperhitungkan biaya transaksi dan kendala perdagangan diperlukan sebelum angka tersebut dapat dibaca sebagai kinerja investasi.

DAFTAR PUSTAKA

- Ainslie, J., Lee-Thorp, J., de Jong, M., Zemlyanskiy, Y., Lebrón, F., & Sanghai, S. (2023). GQA: Training generalized multi-query transformer models from multi-head checkpoints. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 4895–4901.
- Bain, L. J., & Engelhardt, M. (1992). *Introduction to Probability and Mathematical Statistics* (2nd ed.). Boston: PWS-KENT.
- Chen, X., dkk. (2025). *Reasoning beyond language: A comprehensive survey on latent chain-of-thought reasoning*. arXiv:2505.16782.
- Efron, B., & Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. New York: Chapman & Hall.
- Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- Finin, T., Fritzson, R., McKay, D., & McEntire, R. (1994). KQML as an agent communication language. *Proceedings of the 3rd International Conference on Information and Knowledge Management (CIKM)*, 456–463.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232.
- Fu, T., dkk. (2025). *Cache-to-Cache: Direct semantic communication between large language models*. arXiv:2510.03215.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. Cambridge: MIT Press.
- Grinold, R. C., & Kahn, R. N. (2000). *Active Portfolio Management: A Quantitative Approach for Producing Superior Returns and Controlling Risk* (2nd ed.). New York: McGraw-Hill.

- Guo, T., Chen, X., Wang, Y., Chang, R., Pei, S., Chawla, N. V., Wiest, O., & Zhang, X. (2024). *Large language model based multi-agents: A survey of progress and challenges*. arXiv:2402.01680.
- Han, J., Zhang, S., Li, W., Dong, Y., Hu, T., dkk. (2026). *QuantaAlpha: An Evolutionary Framework for LLM-Driven Alpha Mining*. arXiv:2602.07085.
- Hao, S., Sukhbaatar, S., Su, D., Li, X., Hu, Z., Weston, J., & Tian, Y. (2024). *Training large language models to reason in a continuous latent space*. arXiv:2412.06769.
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- Jensen, M. C. (1968). The performance of mutual funds in the period 1945–1964. *The Journal of Finance*, 23(2), 389–416.
- Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6th ed.). Upper Saddle River, NJ: Pearson Prentice Hall.
- Kakushadze, Z. (2016). 101 formulaic alphas. *Wilmott*, 2016(84), 72–81.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3149–3157.
- Kingma, D. P., & Welling, M. (2014). *Auto-encoding variational Bayes*. *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*. arXiv:1312.6114.
- Li, Y., Yang, X., Yang, X., Xu, M., Wang, X., Liu, W., & Bian, J. (2025). *R&D-Agent-Quant: A multi-agent framework for data-centric factors and model joint optimization*. arXiv:2505.15155.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.

- Zhuang, Y., Liu, S., Cheng, S., Zhang, Y., Wang, X., & Zhang, C. (2025). *Mixture of inputs: Text generation beyond discrete token sampling*. arXiv:2505.14827. Dipresentasikan pada *Advances in Neural Information Processing Systems* (NeurIPS 2025).
- Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). *Efficient estimation of word representations in vector space*. arXiv:1301.3781.
- Park, K., Choe, Y. J., & Veitch, V. (2024). *The linear representation hypothesis and the geometry of large language models*. Proceedings of the 41st International Conference on Machine Learning (ICML). arXiv:2311.03658.
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Hoboken, NJ: Pearson.
- Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442.
- Sharpe, W. F. (1994). The Sharpe ratio. *The Journal of Portfolio Management*, 21(1), 49–58.
- Spearman, C. (1904a). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1), 72–101.
- Spearman, C. (1904b). “General intelligence,” objectively determined and measured. *The American Journal of Psychology*, 15(2), 201–292.
- Su, J., Ahmed, M., Lu, Y., Pan, S., Bo, W., & Liu, Y. (2024). RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568, 127063.
- Tandelilin, E. (2010). *Portofolio dan Investasi: Teori dan Aplikasi* (Edisi Pertama). Yogyakarta: Kanisius.
- Tang, Z., Chen, Z., Yang, J., Mai, J., Zheng, Y., Wang, K., Chen, J., & Lin, L. (2025). *AlphaAgent: LLM-driven alpha mining with regularized exploration to counteract alpha decay*. arXiv:2502.16789.

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). *Attention is all you need*. *Advances in Neural Information Processing Systems*, 30.
- Wooldridge, M., & Jennings, N. R. (1995). Intelligent agents: Theory and practice. *The Knowledge Engineering Review*, 10(2), 115–152.
- Wooldridge, M. (2009). *An Introduction to MultiAgent Systems* (2nd ed.). Chichester: Wiley.
- Yang, X., Liu, W., Zhou, D., Bian, J., & Liu, T.-Y. (2020). *Qlib: An AI-oriented quantitative investment platform*. arXiv:2009.11189.
- Yang, A., dkk. (Qwen Team). (2025). *Qwen3 technical report*. arXiv:2505.09388.
- Yu, S., Xue, H., Ao, X., Pan, F., He, J., Tu, D., & He, Q. (2023). Generating synergistic formulaic alpha collections via reinforcement learning. *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (KDD '23).
- Zhang, Z., He, X., Yan, W., Shen, A., Zhao, C., Wang, S., Shen, Y., & Wang, X. E. (2025). *Soft thinking: Unlocking the reasoning potential of LLMs in continuous concept space*. arXiv:2505.15778.
- Zou, J., Qiu, R., Li, G., Yang, X., Tieu, K., Lu, P., Shen, K., Tong, H., Choi, Y., He, J., Zou, J., Wang, M., & Yang, L. (2025). *Latent collaboration in multi-agent systems*. arXiv:2511.20639.

LAMPIRAN A

Tabel Lengkap Sel Lengan *Benchmark*

Seluruh 21 sel utama lengan *benchmark*. Kolom *format* adalah proporsi keluaran berbentuk sah; kolom CJK adalah cacah jawaban yang memuat aksara Tionghoa pada tugas berbahasa Inggris.

Tugas	Sel	n	Akurasi	SK 95%	Format	Token/soal	CJK
GSM8K	gumbel/kv	100	0,91	[0,85; 0,96]	1,00	197	0
GSM8K	moi/kv	100	0,92	[0,86; 0,97]	1,00	190	1
GSM8K	raw/baseline	100	0,92	[0,86; 0,97]	1,00	—	—
GSM8K	raw/kv	100	0,83	[0,75; 0,90]	0,98	212	2
GSM8K	raw/text	100	0,90	[0,84; 0,95]	1,00	845	0
GSM8K	sample/kv	100	0,86	[0,79; 0,92]	0,97	187	0
GSM8K	soft/kv	100	0,88	[0,81; 0,94]	1,00	192	0
ARC-C	gumbel/kv	100	0,91	[0,85; 0,96]	0,98	154	1
ARC-C	moi/kv	100	0,91	[0,85; 0,96]	0,98	145	0
ARC-C	raw/baseline	100	0,91	[0,85; 0,96]	1,00	271	0
ARC-C	raw/kv	100	0,89	[0,83; 0,95]	1,00	219	3
ARC-C	raw/text	100	0,93	[0,88; 0,98]	1,00	1081	0
ARC-C	sample/kv	100	0,94	[0,89; 0,98]	1,00	146	0
ARC-C	soft/kv	100	0,94	[0,89; 0,98]	1,00	154	1
HumanEval+	gumbel/kv	100	0,71	[0,62; 0,80]	0,97	131	0
HumanEval+	moi/kv	100	0,72	[0,63; 0,81]	1,00	122	0
HumanEval+	raw/baseline	100	0,72	[0,63; 0,80]	1,00	122	0
HumanEval+	raw/kv	100	0,42	[0,32; 0,52]	1,00	177	1
HumanEval+	raw/text	100	0,76	[0,68; 0,84]	1,00	997	0
HumanEval+	sample/kv	100	0,74	[0,65; 0,82]	1,00	126	0

Tugas	Sel	n	Akurasi	SK 95%	Format	Token/soal	CJK
HumanEval+	soft/kv	100	0,69	[0,60; 0,78]	0,96	122	0

LAMPIRAN B

Hasil Lengkap Uji Berpasangan

Seluruh 63 uji McNemar eksak beserta nilai p terkoreksi Holm dan Benjamini–Hochberg. Baris diurutkan menaik menurut p dalam tiap tugas. Kolom n_a dan n_b adalah cacah soal diskordan, yaitu soal yang hanya dijawab benar oleh salah satu perlakuan.

Tugas	Pasangan	Δ	SK 95%	n_a	n_b	p	p
GSM8K	moi/kv-raw/kv	+0,090	[+0,01; +0,17]	13	4	0,0490	1,0000
GSM8K	raw/baseline-raw/kv	+0,090	[+0,01; +0,17]	13	4	0,0490	1,0000
GSM8K	gumbel/kv-raw/kv	+0,080	[+0,01; +0,16]	12	4	0,0768	1,0000
GSM8K	moi/kv-sample/kv	+0,060	[-0,01; +0,13]	9	3	0,1460	1,0000
GSM8K	raw/kv-raw/text	-0,070	[-0,16; +0,02]	7	14	0,1892	1,0000
GSM8K	raw/baseline-sample/kv	+0,060	[-0,02; +0,14]	11	5	0,2101	1,0000
GSM8K	moi/kv-soft/kv	+0,040	[-0,01; +0,10]	6	2	0,2891	1,0000
GSM8K	gumbel/kv-sample/kv	+0,050	[-0,03; +0,13]	11	6	0,3323	1,0000
GSM8K	raw/baseline-soft/kv	+0,040	[-0,02; +0,10]	7	3	0,3438	1,0000
GSM8K	raw/kv-soft/kv	-0,050	[-0,14; +0,04]	8	13	0,3833	1,0000
GSM8K	raw/text-sample/kv	+0,040	[-0,04; +0,12]	11	7	0,4807	1,0000
GSM8K	gumbel/kv-soft/kv	+0,030	[-0,04; +0,10]	7	4	0,5488	1,0000
GSM8K	raw/kv-sample/kv	-0,030	[-0,12; +0,05]	8	11	0,6476	1,0000
GSM8K	moi/kv-raw/text	+0,020	[-0,04; +0,08]	6	4	0,7539	1,0000
GSM8K	raw/baseline-raw/text	+0,020	[-0,04; +0,08]	6	4	0,7539	1,0000
GSM8K	raw/text-soft/kv	+0,020	[-0,04; +0,08]	6	4	0,7539	1,0000
GSM8K	sample/kv-soft/kv	-0,020	[-0,10; +0,06]	8	10	0,8145	1,0000
GSM8K	gumbel/kv-moi/kv	-0,010	[-0,06; +0,04]	3	4	1,0000	1,0000
GSM8K	gumbel/kv-raw/baseline	-0,010	[-0,07; +0,05]	4	5	1,0000	1,0000
GSM8K	gumbel/kv-raw/text	+0,010	[-0,05; +0,08]	6	5	1,0000	1,0000

Tugas	Pasangan	Δ	SK 95%	n_a	n_b	p	p
GSM8K	moi/kv-raw/baseline	+0,000	[-0,05; +0,05]	4	4	1,0000	1,0000
ARC-C	raw/kv-sample/kv	-0,050	[-0,10; -0,01]	0	5	0,0625	1,0000
ARC-C	raw/kv-soft/kv	-0,050	[-0,10; +0,00]	1	6	0,1250	1,0000
ARC-C	raw/kv-raw/text	-0,040	[-0,09; +0,00]	1	5	0,2188	1,0000
ARC-C	gumbel/kv-sample/kv	-0,030	[-0,08; +0,01]	1	4	0,3750	1,0000
ARC-C	gumbel/kv-soft/kv	-0,030	[-0,08; +0,01]	1	4	0,3750	1,0000
ARC-C	moi/kv-sample/kv	-0,030	[-0,07; +0,01]	1	4	0,3750	1,0000
ARC-C	moi/kv-soft/kv	-0,030	[-0,08; +0,01]	1	4	0,3750	1,0000
ARC-C	raw/baseline-sample/kv	-0,030	[-0,07; +0,01]	1	4	0,3750	1,0000
ARC-C	raw/baseline-soft/kv	-0,030	[-0,08; +0,01]	1	4	0,3750	1,0000
ARC-C	raw/baseline-raw/text	-0,020	[-0,06; +0,02]	1	3	0,6250	1,0000
ARC-C	moi/kv-raw/kv	+0,020	[-0,03; +0,07]	4	2	0,6875	1,0000
ARC-C	moi/kv-raw/text	-0,020	[-0,07; +0,03]	2	4	0,6875	1,0000
ARC-C	raw/baseline-raw/kv	+0,020	[-0,03; +0,07]	4	2	0,6875	1,0000
ARC-C	gumbel/kv-raw/kv	+0,020	[-0,03; +0,07]	5	3	0,7266	1,0000
ARC-C	gumbel/kv-raw/text	-0,020	[-0,08; +0,03]	3	5	0,7266	1,0000
ARC-C	gumbel/kv-moi/kv	+0,000	[-0,06; +0,05]	4	4	1,0000	1,0000
ARC-C	gumbel/kv-raw/baseline	+0,000	[-0,06; +0,06]	4	4	1,0000	1,0000
ARC-C	moi/kv-raw/baseline	+0,000	[-0,05; +0,05]	3	3	1,0000	1,0000
ARC-C	raw/text-sample/kv	-0,010	[-0,05; +0,02]	1	2	1,0000	1,0000
ARC-C	raw/text-soft/kv	-0,010	[-0,05; +0,02]	1	2	1,0000	1,0000
ARC-C	sample/kv-soft/kv	+0,000	[-0,03; +0,03]	1	1	1,0000	1,0000
HumanEval+	raw/kv-sample/kv	-0,320	[-0,42; -0,22]	2	34	0,0000	0,0000
HumanEval+	moi/kv-raw/kv	+0,300	[+0,20; +0,40]	32	2	0,0000	0,0000
HumanEval+	raw/baseline-raw/kv	+0,300	[+0,20; +0,40]	33	3	0,0000	0,0000
HumanEval+	raw/kv-raw/text	-0,340	[-0,45; -0,22]	6	40	0,0000	0,0000
HumanEval+	gumbel/kv-raw/kv	+0,290	[+0,19; +0,40]	33	4	0,0000	0,0000
HumanEval+	raw/kv-soft/kv	-0,270	[-0,37; -0,17]	4	31	0,0000	0,0000
HumanEval+	raw/text-soft/kv	+0,070	[-0,03; +0,17]	16	9	0,2295	1,0000

Tugas	Pasangan	Δ	SK 95%	n_a	n_b	p	p
HumanEval+	sample/kv-soft/kv	+0,050	[-0,03; +0,13]	11	6	0,3323	1,0000
HumanEval+	gumbel/kv-raw/text	-0,050	[-0,14; +0,04]	8	13	0,3833	1,0000
HumanEval+	moi/kv-soft/kv	+0,030	[-0,03; +0,09]	6	3	0,5078	1,0000
HumanEval+	moi/kv-raw/text	-0,040	[-0,13; +0,05]	9	13	0,5235	1,0000
HumanEval+	raw/baseline-raw/text	-0,040	[-0,13; +0,05]	9	13	0,5235	1,0000
HumanEval+	raw/baseline-soft/kv	+0,030	[-0,03; +0,09]	7	4	0,5488	1,0000
HumanEval+	gumbel/kv-sample/kv	-0,030	[-0,10; +0,04]	5	8	0,5811	1,0000
HumanEval+	moi/kv-sample/kv	-0,020	[-0,09; +0,05]	5	7	0,7744	1,0000
HumanEval+	gumbel/kv-soft/kv	+0,020	[-0,05; +0,09]	8	6	0,7905	1,0000
HumanEval+	raw/baseline-sample/kv	-0,020	[-0,10; +0,06]	7	9	0,8036	1,0000
HumanEval+	raw/text-sample/kv	+0,020	[-0,07; +0,11]	12	10	0,8318	1,0000
HumanEval+	gumbel/kv-moi/kv	-0,010	[-0,07; +0,05]	4	5	1,0000	1,0000
HumanEval+	gumbel/kv-raw/baseline	-0,010	[-0,08; +0,05]	5	6	1,0000	1,0000
HumanEval+	moi/kv-raw/baseline	+0,000	[-0,06; +0,06]	5	5	1,0000	1,0000

LAMPIRAN C

Transkrip Rantai Agen

Keluaran verbatim keempat agen untuk satu soal GSM8K yang sama, dibandingkan antara persamaan langkah laten resmi (raw) dan salah satu anggota keluarga relaksasi diskret (gumbel), pada medium gabungan KV dan teks. Teks tidak disunting; pemenggalan baris ditambahkan agar muat di halaman.

Persamaan langkah laten raw

Agen planner

```
- **Understand the problem**: Identify that Mandy owes $100 with a monthly
  interest rate of 2%, and she pays after 3 months.
- **Calculate the total interest**: Use the formula for simple interest: Interest
  = Principal [U+00D7] Rate [U+00D7] Time.
- **Add the interest to the principal**: Calculate the total amount owed by adding
  the interest to the original $100.
- **Determine the final payment**: Present the total amount Mandy should pay
  Benedict after 3 months.
```

Agen critic

```
Original Plan:
- **Understand the problem**: Identify that Mandy owes $100 with a monthly
  interest rate of 2%, and she pays after 3 months.
- **Calculate the total interest**: Use the formula for simple interest: Interest
  = Principal [U+00D7] Rate [U+00D7] Time.
- **Add the interest to the principal**: Calculate the total amount owed by adding
  the interest to the original $100.
- **Determine the final payment**: Present the total amount Mandy should pay
  Benedict after 3 months.

Feedback:
The original plan is clear and logically structured, but it can be slightly
refined for better precision. Specifically, the step "Use the formula for
simple interest" should include the exact formula (Interest = Principal [U+00
D7] Rate [U+00D7] Time) to ensure clarity. Additionally, the step "Add the
```


interest to the principal" could be more explicitly worded as "Calculate the total amount by adding the calculated interest to the principal amount." These small adjustments will make the plan even more precise and easier to follow.

Agen refiner

Refined Plan:

- ****Understand the problem****: Identify that Mandy owes \$100 with a monthly interest rate of 2%, and she pays after 3 months.
- ****Calculate the total interest****: Use the simple interest formula: $\text{Interest} = \text{Principal} \times \text{Rate} \times \text{Time}$, where Principal = \$100, Rate = 2% (or 0.02), and Time = 3 months.
- ****Compute the total amount owed****: Add the calculated interest to the original principal amount of \$100.
- ****Determine the final payment****: Present the total amount Mandy should pay Benedict after 3 months, including both the principal and the accumulated interest.

Agen judger

To solve the problem, we need to calculate the total amount Mandy should pay Benedict after 3 monthss, including both the principal and the accumulated interest.

Step-by-step Reasoning:

1. ****Identify the principal amount****:
 - The principal amount is \$100.
2. ****Determine the monthly interest rate****:
 - The monthly interest.rate is 2%, which can be expressed as a decimal: 0.02.
3. ****Calculate the total interest over 3 monthss****:
 - Use the simple interest formula:

$$\text{Interest} = \text{Principal} \times \text{Rate} \times \text{Time}$$

$$\text{Interest} = 100 \times 0.02 \times 3 = 6$$
4. ****Add the interest to the principal to get the total amount owed****:
 - Total amount = Principal + Interest

```

\text{Total Amount} = 100 + 6 = 106
$$

### Final Answer:
$$
\boxed{106}
$$

```

Persamaan langkah laten gumbel

Agen planner

- Calculate the monthly interest for the first month by multiplying the principal amount (\$100) by the monthly interest rate (2%).
- Add the first month's interest to the principal to get the new balance after the first month.
- Calculate the monthly interest for the second month using the updated balance.
- Add the second month's interest to the balance to get the new balance after the second month.
- Calculate the monthly interest for the third month using the updated balance after two months.
- Add the third month's interest to the balance to determine the total amount Mandy should pay Benedict after three months.

Agen critic

Feedback:

The original plan is incomplete and lacks clarity in the steps. It should explicitly mention that the interest is compounded monthly, which means each month's interest is calculated based on the current balance (including previously accrued interest). The plan should also include a clear instruction to calculate the total amount after three months by summing up the principal and all the compounded interest. Additionally, it would be helpful to specify that the final amount includes both the original debt and the accumulated interest over the three months.

Agen refiner

- Start with the principal amount of \$100.
- Calculate the monthly interest for each of the three months using the formula:
Interest = Principal [U+00D7] Monthly Interest Rate (2%).
- Add the first month's interest to the principal to get the new balance after the first month.

- Use the updated balance as the new principal for the second month and calculate the interest again.
- Add the second month's interest to the balance to get the new balance after the second month.
- Use the updated balance as the new principal for the third month and calculate the interest again.
- Add the third month's interest to the balance to determine the total amount Mandy should pay Benedict after three months.

Agen judger

To solve the problem, we need to calculate the total amount Mandy should pay Benedict after 3 months, including monthly compound interest.

Step-by-Step Calculation:

1. **Initial Principal**: \$100
2. **Monthly Interest Rate**: 2% = 0.02
3. **Time Period**: 3 months

We use the formula for compound interest:

\$\$

$$A = P(1 + r)^t$$

\$\$

Where:

- \$ A \$ is the final amount
- \$ P \$ is the principal (\$100)
- \$ r \$ is the monthly interest rate (0.02)
- \$ t \$ is the time in months (3)

\$\$

$$A = 100(1 + 0.02)^3 = 100(1.02)^3$$

\$\$

Calculate \$ (1.02)^3 \$:

\$\$

$$(1.02)^3 = 1.061208$$

\$\$

Now multiply by the principal:

\$\$

$$A = 100 \times 1.061208 = 106.1208$$

\$\$

Rounded to two decimal places:

\$\$

\boxed{106.12}

\$\$

Contoh Korupsi Token yang Terekam

Cuplikan jawaban yang memuat aksara di luar ASCII pada tugas berbahasa Inggris. Aksara tersebut ditampilkan sebagai titik kode Unicode.

Sel	Cuplikan
arc_challenge_gumbel_kv_s0	of ice, which scrapes and[U+78E8][U+5E73] (
arc_challenge_raw_kv_s0	the effects of a hypoxic[U+4E8B][U+4EF6].
arc_challenge_soft_kv_s0	[U+73CA][U+745A][U+7901][U+662F]
gsm8k_moi_kv_s0	1. ** [U+786E][U+5B9A][U+6BCF][U+79CD]
gsm8k_raw_kv_s0	To solve the problem of[U+30B3] O
humanevalplus_raw_kv_s0	'No' #Count.digits.in[U+6574][U+4E2A]fi

LAMPIRAN D

Kartu Faktor

Tiga lintasan nyata dari lengan faktor simbolik, disajikan dengan format yang meniru kartu faktor pada lampiran QuantaAlpha. Kartu ketiga sengaja menampilkan sel yang gagal, karena bentuk kegagalannya merupakan bagian dari temuan dan bukan data yang hilang. Angka *backtest* berasal dari simulasi kasar dan tidak boleh dibaca sebagai ramalan keuntungan.

Medium teks · langkah laten raw

Hipotesis Mean reversion in low-volatility stocks occurs after abrupt volatility increases and volume surges, predicting positive returns in the short to medium term.

Nama faktor OddNormalizationFactor

Ekspresi

```
RANK(TS_ARGMAX($return, 20)) / TS_MAD($volume, 30)
```

Maksud This factor utilizes ODD NORMALISATION by ranking the most recent return peaks over 20 days and normalizing it by the median absolute deviation of volume over 30 days. It aims to highlight stocks with extreme returns amidst volatile volume.

Lolos gate ya

RankIC +0,0383 ICIR +0,422 *t* +6,59

Hari perdagangan 243

Backtest ARR +0,298 Sharpe +2,30 MDD -0,087 *turnover* +0,430

Medium kv · langkah laten gumbel

Hipotesis When small-cap stocks experience abnormally high-volume days, short-term reversals follow in next-period cross-sectional returns.

Nama faktor Volume Dispersion Signal

Ekspresi

```
TS_QUANTILE($volume, 20, 0.9) - TS_QUANTILE($volume,
20, 0.1)
```

Maksud Calculates the spread between upper and lower volume quantiles over a 20-day window to identify extreme volume regimes linked to reversals.

Lolos gate ya

RankIC -0,0394 ICIR -0,372 t -5,80

Hari perdagangan 243

Backtest ARR -0,361 Sharpe -2,45 MDD -0,373 turnover +0,111

Medium kv · langkah laten raw

Hipotesis short-term reversal after abnormally high-volume days in small-cap stocks

Nama faktor Asymmetric Volume Impact

Ekspresi

```
TS_PCTCHANGE($volume, 20) *SIGN($return) /
TS_MAD($return, 60)
```

Maksud weights price changes by volume magnitude and asymmetry, focusing on reversal dynamics

Lolos gate	ya				
RankIC	-0,0080	ICIR -0,176	t -2,74		
Hari perdagangan	243				
Backtest	ARR -0,056	Sharpe -0,74	MDD -0,068	turno-	
	ver +1,457				

LAMPIRAN E

Implementasi Empat Persamaan Langkah Laten

Fungsi berikut adalah satu-satunya tempat kelima persamaan langkah laten diwujudkan dalam kode; seluruh sel eksperimen memanggilnya lewat jalur yang sama. Komentar penjelas yang panjang dipendekkan karena isinya sudah diuraikan pada Bab III. Berkas asli: `backend/llm/methods.py`.

```
def latent_step_vec(
    last_hidden: "torch.Tensor",
    *,
    mode: str,
    model: Any,
    realigner: LatentRealigner,
    temp: float,
    beta: float,
) -> "torch.Tensor":
    if mode == "raw":
        return realigner.apply(last_hidden, model)

    W_in = model.get_input_embeddings().weight  # [V, d]
    target_norm = realigner._ensure_matrix(model)[1].to(last_hidden.device)
    T = max(temp, 1e-6)

    out_emb = model.get_output_embeddings()
    logits = (out_emb(last_hidden) if out_emb is not None
               else last_hidden @ W_in.T).float()  # [B, V]

    if mode == "sample":
        idx = torch.multinomial(torch.softmax(logits / T, dim=-1), 1)  # [B, 1]
        z = W_in[idx.squeeze(-1)].float()

    elif mode == "moi":
        # [penjelasan lengkap: Bab III]
        probs = torch.softmax(logits / T, dim=-1)  # [B, V]
        idx = torch.multinomial(probs, 1)  # [B, 1]
        onehot = torch.zeros_like(probs).scatter_(-1, idx, 1.0)
        H = (-(probs * probs.clamp_min(1e-12).log()).sum(-1, keepdim=True)
              / torch.log(torch.tensor(float(probs.shape[-1]),
                                         device=probs.device)))  # [B, 1]
        w = (H * probs + (beta + 1.0 - H) * onehot) / (beta + 1.0)
```



```

        z = (w.to(W_in.dtype) @ W_in).float() # [B, d]
    else:
        if mode == "gumbel":
            u = torch.rand_like(logits).clamp_(1e-9, 1.0 - 1e-9)
            logits = logits + (-torch.log(-torch.log(u)))
            probs = torch.softmax(logits / T, dim=-1)
            z = (probs.to(W_in.dtype) @ W_in).float() # [B, d]

    z = z * (target_norm / z.norm(dim=-1, keepdim=True).clamp_min(1e-6))
    return z.to(last_hidden.dtype)

```

LAMPIRAN F

Hiperparameter dan Lingkungan Eksekusi

Parameter	Nilai
Model	Qwen/Qwen3-8B
Ukuran kosakata V	151.936
Dimensi <i>hidden</i> d	4096
Embedding terikat	tidak
Langkah laten m	10
Suhu langkah laten T	0,70
Regularisasi ridge λ	10^{-5}
Parameter MoI β	1
Suhu pembangkitan	0,60
<i>top-p</i>	0,95
Token baru maksimum	2048
Rantai agen	planner, critic, refiner, judger
Subsampil per sel	100
<i>Seed</i> pengambilan sampel	0
<i>Seed</i> pembangkitan	0
GPU	NVIDIA A40 46 GB, CUDA 12.8
Kerangka kerja	PyTorch 2.6.0+cu124, HuggingFace Transformers