


LAPORAN TUGAS AKHIR I

**EVALUASI FORMULASI LANGKAH LATEN PADA
KOMUNIKASI SISTEM MULTI-AGEN: DISOSIASI ANTARA
VALIDITAS KELUARAN DAN MUTU SINYAL PADA
PENALARAN UMUM DAN PEMBANGKITAN FAKTOR
SIMBOLIK**



Harun Yahya
22/505239/PA/21749

PEMBIMBING :

**PROGRAM SARJANA PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

DAFTAR ISI

DAFTAR ISI	2
BAB I PENDAHULUAN	2
1.1. Latar Belakang	2
1.2. Rumusan Masalah	3
1.3. Tujuan Penelitian	4
1.4. Manfaat Penelitian	4
1.5. Batasan Penelitian	4
BAB II TINJAUAN PUSTAKA DAN LANDASAN TEORI.....	6
2.1. Transformer dan Dua Ruang Representasi	6
2.2. Penalaran Laten dan Langkah Laten	7
2.3. Formulasi Resmi LatentMAS: Regresi Ridge	7
2.3.1. Peran λ	8
2.3.2. Mengapa M bukan identitas.....	8
2.4. Keluarga Relaksasi Diskret.....	8
2.4.1. <code>soft</code> : rerata posterior embedding	9
2.4.2. <code>sample</code> : batas diskret.....	9
2.4.3. <code>gumbel</code> : relaksasi kontinu stokastik	9
2.4.4. <code>moi</code> : rerata posterior Dirichlet	10
2.5. Bahasa Ekspresi Faktor: DSL dan AST	11
2.6. Faktor Alpha dan Koefisien Informasi.....	12
2.7. Uji Statistik yang Dipakai.....	13
2.7.1. Uji eksak Fisher	13
2.7.2. Uji Mann–Whitney.....	13
2.7.3. Uji McNemar dan daya uji	13
BAB III METODOLOGI PENELITIAN	15
3.1. Rancangan Umum.....	15
3.2. Rantai Agen	16
3.3. Parameter dan Asalnya	16
3.4. Sumbu Interpolasi <code>mix</code>	17
3.5. Kendali Mutu Ekspresi (<i>Gate</i>)	17
3.6. Data Pasar dan Universe Penilaian	18
3.6.1. Universe	18
3.6.2. Periode dan pembagian	19
3.6.3. Definisi label.....	19
3.6.4. Metrik portofolio	20
3.6.5. Ambang deteksi	20
3.7. Hipotesis Penelitian.....	21

BAB IV HASIL DAN PEMBAHASAN	22
4.1. Tingkat 1–2: Keandalan Keluaran	22
4.1.1. Uji formal	23
4.2. Tingkat 3: Ekspresi yang Hidup di Pasar Indonesia.....	24
4.3. Tingkat 4: Signifikansi Statistik	24
4.4. Tingkat 5: Mutu Sinyal — Temuan Utama.....	25
4.4.1. Tafsir: apa yang sebenarnya diperbaiki proyeksi <i>convex hull</i>	26
4.4.2. Mengapa ini bukan sekadar hasil nol	27
4.5. Tingkat 6: Ketahanan di Luar Jendela Seleksi	28
4.6. Efisiensi Kanal Laten	29
4.7. Lengan Penalaran Umum	29
4.7.1. Bukti bahwa yang rusak adalah kanalnya, bukan modelnya	31
4.7.2. Sintesis kedua lengan.....	31
4.8. Bentuk Hubungan Geometri–Kinerja	32
4.9. Metrik Portofolio.....	33
4.10. Lantai Acak: Apakah Sistemnya Mengalahkan Penarikan Acak?	34
4.10.1. Pada validitas, sistemnya menang telak	34
4.10.2. <i>raw</i> tidak mengalahkan penarikan acak	35
4.10.3. Pada mutu sinyal, tidak ada yang mengalahkan penarikan acak ..	35
4.11. Keragaman Sinyal: Berapa Banyak Faktor yang Benar-Benar Berbeda .	36
4.11.1. Apakah keluarga $\mathcal{R}$ juga lebih beragam?.....	36
4.12. Peluruhan Sinyal Antar-Tahun	37
4.13. Keberpindahan Keputusan <i>Gate</i> Antar-Pasar	37
4.14. Rangkuman Pengujian Hipotesis	38
BAB V KESIMPULAN DAN SARAN	40
5.1. Kesimpulan	40
5.1.1. Jawaban atas rumusan masalah.....	40
5.1.2. Kontribusi utama	41
5.1.3. Implikasi praktis.....	42
5.2. Keterbatasan.....	42
5.3. Saran.....	43
DAFTAR PUSTAKA	45
BAB A MATRIKS SEL EKSPERIMEN	49
BAB B PARAMETER DAN ASALNYA	50
BAB C INDEKS FIGUR DAN KETERLACAKAN ANGKA.....	51
C.1. Rantai keterlacakan.....	51
C.2. Figur yang dipakai bab hasil	51
C.3. Figur yang sengaja tidak dipakai.....	51
BAB D CARA REPRODUKSI.....	53

BAB I

PENDAHULUAN

1.1. Latar Belakang

Model bahasa besar (*large language model*, LLM) semakin sering dijalankan bukan sebagai model tunggal, melainkan sebagai sistem *multi-agent*: beberapa salinan model diberi peran berbeda dan bekerja berurutan, saling meneruskan hasil pekerjaan sampai jawaban akhir terbentuk [Russell dan Norvig, 2021]. Pembagian peran semacam itu memperbaiki mutu jawaban pada tugas yang menuntut perencanaan dan perbaikan bertahap.

Pada hampir seluruh sistem tersebut, medium penghubung antar-agen adalah teks. Setiap agen mengubah penalaran internalnya menjadi untaian token, lalu agen berikutnya menguraikan untaian itu kembali menjadi representasi internalnya sendiri. Proses bolak-balik ini menimbulkan dua persoalan. Pertama, biaya komputasi meningkat karena setiap penyerahan pekerjaan mengharuskan pembangkitan token yang panjang. Kedua, terjadi penyempitan kanal: representasi internal yang kaya dimampatkan menjadi barisan simbol diskret, dan hanya sebagian yang dapat dipulihkan agen penerima [Zou dkk, 2025, Fu dkk, 2025].

Sebagai jawaban, Zou dkk [2025] mengusulkan LatentMAS, kerangka kolaborasi *multi-agent* yang berlangsung sepenuhnya di ruang laten. Alih-alih bertukar teks, tiap agen menjalankan sejumlah langkah penalaran di ruang representasi kontinu, lalu menyerahkan memori kerjanya berupa *key-value cache* dari mekanisme *attention* [Vaswani dkk, 2017] kepada agen berikutnya. Pendekatan ini bagian dari paradigma penalaran laten yang lebih luas [Hao dkk, 2024, Chen dkk, 2025].

Inti teknis LatentMAS adalah satu persamaan. Sebuah *hidden state* h yang dihasilkan lapisan terakhir transformer hidup di ruang keluaran, yaitu ruang yang dibaca kepala bahasa untuk menghasilkan *logit*; sedangkan masukan yang diharapkan lapisan pertama adalah *embedding* token, yang hidup di ruang masukan.

Kedua ruang berdimensi sama tetapi tidak sama. LatentMAS menjembatannya dengan sebuah matriks M hasil regresi ridge [Hoerl dan Kennard, 1970] yang dipasang sekali di awal, lalu memakai hM sebagai masukan langkah berikutnya.

Penelitian pendahuluan pada penelitian ini menemukan bahwa persamaan tersebut gagal total ketika muatan yang harus dibawa kanal laten bersifat *simbolik* — nama fungsi, pengenalan, ekspresi — dengan *recall* 0,000 mutlak, sementara empat formulasi alternatif yang memproyeksikan langkah laten kembali ke *convex hull* embedding token nyata seluruhnya mendarat pada 0,34–0,38. Temuan itu menimbulkan pertanyaan yang menjadi pokok skripsi ini: apakah keunggulan keluarga formulasi alternatif tersebut bersifat umum, ataukah spesifik untuk muatan simbolik?

Untuk menjawabnya, dua kategori tugas dievaluasi berdampingan dengan perlakuan setara: *penalaran umum* (tiga tolok ukur baku) dan *pembangkitan faktor simbolik* (ekspresi *alpha* atas data pasar saham). Kategori kedua memakai data Bursa Efek Indonesia, indeks LQ45, periode 2021–2025.

1.2. Rumusan Masalah

1. Bagaimana kelima formulasi langkah laten diturunkan dari satu bentuk umum, dan sifat geometris apa yang membedakan formulasi resmi LatentMAS dari keluarga relaksasi diskret?
2. Apakah keluarga relaksasi diskret menghasilkan keluaran yang lebih *valid* dibanding formulasi resmi LatentMAS, dan seberapa besar efeknya?
3. Apakah keunggulan itu juga terjadi pada *mutu sinyal* keluaran, yaitu daya prediksi faktor yang dihasilkan terhadap imbal hasil saham?
4. Berapa besar penghematan biaya komputasi kanal laten murni dibanding kanal teks penuh, dan apakah penghematan itu menurunkan mutu keluaran?
5. Bagaimana bentuk hubungan antara kedekatan geometris representasi laten terhadap ruang embedding dan kinerja hilirnya — monoton, berambang, atau tidak berpola?

1.3. Tujuan Penelitian

1. Menurunkan kelima formulasi langkah laten dari satu bentuk umum dan menetapkan kriteria geometris yang memisahkan keduanya.
2. Menguji secara formal perbedaan validitas keluaran antara keluarga relaksasi diskret dan formulasi resmi LatentMAS pada dua medium komunikasi.
3. Menguji apakah perbedaan validitas itu diikuti perbedaan mutu sinyal, diukur dengan *rank information coefficient* pada data LQ45.
4. Mengukur biaya komputasi tiap medium dengan denominator yang seragam.
5. Memetakan bentuk hubungan geometri–kinerja melalui sumbu interpolasi kontinu antara dua formulasi ujung.

1.4. Manfaat Penelitian

Secara teoretis, penelitian ini memberi kriteria geometris yang dapat diuji untuk menilai formulasi langkah laten mana pun, serta bukti empiris bahwa kriteria itu memisahkan kinerja secara tajam. Secara praktis, penelitian ini menunjukkan bahwa komunikasi antar-agen lewat *key-value cache* dapat memangkas biaya token secara besar tanpa menurunkan keandalan keluaran, asalkan formulasi langkah latennya dipilih dengan benar.

1.5. Batasan Penelitian

1. Model tunggal, Qwen3–8B [Yang dkk, 2025], tanpa pelatihan ulang. Seluruh formulasi bersifat *training-free*.
2. Rantai agen bersifat *single-pass*: proposal → innovate → construct, tanpa loop evolusi.
3. Universe pasar dibatasi pada 37 konstituen LQ45 yang memiliki data lengkap; implikasinya dibahas pada Subbab 3.7 dan 5.3.

4. Metrik portofolio bersifat deskriptif; kesimpulan antar-formulasi disandarkan pada koefisien informasi yang memiliki uji hipotesis.
5. Penelitian ini tidak mengklaim menemukan strategi perdagangan yang menguntungkan.

BAB II

TINJAUAN PUSTAKA DAN LANDASAN TEORI

2.1. Transformer dan Dua Ruang Representasi

Sebuah transformer *decoder-only* [Vaswani dkk, 2017] memetakan barisan token menjadi barisan *hidden state*. Pada posisi terakhir, keluaran lapisan terakhir dinotasikan $\mathbf{h} \in \mathbb{R}^d$. Untuk Qwen3-8B, $d = 4096$ dan ukuran kosakata $V = 151\,936$.

Model memiliki dua matriks embedding yang berbeda:

$$\mathbf{W}_{\text{in}} \in \mathbb{R}^{V \times d}, \quad \mathbf{W}_{\text{out}} \in \mathbb{R}^{V \times d}.$$

Baris ke- i dari $\mathbf{W}_{\text{in}}$ adalah representasi token i sebagai *masukan*; baris ke- i dari $\mathbf{W}_{\text{out}}$ adalah arah pada ruang keluaran yang memilih token i . *Logit* untuk token berikutnya adalah

$$\ell = \mathbf{W}_{\text{out}} \mathbf{h}, \quad \ell_i = \langle \mathbf{W}_{\text{out}}[i], \mathbf{h} \rangle. \quad (2.1)$$

Pada model dengan *tied embeddings* kedua matriks itu identik. Model yang dipakai penelitian ini *tidak* demikian: pengukuran langsung pada Qwen3-8B memberi rerata kosinus antar-baris bersesuaian $\overline{\cos}(\mathbf{W}_{\text{in}}[i], \mathbf{W}_{\text{out}}[i]) = 0,0041$, yaitu praktis ortogonal. Karena itu $\mathbf{h}$ tidak berada pada sistem koordinat yang diharapkan lapisan pertama, dan mengumpulkannya kembali secara langsung merupakan kekeliruan tipe yang kebetulan tidak menimbulkan galat runtime.

Teorema 2.1.1 (Interpretasi *hidden state*) $\mathbf{h}$ bukan distribusi peluang, bukan token, dan bukan embedding. Ia adalah vektor bilangan real tak terkendala berdimensi d yang, melalui Persamaan (2.1), menentukan seluruh distribusi token berikutnya.

2.2. Penalaran Laten dan Langkah Laten

Pada penalaran normal, h diubah menjadi indeks token, lalu indeks itu dicari kembali pada W_{in} untuk menjadi masukan langkah berikutnya. *Langkah laten* memotong tahap tengah: h dipetakan langsung menjadi vektor $z \in \mathbb{R}^d$ yang diumpankan balik sebagai `inputs_embeds`, tanpa pernah didekodekan menjadi teks [Hao dkk, 2024, Zou dkk, 2025].

Seluruh perbedaan antar-formulasi yang dibandingkan skripsi ini terletak pada pemetaan $h \mapsto z$ tersebut.

2.3. Formulasi Resmi LatentMAS: Regresi Ridge

Zou dkk [2025] memilih pemetaan linear yang dipasang sekali secara luring, memakai kosakata model itu sendiri sebagai data:

$$M^* = \arg \min_{M \in \mathbb{R}^{d \times d}} \|W_{\text{out}}M - W_{\text{in}}\|_F^2 + \lambda \|M\|_F^2. \quad (2.2)$$

Persamaan (2.2) adalah regresi ridge keluaran-ganda [Hoerl dan Kennard, 1970, Wooldridge dan Jennings, 1995]: untuk setiap token i dikehendaki $W_{\text{out}}[i] M \approx W_{\text{in}}[i]$.

Teorema 2.3.1 (Solusi bentuk tertutup) *Minimum Persamaan (2.2) memenuhi persamaan normal*

$$(W_{\text{out}}^\top W_{\text{out}} + \lambda I)M = W_{\text{out}}^\top W_{\text{in}}. \quad (2.3)$$

Bukti. Tuliskan $J(M) = \|W_{\text{out}}M - W_{\text{in}}\|_F^2 + \lambda \|M\|_F^2$. Dengan $\|A\|_F^2 = \text{tr}(A^\top A)$,

$$J(M) = \text{tr}(M^\top W_{\text{out}}^\top W_{\text{out}}M) - 2 \text{tr}(M^\top W_{\text{out}}^\top W_{\text{in}}) + \text{tr}(W_{\text{in}}^\top W_{\text{in}}) + \lambda \text{tr}(M^\top M).$$

Memakai $\partial_M \text{tr}(M^\top A M) = 2AM$ untuk A simetris dan $\partial_M \text{tr}(M^\top B) = B$, diperoleh

$$\frac{\partial J}{\partial M} = 2W_{\text{out}}^\top W_{\text{out}}M - 2W_{\text{out}}^\top W_{\text{in}} + 2\lambda M = 0,$$

yang setara dengan Persamaan (2.3). ■

Vektor yang diumpankan balik kemudian dinormalkan panjangnya,

$$\mathbf{z}_{\text{raw}} = \frac{\mathbf{h}\mathbf{M}}{\|\mathbf{h}\mathbf{M}\|} \tau, \quad \tau = \frac{1}{V} \sum_{i=1}^V \|\mathbf{w}_{\text{in}}[i]\|, \quad (2.4)$$

dengan τ rerata norma embedding masukan nyata (terukur 1,3758).

2.3.1. Peran λ

Nilai $\lambda = 10^{-5}$ bukan hasil penyetelan melainkan pengaman numerik. Pengukuran spektrum $\mathbf{W}_{\text{out}}^\top \mathbf{W}_{\text{out}}$ pada Qwen3-8B memberi nilai eigen terkecil 6,13 dan terbesar 24 465, sehingga faktor penyusutan pada arah paling lemah adalah $6,13/(6,13 + 10^{-5}) = 0,9999984$. Regularisasi itu, pada model ini, praktis tidak berpengaruh.

2.3.2. Mengapa $\mathbf{M}$ bukan identitas

Jika embedding *tied*, maka $\mathbf{M} = (\mathbf{W}^\top \mathbf{W} + \lambda \mathbf{I})^{-1} \mathbf{W}^\top \mathbf{W} \approx \mathbf{I}$ dan penye-larasan tidak mengerjakan apa pun. Pada Qwen3-8B yang tidak *tied*, pengukuran memberi $\|\mathbf{M} - \mathbf{I}\|_F = 66,57$, simpangan relatif 1,04, dan $\overline{\cos}(\mathbf{h}, \mathbf{h}\mathbf{M}) = 0,011$. Artinya proyeksi ridge memindahkan vektor ke arah yang praktis tak berhubungan dengan asalnya. Fakta ini penting: ia memastikan perbandingan pada skripsi ini mengukur efek geometri yang nyata, bukan artefak model dengan $\mathbf{M} \approx \mathbf{I}$.

2.4. Keluarga Relaksasi Diskret

Empat formulasi pembanding tidak memakai $\mathbf{M}$ sama sekali. Keduanya diselesaikan lewat kosakata, dalam dua langkah:

$$\ell = \mathbf{W}_{\text{out}} \mathbf{h} \longrightarrow \mathbf{w} \in \Delta^{V-1} \longrightarrow \mathbf{z} = \mathbf{w}^\top \mathbf{W}_{\text{in}} = \sum_{i=1}^V w_i \mathbf{w}_{\text{in}}[i], \quad (2.5)$$

dengan $\Delta^{V-1} = \{\mathbf{w} \in \mathbb{R}^V : w_i \geq 0, \sum_i w_i = 1\}$ simpleks peluang. Vektor $\mathbf{w}$ adalah distribusi peluang atas kosakata, dan $\mathbf{z}$ adalah rerata terbobot embedding masukan nyata.

Teorema 2.4.1 (Kriteria pemisah) *Untuk setiap $\mathbf{w} \in \Delta^{V-1}$, vektor $\mathbf{z} = \mathbf{w}^\top \mathbf{W}_{in}$ terletak di dalam convex hull baris-baris $\mathbf{W}_{in}$:*

$$\mathbf{z} \in \text{conv}\{\mathbf{W}_{in}[1], \dots, \mathbf{W}_{in}[V]\}.$$

Formulasi raw pada Persamaan (2.4) tidak memiliki jaminan itu.

Bukti. Langsung dari definisi kombinasi konveks: $w_i \geq 0$ dan $\sum_i w_i = 1$. Untuk raw , $\mathbf{hM}$ adalah titik sembarang di $\mathbb{R}^d$ yang tidak dibatasi berada di dalam *hull* mana pun. ■

Teorema 2.4.1 adalah kriteria yang memisahkan $\mathcal{R} = \{\text{soft}, \text{sample}, \text{gumbel}, \text{moi}\}$ dari raw , dan menjadi hipotesis mekanistik seluruh skripsi ini. Ukuran empirisnya adalah $\max_i \cos(\mathbf{z}, \mathbf{W}_{in}[i])$.

2.4.1. **soft**: rerata posterior embedding

Dengan $\mathbf{p} = \text{softmax}(\ell/T)$ dan $\mathbf{w} = \mathbf{p}$,

$$\mathbf{z}_{\text{soft}} \propto \mathbf{p}^\top \mathbf{W}_{in} = \mathbb{E}_{i \sim \mathbf{p}}[\mathbf{W}_{in}[i]]. \quad (2.6)$$

Formulasi ini deterministik. Kelemahannya adalah perata-rataan atas V token menghapus identitas token tunggal — persis muatan yang harus dipertahankan pada tugas simbolik.

2.4.2. **sample**: batas diskret

Dengan $i^* \sim \mathbf{p}$ dan $\mathbf{w} = \mathbf{e}_{i^*}$, $\mathbf{z}$ adalah embedding token nyata, yaitu *titik sudut hull*. Fidelitas simbol maksimum, superposisi nol.

2.4.3. **gumbel**: relaksasi kontinu stokastik

Dengan $g_i \stackrel{iid}{\sim} \text{Gumbel}(0, 1)$,

$$\mathbf{w} = \text{softmax}((\ell + \mathbf{g})/T), \quad (2.7)$$

yaitu distribusi Gumbel-softmax [Zhang dkk, 2025]. Landasannya adalah trik Gumbel-max.

Teorema 2.4.2 (Trik Gumbel-max) *Jika $g_i \stackrel{iid}{\sim} \text{Gumbel}(0, 1)$, maka*

$$\Pr \left[\arg \max_j (\ell_j + g_j) = i \right] = \text{softmax}(\boldsymbol{\ell})_i.$$

Bukti. Fungsi distribusi Gumbel baku adalah $F(t) = e^{-e^{-t}}$ dengan densitas $f(t) = e^{-t}e^{-e^{-t}}$. Maka

$$\Pr \left[\arg \max_j (\ell_j + g_j) = i \right] = \int_{-\infty}^{\infty} f(t - \ell_i) \prod_{j \neq i} F(t - \ell_j) dt.$$

Karena $\prod_j F(t - \ell_j) = \exp(-e^{-t} \sum_j e^{\ell_j})$, integralnya menjadi

$$\int_{-\infty}^{\infty} e^{-(t-\ell_i)} \exp(-e^{-t} \sum_j e^{\ell_j}) dt.$$

Substitusi $u = e^{-t} \sum_j e^{\ell_j}$, sehingga $du = -u dt$, memberi

$$\frac{e^{\ell_i}}{\sum_j e^{\ell_j}} \int_0^{\infty} e^{-u} du = \frac{e^{\ell_i}}{\sum_j e^{\ell_j}} = \text{softmax}(\boldsymbol{\ell})_i.$$

■

Mengganti $\arg \max$ dengan $\text{softmax}(\cdot/T)$ menghasilkan relaksasi kontinu dari penarikan diskret tersebut. Karena itu gumbel terletak pada kontinum antara `sample` ($T \rightarrow 0$) dan campuran seragam ($T \rightarrow \infty$).

2.4.4. `moi`: rerata posterior Dirichlet

Zhuang dkk [2025] mengusulkan *Mixture of Inputs*. Dengan entropi ternormalisasi

$$H = \frac{-\sum_i p_i \log p_i}{\log V} \in [0, 1], \quad (2.8)$$

sebuah token $y \sim \mathbf{p}$ ditarik, lalu

$$\mathbf{w} = \frac{H\mathbf{p} + (\beta + 1 - H)\mathbf{e}_y}{\beta + 1}. \quad (2.9)$$

Teorema 2.4.3 (moi sebagai rerata posterior) *Misalkan $\boldsymbol{\theta} \sim \text{Dirichlet}(\boldsymbol{\alpha})$ dengan $\alpha_i = Hp_i$, dan diamati satu observasi kategorik y dengan pseudo-hitung $\beta + 1 - H$. Maka rerata posteriornya tepat sama dengan Persamaan (2.9).*

Bukti. Dirichlet konjugat terhadap kategorik, sehingga $\boldsymbol{\theta} \mid y \sim \text{Dirichlet}(\boldsymbol{\alpha} + (\beta + 1 - H)\mathbf{e}_y)$. Rerata Dirichlet adalah parameter dibagi jumlahnya, dan $\alpha_0 = \sum_i Hp_i = H$, sehingga

$$\mathbb{E}[\boldsymbol{\theta} \mid y] = \frac{\boldsymbol{\alpha} + (\beta + 1 - H)\mathbf{e}_y}{\alpha_0 + (\beta + 1 - H)} = \frac{H\mathbf{p} + (\beta + 1 - H)\mathbf{e}_y}{H + \beta + 1 - H} = \frac{H\mathbf{p} + (\beta + 1 - H)\mathbf{e}_y}{\beta + 1}.$$

■

Bahwa $\mathbf{w}$ pada Persamaan (2.9) berada di simpleks mudah diperiksa: $\sum_i w_i = (H + \beta + 1 - H)/(\beta + 1) = 1$, dan $w_i \geq 0$ karena $\beta + 1 \geq 1 \geq H$. Suku $\mathbf{e}_y$ menjangkarkan identitas token diskret, sementara $H\mathbf{p}$ mempertahankan superposisi ketika model memang ragu.

2.5. Bahasa Ekspresi Faktor: DSL dan AST

Domain-specific language (DSL) adalah bahasa formal kecil yang dirancang untuk satu ranah persoalan. DSL pada penelitian ini memiliki enam *leaf* data — `$open`, `$high`, `$low`, `$close`, `$volume`, `$return` — operator aritmetika, pembandingan, logika, ternari, serta sekitar tujuh puluh fungsi yang terbagi menjadi fungsi lintas-saham (RANK, ZSCORE) dan fungsi deret waktu (TS_MEAN, TS_CORR, REGRESI).

Pemakaian DSL, alih-alih bahasa pemrograman umum, dipilih atas tiga alasan. Pertama, keamanan: keluaran model dieksekusi, sehingga tata bahasa terbatas mencegah eksekusi kode sembarang. Kedua, keterujian: dengan tata bahasa tetap, pertanyaan “apakah keluaran ini sah” dapat diputuskan secara algoritmik — inilah

yang diukur sebagai laju lolos *gate*. Ketiga, keterbandingan: semua formulasi harus menyatakan gagasannya dalam bahasa yang sama.

Abstract syntax tree (AST) adalah pohon yang simpul-daunnya berupa variabel atau konstanta dan simpul-dalamnya berupa operator atau pemanggilan fungsi. Pada penelitian ini AST dipakai untuk dua hal yang berbeda: jalur eksekusi (mengubah ekspresi menjadi kode yang dapat dijalankan) dan jalur analisis (menghitung kedalaman ekspresi serta cakupan fungsi DSL).

2.6. Faktor Alpha dan Koefisien Informasi

Sebuah *faktor alpha* adalah fungsi f yang memetakan data pasar sampai hari t menjadi skor lintas-saham yang diharapkan berkorelasi dengan imbal hasil masa depan [Kakushadze, 2016, Yu dkk, 2023]. Mutunya diukur dengan *rank information coefficient*,

$$IC_t = \rho_{\text{Spearman}}(f_{\cdot t}, y_{\cdot t}), \quad (2.10)$$

yaitu korelasi Spearman [Spearman, 1904a] lintas-saham antara nilai faktor dan imbal hasil berikutnya. Peringkat dipilih, bukan korelasi Pearson, atas tiga alasan: invarian terhadap transformasi monoton naik, ketahanan terhadap pencilan pada imbal hasil harian yang berekor tebal, dan keterbandingan antar-ekspresi yang skalanya sangat berbeda.

Agregatnya adalah

$$\overline{IC} = \frac{1}{T} \sum_{t=1}^T IC_t, \quad ICIR = \frac{\overline{IC}}{s_{IC}}, \quad t\text{-stat} = ICIR\sqrt{T}, \quad (2.11)$$

dengan s_{IC} simpangan baku deret IC_t . Bentuk terakhir adalah statistik- t satu sampel untuk $H_0 : \mathbb{E}[IC] = 0$, karena $s_{IC}/\sqrt{T}$ merupakan galat baku rerata. *Information ratio* [Grinold dan Kahn, 2000] adalah padanan ICIR pada literatur manajemen portofolio.

Teorema 2.6.1 (Ambang deteksi dan lebar lintas-saham) *Di bawah H_0 tanpa asosiasi, untuk satu hari dengan N saham berlaku $\text{Var}(IC_t) = 1/(N - 1)$. Dengan asumsi kebebasan antar-hari, besaran $|\overline{IC}|$ terkecil yang dapat dinyatakan signif-*

an pada taraf 5% adalah

$$|\overline{\text{IC}}|_{\min} = \frac{1,96}{\sqrt{(N-1)T}}. \quad (2.12)$$

Teorema 2.6.1 berimplikasi langsung pada tafsir hasil skripsi ini: $|\text{IC}|$ tidak dapat dibandingkan antar-pasar tanpa menyebutkan N dan T . Tabel 3.2 pada Bab III memuat angkanya.

2.7. Uji Statistik yang Dipakai

2.7.1. Uji eksak Fisher

Dipakai untuk membandingkan proporsi dua kelompok bebas. Di bawah H_0 dengan marginal tetap, cacah satu sel mengikuti sebaran hipergeometrik, sehingga nilai- p dihitung eksak tanpa hampiran sampel besar. Ukuran efeknya memakai h Cohen,

$$h = 2 \arcsin \sqrt{p_1} - 2 \arcsin \sqrt{p_2}, \quad (2.13)$$

yang didefinisikan pada skala arcsin-akar karena skala itulah yang menstabilkan ragam proporsi binomial.

2.7.2. Uji Mann–Whitney

Dipakai untuk membandingkan sebaran $|\text{IC}|$ antar-kelompok. Sebaran itu condong dan berekor, sehingga uji- t tidak tepat. Ukuran efeknya memakai korelasi *rank-biserial*.

2.7.3. Uji McNemar dan daya uji

Untuk perbandingan berpasangan biner, hanya pasangan diskordan yang membawa informasi: dengan $b_{01} + b_{10} = m$, di bawah H_0 berlaku $b_{01} \sim \text{Binomial}(m, \frac{1}{2})$. Konsekuensi aritmetiknya penting untuk merancang eksperimen: pada $n = 8$ pasangan dengan efek sempurna ($b_{01} = 5$, $b_{10} = 0$), nilai- p dua sisi terkecil yang mungkin adalah $2 \cdot (1/2)^5 = 0,0625 > 0,05$. Artinya sel dengan $n = 8$ tidak akan pernah signifikan berapa pun besar efeknya. Pertimbangan inilah yang menetapkan

$n = 20$ jalan per sel pada rancangan Bab III.

BAB III

METODOLOGI PENELITIAN

3.1. Rancangan Umum

Penelitian ini berbentuk eksperimen faktorial dengan dua sumbu perlakuan yang dijalankan pada dua kategori tugas.

Sumbu A — formulasi langkah laten. Lima nilai: $\mathcal{M} = \{\text{raw}, \text{soft}, \text{gumbel}, \text{sample}, \text{moi}\}$, dengan keluarga relaksasi diskret $\mathcal{R} = \mathcal{M} \setminus \{\text{raw}\}$.

Sumbu B — medium komunikasi antar-agen. Tiga nilai: `text` (teks penuh, garis dasar), `kv` (hanya *key-value cache*), `kv_and_text` (keduanya).

Kedua kategori tugas diperlakukan setara, bukan sebagai tugas utama dan tugas tambahan:

Lengan penalaran umum. GSM8K (1 319 soal aritmetika bertingkat), ARC-Challenge (1 172 soal pilihan ganda sains), HumanEval+ (164 soal sintesis program, dinilai *pass@1* di bawah uji unit).

Lengan faktor simbolik. Pembangkitan ekspresi faktor alpha dalam DSL, dinilai pada data Bursa Efek Indonesia.

Ketiga tolok ukur dipilih karena mengisolasi kemampuan yang berbeda: GSM8K menguji panjang rantai penalaran, ARC-Challenge menguji pengetahuan dengan rantai pendek, dan HumanEval+ menguji fidelitas simbol — satu pengenalan salah membuat seluruh program gagal. Rancangan itu membuat hipotesis penelitian dapat dipatahkan: jika kelemahan kanal laten memang spesifik pada muatan simbolik, efek terbesar harus muncul pada HumanEval+ dan lengan faktor, bukan merata.

3.2. Rantai Agen

Rantai bersifat *single-pass* dengan tiga peran berurutan: **proposal** (merumuskan satu hipotesis pasar), **innovate** (mempertajam atau menyilangkan hipotesis), **construct** (menuliskan ekspresi DSL). Hanya `construct` yang menghasilkan teks terstruktur; dua agen sebelumnya, pada medium `kv`, berkomunikasi murni lewat *key-value cache*. Tidak ada loop evolusi: keputusan ini diambil sadar agar yang diukur adalah kanal komunikasi, bukan kualitas mekanisme pencarian.

Setiap agen menjalankan $m = 10$ langkah laten sebelum menyerahkan pekerjaan.

3.3. Parameter dan Asalnya

Tabel 3.1 mendaftarkan seluruh parameter beserta asal nilainya. Hanya satu parameter yang pernah dicari nilainya, yaitu β pada `moi`; sisanya dipatok pada nilai yang ditetapkan paper asal, nilai baku pustaka, atau konstanta rancangan. Ketiadaan penyetelan ini disengaja: dengan tidak menyetel apa pun terhadap hasil, tidak ada risiko parameter dipilih supaya formulasi tertentu menang.

Tabel 3.1 Parameter penelitian dan asal nilainya.

Simbol	Nama kode	Nilai	Asal
d	<code>d.h</code>	4 096	konstanta model Qwen3-8B
V	<code>vocab</code>	151 936	konstanta model Qwen3-8B
λ	<code>reg_lambda</code>	10^{-5}	pengaman numerik; terukur inert
τ	<code>target_norm</code>	1,3758	diturunkan dari W_{in}
T	<code>latent_temp</code>	0,7	nilai baku dekode
β	<code>latent_step_beta</code>	1	dicari, sapuan 0,25–8, tanpa efek
α	<code>latent_alpha</code>	0,25/0,5/0,75	variabel bebas sumbu <code>mix</code>
m	<code>latent_steps</code>	10	konstanta rancangan
—	<code>temperature</code>	0,8	nilai baku dekode teks
—	<code>max_new_tokens</code>	4 096	batas panjang keluaran
—	<code>max_repair</code>	3	batas perbaikan per jalan
—	<code>seeds</code>	0–4	5 <i>seed</i>
—	<code>directions</code>	4 arah	d0, d1, opp_mom, opp_rev

Perkalian $5 \text{ seed} \times 4 \text{ arah}$ menghasilkan $n = 20$ jalan per sel. Rancangan ini berpasangan: sel yang berbeda menghadapi pasangan (*seed*, arah) yang sama, sehingga variasi kesulitan terkontrol.

3.4. Sumbu Interpolasi *mix*

Kelima formulasi memberi lima titik terpisah, sehingga hubungan geometri-kinerja hanya dapat dibaca sebagai “searah”. Untuk menguji *bentuk* hubungan itu, ditambahkan sumbu interpolasi

$$\mathbf{z}(\alpha) = \frac{(1 - \alpha)\mathbf{z}_{\text{raw}} + \alpha\mathbf{z}_{\text{soft}}}{\|(1 - \alpha)\mathbf{z}_{\text{raw}} + \alpha\mathbf{z}_{\text{soft}}\|} \tau, \quad \alpha \in [0, 1]. \quad (3.1)$$

Sumbu ini **bukan usulan metode baru** melainkan alat ukur. Karena kedua ujung sudah dinormalkan ke τ yang sama, perubahan α hanya mengubah *arah* vektor, bukan panjangnya — dan arah itulah yang diukur $\max_i \cos(\mathbf{z}, \mathbf{W}_{\text{in}}[i])$. Nilai $\alpha \in \{0,25; 0,5; 0,75\}$ dijalankan; $\alpha = 0$ dan $\alpha = 1$ secara konstruksi identik dengan *raw* dan *soft*.

3.5. Kendali Mutu Ekspresi (*Gate*)

Setiap ekspresi yang dihasilkan `construct` melewati rangkaian pemeriksaan berurutan, disusun dari yang termurah ke yang termahal. Enam pemeriksaan pertama bersifat *struktural* dan tidak menyentuh data pasar sama sekali:

1. **Keterparsingan** — ekspresi dapat diurai tata bahasa DSL.
2. **Ariti** — jumlah argumen sesuai tanda tangan fungsi. Menangkap kesalahan paling sering, yaitu memberi periode pada fungsi lintas-saham berargumen tunggal, misalnya `RANK ($x, 7)`.
3. **Variabel dikenal** — menangkap variabel halusinasi seperti `$return_id`.
4. **Argumen tak degenerate** — menangkap `REGRESI (x, x)`.
5. **Semantik numerik** — jendela degenerate, kondisi non-boolean, ambang pada persentil.
6. **Regulator** — panjang simbol ≤ 300 , fitur dasar ≤ 6 , duplikasi sub-pohon ≤ 8 .

Pemeriksaan ketujuh, **eksekusi**, adalah satu-satunya yang benar-benar menjalankan ekspresi. Ia mengevaluasinya pada sampel data tetap dan menolak ekspresi yang menghasilkan kolom kosong seluruhnya, kolom konstan, atau kolom yang terdefinisi pada kurang dari 20 hari. Pemeriksaan ini perlu justru karena enam pemeriksaan sebelumnya struktural: ekspresi yang sempurna secara sintaksis tetap dapat menghasilkan kolom mati, dan hanya eksekusi yang dapat melihatnya.

Dua sifat pemeriksaan ini perlu dinyatakan terbuka. Pertama, ia *fail-open*: bila data sampel tidak tersedia, pemeriksaan dilewati dengan peringatan, bukan menjatuhkan proses. Kedua, jendela sampelnya *tetap* dan sengaja berbeda dari jendela penilaian, sehingga *gate* tidak pernah ikut menyeleksi di atas data uji. Karena jendela itu tetap, keputusan *gate* tidak bergantung pada panjang jendela penilaian T — perbedaan yang penting ketika membaca Bab IV, sebab laju lolos *gate* dan laju signifikansi adalah dua besaran dengan mekanisme yang sama sekali berbeda.

3.6. Data Pasar dan Universe Penilaian

Ekspresi faktor dinilai pada data harga dan volume harian Bursa Efek Indonesia. Data diperoleh dari Yahoo Finance untuk seluruh emiten tercatat, dengan penyesuaian aksi korporasi diterapkan mundur sehingga deret harga kontinu. Panel mentah mencakup 896 emiten pada 1 Januari 2019 sampai 14 Januari 2026, sejumlah 1 286 173 baris.

Setiap baris memuat enam kolom yang menjadi satu-satunya *leaf* data dalam DSL. Tidak ada kolom fundamental maupun data pesanan; keterbatasan ini disengaja, karena tujuan lengan faktor adalah menguji kesetiaan muatan simbolik pada kanal komunikasi, bukan memaksimalkan performa strategi.

3.6.1. Universe

Universe dibatasi pada konstituen indeks LQ45. Indeks ini dipilih karena kriteria keanggotaannya ditetapkan otoritas bursa berdasarkan likuiditas dan kapitalisasi pasar [Tandelilin, 2010], bukan oleh peneliti; karena keanggotaannya kecil dan stabil sehingga jumlah emiten per hari konstan; dan karena likuiditasnya tinggi

sehingga harga penutupan harian merepresentasikan transaksi nyata.

Dari 44 konstituen, tujuh dikeluarkan karena tercatat setelah awal periode penelitian sehingga tidak memiliki data pada seluruh rentang: AADI, ADMR, AMMN, CUAN, GOTO, MBMA, dan PGEO. Emiten yang dipakai berjumlah **37** dan seluruhnya memiliki data pada sekurang-kurangnya 98% hari bursa. Jumlah emiten per hari bursa karena itu tetap 37 tanpa hari yang berkurang.

3.6.2. Periode dan pembagian

1. **Jendela seleksi**, 1 Januari 2021 – 31 Desember 2021, sebanyak **247** hari bursa. Jendela ini dipakai sistem untuk menilai dan menyaring ekspresi.
2. **Jendela holdout**, 1 Januari 2022 – 26 Desember 2025, sebanyak **958** hari bursa. Jendela ini tidak pernah dipakai untuk menilai maupun menyaring ekspresi mana pun.

Data sebelum 2021 tetap dimuat sebagai periode pemanasan sepanjang 400 hari kalender, karena operator deret waktu berjendela panjang memerlukan riwayat sebelum hari pertama penilaian agar terdefinisi.

3.6.3. Definisi label

Label yang diprediksi setiap ekspresi adalah imbal hasil satu hari yang dimulai pada hari bursa berikutnya:

$$y_{i,t} = \frac{P_{i,t+2}}{P_{i,t+1}} - 1. \quad (3.2)$$

Nilai faktor pada hari t dihitung dari informasi paling lambat penutupan hari t , sedangkan transaksi paling awal yang dapat dilakukan adalah hari $t + 1$. Imbal hasil pertama yang benar-benar dapat diperoleh karena itu adalah dari $t + 1$ ke $t + 2$. Penundaan satu hari ini merupakan pengaman terhadap *look-ahead bias*, dan berlaku seragam pada seluruh formulasi.

3.6.4. Metrik portofolio

Selain koefisien informasi, tiap ekspresi diperdagangkan sebagai portofolio *long-short* berbobot sama dengan penyeimbangan ulang harian penuh. Fraksi universe tiap sisi ditetapkan $q = 0,2$ (kuintil), sehingga tiap sisi berisi tujuh emiten. Bobot berjumlah nol sehingga portofolio bersifat *dollar-neutral*, dan jumlah nilai mutlaknya dua sehingga imbal hasil harian terbaca langsung sebagai selisih *long* dikurangi *short*.

Pemilihan kuintil, bukan desil, mengikuti pertimbangan ragam. Jika imbal hasil diuraikan sebagai $r_{i,t} = \mu_{i,t} + \varepsilon_{i,t}$ dengan $\text{Var}(\varepsilon_{i,t}) = \sigma^2$, maka komponen derau imbal hasil portofolio dengan k emiten per sisi memiliki simpangan baku

$$\text{sd} \left(\frac{1}{k} \sum_{\text{long}} \varepsilon - \frac{1}{k} \sum_{\text{short}} \varepsilon \right) = \sigma \sqrt{2/k}, \quad (3.3)$$

sedangkan komponen sinyal tidak bergantung k . Pada universe 37 emiten dengan $\sigma = 2,42\%$ terukur, desil memberi $k = 3$ sehingga simpangan baku imbal hasil harian 1,98% dan galat baku imbal hasil tahunan 30,3 poin persen; kuintil memberi $k = 7$ sehingga keduanya turun menjadi 1,29% dan 19,9 poin persen. Fraksi yang sama dipakai pada seluruh formulasi sehingga perbandingan tetap setara. Biaya transaksi ditetapkan nol dan dilaporkan apa adanya, sedangkan perputaran portofolio dilaporkan tersendiri sehingga besar biaya yang diabaikan dapat dinilai pembaca. Anualisasi memakai 241 hari bursa per tahun.

3.6.5. Ambang deteksi

Menerapkan Teorema 2.6.1 pada universe ini memberi Tabel 3.2, yang harus dibaca bersama setiap angka $|\text{IC}|$ di Bab IV.

Tabel 3.2 Ambang deteksi $|\overline{\text{IC}}|$ menurut lebar lintas-saham N dan panjang jendela T , dari Persamaan (2.12).

Jendela	N	T	galat baku $\overline{\text{IC}}$	$ \overline{\text{IC}} _{\min}$
Seleksi 2021	37	247	0,01060	0,0208
Holdout 2022–2025	37	958	0,00538	0,0106

Konsekuensinya harus dinyatakan sejak awal: jumlah ekspresi signifikan pada jendela holdout dapat *naik* dibanding jendela seleksi semata-mata karena T hampir empat kali lebih panjang sehingga ambangnya turun sekitar $\sqrt{958/247} \approx 1,97$ kali. Kenaikan itu bukan bukti perbaikan mutu sinyal.

3.7. Hipotesis Penelitian

H1 (validitas). Keluarga $\mathcal{R}$ menghasilkan keluaran yang lebih sering sah dibanding `raw`, pada kedua medium.

H2 (efisiensi). Medium `kv` memangkas biaya token dan waktu secara besar dibanding `text`, tanpa menurunkan laju lolos *gate*.

H3 (mutu sinyal). Keunggulan validitas pada H1 *tidak* disertai keunggulan mutu sinyal, yaitu sebaran $|IC|$ keluarga $\mathcal{R}$ tidak berbeda dari `raw`.

H4 (bentuk hubungan). Hubungan antara kedekatan geometris ke *convex hull* dan kinerja hilir berbentuk berambang, bukan monoton bertahap.

Perlu ditegaskan bahwa H3 dirumuskan sebagai hipotesis nol yang *diharapkan tidak ditolak*. Perumusan semacam ini memerlukan kehati-hatian tafsir: tidak ditolaknya H3 bukan bukti kesetaraan, melainkan ketiadaan bukti perbedaan pada daya uji yang tersedia. Bab IV melaporkan ukuran efek dan ukuran sampelnya agar pembaca dapat menilai sendiri.

BAB IV

HASIL DAN PEMBAHASAN

Bab ini disusun sebagai *bukti berjenjang*. Setiap tingkat menanyakan satu hal yang lebih menuntut daripada tingkat sebelumnya, dan sebuah formulasi harus lolos tingkat k sebelum pertanyaan tingkat $k + 1$ bermakna baginya. Susunan ini dipilih karena temuan utama penelitian justru berupa *putusnya* rantai itu pada satu titik tertentu: keunggulan yang sangat besar di tingkat rendah tidak berlanjut ke tingkat tinggi.

Tingkat 1 Apakah sistem menghasilkan keluaran sama sekali?

Tingkat 2 Apakah keluaran itu sah menurut tata bahasa dan *gate*?

Tingkat 3 Apakah ekspresi yang sah benar-benar hidup ketika dijalankan pada data pasar Indonesia?

Tingkat 4 Apakah nilainya signifikan secara statistik?

Tingkat 5 Apakah *mutu* sinyalnya berbeda antar-formulasi?

Tingkat 6 Apakah temuan itu bertahan di luar jendela seleksi?

4.1. Tingkat 1–2: Keandalan Keluaran

Tabel 4.1 melaporkan keandalan dan biaya tiap sel dengan denominator jalan.

Pola pada kolom “Lolos *gate*” tajam dan tidak memerlukan uji untuk dilihat. Pada medium `kv`, keempat anggota keluarga $\mathcal{R}$ berada di 95–100%, sementara `raw` berada di 50%. Pada medium `kv_and_text`, jarak itu melebar: keluarga $\mathcal{R}$ mencapai 100% sementara `raw` turun ke 30%.

Tabel 4.1 Keandalan dan biaya lengan faktor per JALAN. Satu jalan = satu pasangan (arah, *seed*); denominatornya sama di seluruh sel menurut rancangan, sehingga laju antar-sel sebanding. Kolom terakhir mencatat berapa kali agen *construct* harus dipanggil per jalan; nilai di atas 1 berarti *gate* memicu perbaikan, sehingga kolom itu sekaligus ukuran biaya dan ukuran keandalan.

Medium	Formulasi	Jalan	Lolos <i>gate</i>	Ekspresi	Token/jalan	Detik/jalan
teks	—	20	100,0%	120	2436	181
kv	raw	20	50,0%	59	803	77
kv	soft	20	100,0%	111	481	51
kv	gumbel	20	100,0%	112	502	58
kv	sample	20	95,0%	109	517	49
kv	moi	20	95,0%	106	524	56
kv	mix $\alpha=0,50$	20	100,0%	116	511	61
kv	mix $\alpha=0,25$	20	55,0%	68	734	63
kv	mix $\alpha=0,75$	20	100,0%	119	502	72
kv+teks	raw	20	30,0%	29	3690	296
kv+teks	soft	20	100,0%	120	1920	185
kv+teks	gumbel	20	100,0%	120	1991	204
kv+teks	sample	20	100,0%	119	2019	198
kv+teks	moi	20	100,0%	120	1993	136

Kolom “Ekspresi” memperkuat pembacaan yang sama dari sisi lain. Dua puluh jalan *kv_raw* hanya menghasilkan 59 ekspresi, sedangkan jumlah jalan yang identik pada *kv_soft* menghasilkan 111. Selisih itu bukan soal selera panjang keluaran: *raw* justru memakai lebih banyak token (803 berbanding 481 per jalan) dan lebih banyak waktu (77 berbanding 51 detik), sekaligus memerlukan 1,60 kali panggilan *construct* per jalan karena *gate* berulang kali memicu perbaikan.

4.1.1. Uji formal

Tabel 4.2 memuat seluruh uji formal penelitian ini. Dua baris pertama tiap medium adalah pengujian Tingkat 2–3.

Pada medium *kv*, keluarga $\mathcal{R}$ lolos *gate* pada 97,5% jalan berbanding 50,0% untuk *raw*; selisih 47,5 poin persen dengan uji eksak Fisher $p = 5,69 \times 10^{-7}$ dan h Cohen = 1,25, yaitu ukuran efek yang menurut konvensi tergolong sangat besar. Pada medium *kv_and_text*, selisihnya 70,0 poin persen dengan $p = 8,77 \times 10^{-13}$.

H1 diterima dengan margin yang lebar pada kedua medium.

Tabel 4.2 Uji formal keluarga $\mathcal{R}$ melawan `raw`. Dua baris pertama tiap medium menguji VALIDITAS keluaran (uji eksak Fisher, ukuran efek h Cohen); dua baris berikutnya menguji MUTU SINYAL (uji Mann–Whitney atas sebaran $|IC|$, ukuran efek *rank-biserial*). Perbedaan arah kesimpulan antara kedua kelompok baris inilah temuan utama penelitian.

Medium	Ukuran	$\mathcal{R}$ vs <code>raw</code>	Selisih	Ukuran efek	Nilai- p
kv	lolos <i>gate</i> /jalan	97,5% vs 50,0%	47,5 pp	$h=1,253$	$5,69 \times 10^{-7}$
	ekspresi hidup	89,4% vs 48,3%	41,1 pp	$h=0,941$	$3,02 \times 10^{-12}$
	median $ IC $ 2021	0,0103 vs 0,0076	—	$r_{rb}=0,143$	0,207
	median $ IC $ holdout	0,0060 vs 0,0091	—	$r_{rb}=-0,126$	0,265
kv+teks	lolos <i>gate</i> /jalan	100,0% vs 30,0%	70,0 pp	$h=1,982$	$8,77 \times 10^{-13}$
	ekspresi hidup	86,4% vs 58,6%	27,7 pp	$h=0,641$	$4,12 \times 10^{-4}$
	median $ IC $ 2021	0,0111 vs 0,0129	—	$r_{rb}=0,067$	0,639
	median $ IC $ holdout	0,0062 vs 0,0066	—	$r_{rb}=0,063$	0,662

4.2. Tingkat 3: Ekspresi yang Hidup di Pasar Indonesia

Lolos *gate* belum berarti berguna. Sebuah ekspresi dapat sah secara struktural, lolos pemeriksaan eksekusi pada sampel, dan tetap menghasilkan kolom yang tidak informatif pada universe penilaian. Tingkat ini menghitung proporsi ekspresi yang menghasilkan nilai IC terdefinisi dan tidak konstan pada panel LQ45.

Hasilnya, pada medium kv: 89,4% untuk keluarga $\mathcal{R}$ berbanding 48,3% untuk `raw`, selisih 41,1 poin persen, $p = 3,02 \times 10^{-12}$. Pada kv_and_text: 86,4% berbanding 58,6%, selisih 27,7 poin persen, $p = 4,12 \times 10^{-4}$.

Keunggulan Tingkat 2 karena itu tidak hilang ketika ekspresi benar-benar dijalankan pada data pasar Indonesia. Ia berkurang sedikit besarnya, tetapi tetap sangat signifikan.

4.3. Tingkat 4: Signifikansi Statistik

Tabel 4.3 melaporkan, untuk tiap sel, jumlah ekspresi hidup, jumlah yang signifikan, dan rerata $|IC|$, pada kedua jendela.

Pembacaan tabel ini menuntut kehati-hatian yang sudah disiapkan pada Subbab 3.6.. Jumlah ekspresi signifikan pada jendela holdout secara umum *lebih besar* daripada pada jendela seleksi — misalnya kv_and_text_soft naik dari 22 menjadi 33. Kenaikan itu **bukan** bukti bahwa ekspresi menjadi lebih baik di luar sampel. Penjelasannya murni aritmetika: jendela holdout memiliki $T = 958$ ber-

Tabel 4.3 Mutu sinyal ekspresi pada universe LQ45. “Hidup” berarti IC terdefinisi dan nilainya tidak konstan; “sig.” berarti $|t| \geq 1,96$. Ambang deteksi berbeda antar-jendela (Tabel 3.2), sehingga kolom sig. TIDAK sebanding langsung antar-jendela.

Medium	Formulasi	Seleksi 2021 ($T=247$)			Holdout 2022–2025 ($T=958$)		
		Hidup	Sig.	$ IC $	Hidup	Sig.	$ IC $
teks	—	96	11	0,0115	96	18	0,0071
kv	raw	28	5	0,0116	28	8	0,0097
kv	soft	92	13	0,0122	92	17	0,0077
kv	gumbel	98	19	0,0147	98	24	0,0085
kv	sample	94	24	0,0170	94	24	0,0089
kv	moi	86	18	0,0144	86	13	0,0081
kv	mix $\alpha=0,50$	99	15	0,0126	99	20	0,0078
kv	mix $\alpha=0,25$	53	11	0,0155	53	10	0,0086
kv	mix $\alpha=0,75$	99	18	0,0152	99	19	0,0082
kv+teks	raw	17	3	0,0136	17	5	0,0082
kv+teks	soft	98	22	0,0153	98	33	0,0102
kv+teks	gumbel	106	18	0,0150	106	28	0,0083
kv+teks	sample	95	13	0,0126	95	23	0,0077
kv+teks	moi	100	26	0,0163	100	23	0,0083


banding $T = 247$, sehingga menurut Persamaan (2.12) ambang deteksinya turun dari 0,0208 menjadi 0,0106, yaitu sekitar $\sqrt{958/247} \approx 1,97$ kali lebih rendah. Ekspresi dengan $|IC|$ yang sama karena itu lebih mudah melewati ambang, meskipun rerata $|IC|$ -nya justru *turun* (kolom terakhir tabel: dari kisaran 0,012–0,017 menjadi 0,007–0,010).

Gambar 4.1 menampilkan hal yang sama secara visual: kotak sebaran $|IC|$ beserta garis ambang deteksi masing-masing jendela.

4.4. Tingkat 5: Mutu Sinyal — Temuan Utama

Tingkat ini menanyakan pertanyaan yang berbeda dari seluruh tingkat sebelumnya. Tingkat 1–4 mengukur *berapa banyak* ekspresi yang sah, hidup, dan signifikan. Tingkat 5 mengukur, di antara ekspresi yang berhasil, *seberapa baik* sinyalnya.


Dua baris terakhir tiap medium pada Tabel 4.2 menjawabnya. Pada medium kv, median $|IC|$ keluarga $\mathcal{R}$ adalah 0,0103 berbanding 0,0076 untuk raw; uji Mann–Whitney memberi $p = 0,207$ dengan korelasi *rank-biserial* 0,143. Pada medium kv_and_text, mediannya 0,0111 berbanding 0,0129 — arahnya *terbalik*



Gambar 4.1 Sebaran $|C|$ per formulasi pada medium kv , dua jendela penilaian, dengan garis putus-putus menandai ambang signifikansi $1,96/\sqrt{(N-1)T}$. Perhatikan bahwa kotak kelima formulasi saling bertumpang tindih hampir seluruhnya pada kedua jendela.

— dengan $p = 0,639$. Pada jendela holdout, arah pada medium kv juga berbalik ($r_{rb} = -0,126$, $p = 0,265$).

H3 tidak ditolak. Tidak ditemukan bukti bahwa keluarga relaksasi diskret menghasilkan sinyal yang lebih baik. Gambar 4.2 menyandingkan kedua temuan.



Gambar 4.2 Temuan utama penelitian. Panel (a): validitas keluaran berbeda tajam antara keluarga $\mathcal{R}$ dan raw , dengan p sampai $8,8 \times 10^{-13}$. Panel (b): mutu sinyal keluaran yang berhasil tidak berbeda, dengan $p = 0,21$ dan $p = 0,64$. Kedua panel berasal dari korpus ekspresi yang sama persis.

4.4.1. Tafsir: apa yang sebenarnya diperbaiki proyeksi *convex hull*

Gabungan Tingkat 2–5 membentuk sebuah *disosiasi* yang bersih, dan inilah kontribusi utama skripsi ini:

Memproyeksikan langkah laten ke dalam *convex hull* embedding token nyata memperbaiki **validitas** keluaran secara dramatis — dari 50% menjadi 97,5% jalan yang menghasilkan ekspresi sah — tetapi **tidak memperbaiki mutu** sinyal ekspresi yang berhasil dihasilkan.

Tafsir mekanistiknya sejalan dengan Teorema 2.4.1. Yang rusak pada `raw` adalah kemampuan kanal membawa *symbol*: nama fungsi DSL, tanda kurung, argumen. Vektor hM tidak dijamin dekat dengan embedding token mana pun, sehingga ketika agen berikutnya membaca memori kerja itu dan mendekodekannya, ia menghasilkan untaian yang bentuknya menyerupai ekspresi tetapi ejaannya salah. Sebaliknya, apa yang *tidak* rusak adalah mutu gagasannya. Hipotesis pasar yang dibawa `raw` tampaknya sama baiknya — hanya lebih sering gagal dituliskan.

Pembacaan ini konsisten dengan bukti dari sisi lain. Ukuran kemiripan semantik antar-ekspresi memberi angka yang nyaris sama untuk kelima formulasi (0,84–0,85), yang berarti `raw` tidak kolaps ke kumpulan gagasan yang lebih sempit. Yang berbeda adalah keberhasilan menuliskannya.

4.4.2. Mengapa ini bukan sekadar hasil nol

Perumusan H3 sebagai hipotesis yang diharapkan tidak ditolak menuntut kehati-hatian. Tidak ditolaknya H_0 bukan bukti kesetaraan. Tiga hal membuat pembacaan disosiasi di atas tetap dapat dipertahankan.

Pertama, ukuran sampelnya tidak kecil: 370 ekspresi keluarga $\mathcal{R}$ berbanding 28 ekspresi `raw` pada medium `kv`. Ketimpangan jumlah itu sendiri adalah konsekuensi dari temuan Tingkat 2 dan tidak dapat dihindari tanpa mengubah rancangan.

Kedua, ukuran efeknya kecil dan tidak konsisten arahnya: $r_{rb} = +0,143$ pada `kv` seleksi, $-0,126$ pada `kv` holdout, $+0,067$ dan $+0,063$ pada `kv_and_text`. Efek yang nyata tetapi kurang daya biasanya konsisten arahnya; yang terlihat di sini tidak.

Ketiga, dan paling penting, kontrasnya sangat besar. Pada korpus yang sama, dengan uji pada tingkat sebelumnya, p mencapai 10^{-13} . Bahwa uji pada tingkat berikutnya memberi $p = 0,21$ dan $p = 0,64$ bukan sekadar ketiadaan daya — ia

perbedaan lima sampai dua belas orde besaran pada data yang sama.

4.5. Tingkat 6: Ketahanan di Luar Jendela Seleksi

Seluruh angka Tingkat 4–5 dihitung pada jendela yang sama dengan yang dipakai sistem untuk menyaring ekspresi. Pembaca berhak menuntut bukti bahwa yang diukur bukan kecocokan kebetulan. Tabel 4.4 melaporkan hasil penilaian ulang korpus yang sama pada jendela holdout.


Tabel 4.4 Ketahanan dan keragaman sinyal korpus faktor.

Ukuran	Nilai
Ekspresi berpasangan seleksi–holdout	1053
Berbalik tanda IC	332 (31,5%)
Signifikan di seleksi	636
Tetap signifikan di holdout	156 (24,5%)
Ekspresi dengan deret IC harian	1003
Sinyal efektif n_{eff} (rasio partisipasi)	36,6
Rasio n_{eff} per ekspresi	0,037
Klaster pautan tunggal ($ \rho > 0,7$)	344
Ukuran klaster terbesar	510
Rerata $ IC $ tahun 2021 (247 hari)	0,0140
Rerata $ IC $ tahun 2022 (246 hari)	0,0112
Rerata $ IC $ tahun 2023 (239 hari)	0,0095
Rerata $ IC $ tahun 2024 (237 hari)	0,0144
Rerata $ IC $ tahun 2025 (234 hari)	0,0111

Dua angka penting. Pertama, **31,5%** ekspresi berbalik tanda IC antara kedua jendela (332 dari 1 053 ekspresi berpasangan). Sinyal yang murni derau akan berbalik tanda pada sekitar 50% kasus; angka 31,5% karena itu menunjukkan arah sinyal bertahan pada mayoritas ekspresi. Kedua, dari 636 ekspresi yang signifikan pada jendela seleksi, **156** atau 24,5% tetap signifikan pada jendela holdout. Bila seluruh signifikansi jendela seleksi murni kebetulan, tingkat pengulangan yang diharapkan pada jendela bebas hanyalah taraf uji itu sendiri, yaitu 5%. Angka 24,5% adalah sekitar lima kali lipatnya.

Gambar 4.3 menampilkan hubungan IC kedua jendela per ekspresi.

Perlu dicatat bahwa laju berbalik tanda tidak berbeda secara mencolok antar-formulasi. Ini konsisten dengan temuan Tingkat 5: yang dibedakan formulasi langka laten adalah validitas keluaran, bukan sifat sinyalnya.



Gambar 4.3 Ketahanan sinyal. Panel (a): IC jendela holdout terhadap IC jendela seleksi per ekspresi; titik pada kuadran satu dan tiga mempertahankan tanda. Panel (b): laju berbalik tanda per formulasi, dengan garis putus-putus menandai 50% yang diharapkan dari sinyal acak.

4.6. Efisiensi Kanal Laten

Hipotesis H2 menyangkut biaya. Angkanya sudah ada pada Tabel 4.1 dan dapat dibaca langsung dengan membandingkan medium pada formulasi yang sama.

Baseline teks penuh (`text`) memakai 2 436 token keluaran dan 181 detik per jalan. Sel `kv` terbaik (`kv_soft`) memakai 481 token dan 51 detik — yaitu **penghematan 80,3% token dan percepatan 3,5 kali** — dengan laju lolos *gate* yang identik, 100% pada keduanya.


H2 diterima. Penghematan itu tidak dibayar dengan penurunan keandalan.

Gambar 4.4 menempatkan seluruh sel pada bidang biaya–keandalan. Perhatikan posisi `kv_raw`: ia berada di kuadran terburuk, yaitu lebih mahal daripada seluruh sel `kv` lain *dan* paling tidak andal. Ini menutup kemungkinan pembacaan bahwa `raw` sekadar menukar keandalan dengan biaya.

4.7. Lengan Penalaran Umum

Lengan kedua menguji apakah temuan di atas bersifat umum atau khusus untuk muatan simbolik. Tabel 4.5 melaporkan akurasi ketiga tolok ukur.

Pembacaan per kolom memperlihatkan pola yang tidak dapat dijelaskan oleh “formulasi $\mathcal{R}$ lebih baik secara umum”. Pada ARC-Challenge, `raw/kv` men-



Gambar 4.4 Biaya token per jalan terhadap laju lolos *gate* per jalan. Bentuk penanda menyatakan medium, warna menyatakan formulasi.

Tabel 4.5 Lengan penalaran umum: akurasi pada 100 butir per tolok ukur (*seed* sampel identik antar-sel, diverifikasi lewat *fingerprint* data). Kolom waktu adalah total detik untuk 100 butir. Perhatikan pola kolomnya: selisih raw/kv terhadap keluarga $\mathcal{R}$ kecil pada ARC-C, sedang pada GSM8K, dan besar pada HumanEval+.

Sel	ARC-C	GSM8K	HumanEval+	Detik/100 butir
raw tanpa agen (garis dasar)	0,91	0,92	0,72	1561
raw / teks	0,93	0,90	0,76	6480
raw / kv	0,89	0,83	0,42	1938
soft / kv	0,94	0,88	0,69	1330
gumbel / kv	0,91	0,91	0,71	1966
sample / kv	0,94	0,86	0,74	1404
moi / kv	0,91	0,92	0,72	1508

capai 0,89 sementara keluarga $\mathcal{R}$ berkisar 0,91–0,94 — selisih beberapa butir soal. Pada GSM8K, 0,83 berbanding 0,86–0,92. Pada HumanEval+, `raw/kv` jatuh ke **0,42** sementara keluarga $\mathcal{R}$ bertahan di 0,69–0,74.

Tabel 4.6 menguji pola itu secara formal dengan uji McNemar eksak pada rancangan berpasangan butir demi butir.

Tabel 4.6 Gradien efek pada lengan penalaran umum: nilai- p uji McNemar eksak `raw/kv` melawan tiap anggota keluarga $\mathcal{R}$ pada medium `kv`, 100 butir per tolak ukur. Baca tabel ini per BARIS: efeknya tak terdeteksi pada penalaran berbasis pengetahuan, marginal pada penalaran aritmetika bertingkat, dan sangat kuat pada sintesis program — satu-satunya tolak ukur yang menuntut kesetiaan simbol.

Tolak ukur	<code>soft</code>	<code>gumbel</code>	<code>sample</code>	<code>moi</code>
ARC-C	0,125	0,727	0,062	0,688
GSM8K	0,383	0,077	0,648	0,049
HumanEval+	$3,47 \times 10^{-6}$	$1,08 \times 10^{-6}$	$1,94 \times 10^{-8}$	$6,94 \times 10^{-8}$

Nilai- p turun berorde-orde dari atas ke bawah. Pada ARC-Challenge, tidak satu pun dari empat kontras signifikan. Pada GSM8K, hanya satu yang menyentuh batas ($p = 0,049$). Pada HumanEval+, **keempatnya** signifikan dengan p antara $1,9 \times 10^{-8}$ dan $3,5 \times 10^{-6}$.

4.7.1. Bukti bahwa yang rusak adalah kanalnya, bukan modelnya

Satu perbandingan tambahan menutup tafsir alternatif. Formulasi `raw` yang sama, dengan model yang sama dan jumlah langkah laten yang sama, mencapai **0,76** pada HumanEval+ ketika mediumnya `text` — berbanding 0,42 ketika mediumnya `kv`. Uji McNemar atas pasangan itu memberi $p = 3,1 \times 10^{-7}$.

Artinya penurunan pada `raw/kv` bukan karena modelnya kurang mampu menulis program, melainkan karena *muatan simboliknya rusak saat melewati kanal laten*. Ketika muatan yang sama dilewatkan sebagai teks, kemampuan itu kembali utuh.

4.7.2. Sintesis kedua lengan

Kedua lengan menunjuk ke kesimpulan yang sama dari dua arah yang berbeda:

1. Pada tugas yang menuntut *kesetiaan simbol* — sintesis program pada lengan pertama, penulisan ekspresi DSL pada lengan kedua — formulasi `raw` gagal jauh lebih sering, dengan p mencapai 10^{-13} .
2. Pada tugas yang menuntut *penalaran tanpa keluaran simbolik ketat* — ARC-Challenge, GSM8K — selisihnya kecil dan sebagian besar tidak signifikan.
3. Pada dimensi *mutu* keluaran yang berhasil — $|IC|$ pada lengan faktor — tidak ada perbedaan sama sekali ($p = 0,21$ dan $p = 0,64$).

Ketiganya bersama membentuk jawaban atas pertanyaan penelitian yang dirumuskan Bab I: keunggulan keluarga relaksasi diskret **bukan** perbaikan umum atas kemampuan penalaran, melainkan perbaikan spesifik atas *kemampuan kanal laten membawa simbol*.

4.8. Bentuk Hubungan Geometri–Kinerja

Hipotesis H4 menyangkut bentuk, bukan arah. Sumbu interpolasi Persamaan (3.1) menyediakan tiga titik antara di antara `raw` ($\alpha = 0$) dan `soft` ($\alpha = 1$).

Laju lolos *gate* per jalan sepanjang sumbu itu adalah: 50% pada $\alpha = 0$, **55%** pada $\alpha = 0,25$, 100% pada $\alpha = 0,50$, 100% pada $\alpha = 0,75$, dan 100% pada $\alpha = 1$.

Bentuknya karena itu adalah **fungsi tangga berambang**, bukan tanjakan bertahap. Seperempat perjalanan pertama dari `raw` ke `soft` hampir tidak memberi perbaikan apa pun (50% $\rightarrow$ 55%); lompatan berikutnya, dari $\alpha = 0,25$ ke $\alpha = 0,50$, memuat hampir seluruh rentang efeknya (55% $\rightarrow$ 100%). **H4 diterima.**

Temuan ini memiliki konsekuensi tafsir yang penting. Bila hubungannya monoton bertahap, orang dapat menyimpulkan “semakin dekat ke *convex hull* semakin baik”, dan pertanyaannya menjadi soal derajat. Karena hubungannya berambang, kesimpulannya berbeda: yang menentukan adalah apakah representasi laten berada *di dalam atau di luar* wilayah tempat token dapat dikenali kembali. Ini menguatkan Teorema 2.4.1 sebagai kriteria kualitatif, bukan sekadar ukuran kuantitatif.

4.9. Metrik Portofolio

Tabel 4.7 melaporkan metrik portofolio kuintil pada jendela seleksi.

Tabel 4.7 Metrik portofolio *long-short* kuintil (7 emiten per sisi), jendela seleksi 2021, median lintas-ekspresi per sel. Angka bersifat DESKRIPTIF: pada universe 37 emiten galat baku imbal hasil tahunan mencapai 19,9 poin persen (Persamaan (3.3)), sehingga tabel ini tidak dipakai menyimpulkan formulasi mana yang unggul.

Medium	Formulasi	Sharpe	Imbal tahunan	<i>Max DD</i>	Perputaran	<i>Hit rate</i>
teks	—	-0,05	-0,011	-0,269	0,427	0,498
kv	raw	-0,19	-0,044	-0,277	0,845	0,490
kv	soft	-0,16	-0,040	-0,300	0,448	0,486
kv	gumbel	0,00	0,000	-0,252	0,453	0,496
kv	sample	-0,06	-0,017	-0,282	0,408	0,494
kv	moi	-0,25	-0,055	-0,272	0,451	0,494
kv	mix $\alpha=0,50$	-0,15	-0,038	-0,270	0,636	0,498
kv	mix $\alpha=0,25$	-0,10	-0,029	-0,300	0,495	0,490
kv	mix $\alpha=0,75$	-0,24	-0,058	-0,278	0,523	0,494
kv+teks	raw	0,07	0,018	-0,263	0,729	0,494
kv+teks	soft	0,21	0,061	-0,258	0,675	0,498
kv+teks	gumbel	-0,12	-0,031	-0,279	0,739	0,494
kv+teks	sample	0,19	0,048	-0,234	0,613	0,502
kv+teks	moi	-0,33	-0,083	-0,304	0,716	0,486

Median rasio Sharpe seluruh sel berkisar $-0,33$ sampai $+0,23$, yaitu berpusat di sekitar nol tanpa satu formulasi pun terpisah dari yang lain. Ini konsisten dengan temuan Tingkat 5 dan tidak menambah informasi baru, tetapi perlu dilaporkan karena skripsi ini menjanjikan metrik hasil *backtest*.

Interpretasinya harus dibatasi secara tegas. Dengan tujuh emiten per sisi dan $\sigma = 2,42\%$ per hari, galat baku imbal hasil tahunan mencapai 19,9 poin persen (Persamaan (3.3)). Selisih Sharpe antar-sel pada tabel jauh lebih kecil daripada ketidakpastian itu. Karena itu tabel ini bersifat deskriptif: ia memperlihatkan besaran perputaran portofolio dan penurunan maksimum yang menyertai sinyal-sinyal ini, bukan memutuskan formulasi mana yang unggul.

Perputaran portofolio yang tercatat berkisar $0,41$ – $0,85$ per hari. Pada tingkat itu, biaya transaksi satu arah sebesar 20 basis poin akan menimbulkan hambatan sekitar $0,56 \times 2 \times 20 \text{ bp} \times 241 \approx 54$ poin persen per tahun pada perputaran median — jauh melampaui seluruh imbal hasil yang tercatat. Fakta ini dilaporkan terbuka, dan merupakan alasan tambahan mengapa kesimpulan penelitian ini tidak disandarkan

pada metrik portofolio.

4.10. Lantai Acak: Apakah Sistemnya Mengalahkan Penarikan Acak?

Seluruh Bab IV sampai titik ini membandingkan lima formulasi *satu sama lain*. Pertanyaan yang belum dijawab, dan yang wajib dijawab agar angka-angka di atas punya makna absolut, adalah: apakah salah satu di antaranya lebih baik daripada tidak memakai model bahasa sama sekali?

Pembandingnya dibangun langsung dari tata bahasa DSL. Enam ratus ekspresi ditarik acak dengan kedalaman 1–3, memakai daftar fungsi, rentang periode, dan enam *leaf* data yang sama persis dengan yang diberikan kepada agen. Ekspresi itu kemudian dilewatkan rangkaian *gate* yang sama dan dinilai oleh Lab yang sama pada jendela yang sama. Satu-satunya yang berbeda adalah asal ekspresinya.

Tabel 4.8 Sistem melawan LANTAI ACAK: 600 ekspresi ditarik acak dari tata bahasa DSL yang sama, dilewatkan rangkaian *gate* yang sama, dan dinilai pada jendela yang sama. Kolom kiri menguji VALIDITAS (uji eksak Fisher), kolom kanan menguji MUTU SINYAL (uji Mann–Whitney atas sebaran $|IC|$). Perbedaan kesimpulan antara kedua kolom adalah temuan tersendiri.

Sumber ekspresi	Lolos <i>gate</i>	Selisih	Fisher p	Median $ IC $	M–W p
penarikan acak	346/600 = 57,7%	—	—	0,0102	—
keluarga $\mathcal{R}$ (kv)	372/438 = 84,9%	27,3 pp	$8,85 \times 10^{-22}$	0,0103	0,073
raw (kv)	27/59 = 45,8%	-11,9 pp	0,098	0,0076	0,537
text	94/120 = 78,3%	20,7 pp	$1,48 \times 10^{-5}$	0,0084	0,469

Hasilnya memisah dengan tajam menurut sumbu yang diuji, dan pemisahan itu sendiri adalah temuan.

4.10.1. Pada validitas, sistemnya menang telak

Keluarga $\mathcal{R}$ meloloskan 84,9% ekspresinya melawan 57,7% untuk penarikan acak — selisih 27,3 poin persen dengan $p = 8,9 \times 10^{-22}$ dan h Cohen = 0,62. Medium teks penuh juga menang, 78,3% dengan $p = 1,5 \times 10^{-5}$. Rantai agen jelas mengerjakan sesuatu yang nyata: ia menuliskan ekspresi yang sah jauh lebih sering daripada penarikan acak dari tata bahasa yang sama.

4.10.2. **raw tidak mengalahkan penarikan acak**

Formulasi *raw* meloloskan 45,8% ekspresinya — **11,9 poin persen di bawah** penarikan acak, dengan $p = 0,098$. Selisih itu tidak signifikan, sehingga pernyataan yang sah adalah bahwa *raw tidak dapat dibedakan dari penarikan acak*, dengan arah efek yang negatif.

Ini pernyataan yang jauh lebih tajam daripada “*raw* lebih buruk dari $\mathcal{R}$ ”. Seluruh rantai tiga agen, sepuluh langkah laten per agen, dan seluruh biaya komputasinya, ketika langkah latennya memakai proyeksi ridge, menghasilkan ekspresi sah tidak lebih sering daripada menarik simbol secara acak dari tata bahasanya.

4.10.3. **Pada mutu sinyal, tidak ada yang mengalahkan penarikan acak**

Kolom terakhir Tabel 4.8 adalah temuan yang paling membatasi seluruh penelitian ini, dan justru karena itu harus dilaporkan paling jelas. Median $|IC|$ ekspresi acak adalah 0,0102. Keluarga $\mathcal{R}$ mencapai 0,0103 ($p = 0,073$), *raw* 0,0076 ($p = 0,537$), dan medium teks 0,0084 ($p = 0,469$).

Tidak satu pun sumber ekspresi berbasis model bahasa menghasilkan sinyal yang lebih baik daripada penarikan acak dari tata bahasa DSL.

Tafsirnya harus hati-hati dan tidak boleh dilebihkan ke dua arah. Ini *bukan* berarti model bahasanya tidak berguna: pada sumbu validitas ia menang dengan $p = 10^{-22}$, dan pada tugas penalaran umum ia jelas jauh di atas kebetulan. Yang ditunjukkan tabel ini adalah bahwa *pada ranah pencarian faktor alpha dengan rancangan single-pass ini*, kemampuan yang terbukti dimiliki sistem adalah menuliskan ekspresi yang sah, bukan memilih ekspresi yang prediktif.

Temuan ini menyatu dengan disosiasi Tingkat 5 dan membentuk satu gambaran yang konsisten pada tiga sumbu sekaligus:

1. **Validitas** — formulasi berpengaruh besar ($p = 10^{-7}$ sampai 10^{-13}), dan sistem mengalahkan acak ($p = 10^{-22}$).
2. **Mutu sinyal** — formulasi tidak berpengaruh ($p = 0,21$; $p = 0,64$), dan sistem tidak mengalahkan acak ($p = 0,07$).

3. **Keragaman sinyal** — formulasi tidak berpengaruh (Subbab berikut, seluruh sel berada dalam satu simpangan baku).

Ketiganya menunjuk ke satu kesimpulan: yang diperbaiki proyeksi *convex hull* adalah *kemampuan kanal menuliskan simbol*, dan hanya itu.

4.11. Keragaman Sinyal: Berapa Banyak Faktor yang Benar-Benar Berbeda

Jumlah ekspresi bukan ukuran keragaman. Dua ekspresi dengan teks yang sangat berbeda dapat menghasilkan deret IC harian yang hampir identik, dan karenanya membawa satu sinyal yang sama. Untuk mengukurnya, korpus dinilai ulang pada jendela penuh 2021–2025 dengan deret IC harian per ekspresi disimpan, lalu dihitung *rasio partisipasi* dari spektrum matriks korelasinya:

$$n_{\text{eff}} = \frac{(\sum_i \lambda_i)^2}{\sum_i \lambda_i^2}, \quad (4.1)$$

dengan λ_i nilai eigen matriks korelasi antar-deret IC. Besaran ini bernilai 1 bila seluruh ekspresi membawa satu sinyal yang sama dan n bila seluruhnya saling ortogonal.

Hasilnya tegas: dari **1 003** ekspresi dengan deret IC harian, $n_{\text{eff}} = \mathbf{36,6}$ — yaitu hanya **3,7%**. Seribu ekspresi yang berbeda secara tekstual ternyata membawa kurang dari empat puluh sinyal yang benar-benar berbeda.

Temuan ini penting dilaporkan justru karena tidak menguntungkan narasi penelitian. Ia membatasi tafsir seluruh Bab IV: sistem ini menghasilkan banyak ekspresi, tetapi tidak menghasilkan banyak *ide*.

4.11.1. Apakah keluarga $\mathcal{R}$ juga lebih beragam?

Pertanyaan lanjutannya wajar: mungkin keunggulan keluarga $\mathcal{R}$ bukan hanya soal validitas, melainkan juga keragaman. Perbandingan naifnya menyesatkan. Rasio n_{eff}/n menurun secara mekanis seiring bertambahnya n , dan sel `raw` justru memiliki jauh lebih sedikit ekspresi — konsekuensi langsung temuan Tingkat 2. Karena itu rasio mentahnya tampak paling tinggi untuk `raw` (0,579 berbanding

0,22–0,28 untuk sel lain), yang akan salah terbaca sebagai “raw lebih beragam”.

Perbandingan yang sah menyamakan n lebih dahulu. Setiap sel disubsampel ke $n = 17$, yaitu ukuran sel terkecil, sebanyak 200 ulangan, lalu n_{eff} -nya dirata-rata. Hasilnya seluruh sel berada pada rentang **9,8 sampai 12,3**, dengan kv_{raw} pada 11,94 — tepat di tengah, dan seluruh selisihnya berada dalam satu simpangan baku subsampel ($\approx 1,3$).

Tidak ada perbedaan keragaman sinyal antar-formulasi. Ini konfirmasi ketiga atas disosiasi Tingkat 5: keluarga $\mathcal{R}$ menghasilkan lebih banyak ekspresi yang sah, dengan mutu sinyal yang sama dan keragaman sinyal yang sama.

4.12. Peluruhan Sinyal Antar-Tahun

Kekhawatiran yang wajar terhadap seluruh penelitian pencarian faktor adalah bahwa sinyal yang terlihat hanyalah kecocokan terhadap satu periode. Bila demikian, $|IC|$ seharusnya tinggi pada tahun seleksi lalu meluruh pada tahun-tahun sesudahnya.

Tabel 4.4 melaporkan rerata $|IC|$ per tahun kalender atas seluruh korpus. Polanya *tidak* meluruh: 0,0140 pada 2021 (tahun seleksi), 0,0112 pada 2022, 0,0095 pada 2023, **0,0144** pada 2024 — lebih tinggi daripada tahun seleksi — dan 0,0111 pada 2025.

Fluktuasi antar-tahun jelas ada, tetapi tidak berbentuk peluruhan monoton dari tahun seleksi. Tafsir yang paling sederhana adalah bahwa besaran $|IC|$ lebih ditentukan oleh keadaan pasar tiap tahun daripada oleh kedekatan tahun itu ke jendela seleksi. Ini melengkapi temuan Tingkat 6: bukan hanya tanda IC yang bertahan, besarannya pun tidak runtuh.

4.13. Keberpindahan Keputusan *Gate* Antar-Pasar

Satu keberatan metodologis perlu ditutup. Laju lolos *gate* pada Tabel 4.1 diukur *saat generasi*, dan tahap eksekusi pada rangkaian *gate* waktu itu memakai sampel pasar A-share. Apakah angka itu masih berlaku setelah penelitian berpindah ke pasar Indonesia?

Pengujiannya langsung: jalankan rangkaian *gate* yang sama — ketujuh tahapnya, bukan hanya tahap eksekusi — pada panel LQ45, lalu bandingkan keputusannya dengan yang tercatat.

Tabel 4.9 Uji keberpindahan keputusan *gate* antar-pasar. *Gate* eksekusi saat generasi memakai sampel pasar A-share; tabel ini menjalankan *gate* yang sama pada panel LQ45 dan membandingkan keputusannya. Kesesuaian tinggi berarti angka lolos *gate* pada Tabel 4.1 tidak bergantung pasar.

Ukuran	Nilai
Ekspresi diperiksa	1428
Keputusan sama	1269
Keputusan berbeda	159
Kesesuaian	88,87%

Kesesuaiannya sangat tinggi. Hal ini tidak mengejutkan bila diingat bahwa enam dari tujuh tahap *gate* bersifat struktural dan tidak menyentuh data pasar sama sekali; satu-satunya tahap yang dapat berbeda adalah eksekusi, dan ekspresi yang menghasilkan kolom hidup pada satu panel harga-volume umumnya juga hidup pada panel lain dengan skema kolom yang sama.

Perlu dicatat bahwa versi pertama pengujian ini keliru: ia membandingkan *tahap eksekusi saja* pada IDX melawan keluaran *rangkaian penuh* pada A-share. Perbandingan itu tidak setara — tahap eksekusi sendirian jauh lebih permisif — dan menghasilkan ketidaksesuaian semu yang didominasi arah “gagal di A-share, lolos di IDX”. Angka yang dilaporkan di sini berasal dari perbandingan rangkaian penuh melawan rangkaian penuh.

4.14. Rangkuman Pengujian Hipotesis

Perhatikan bahwa H1 dan H3 dinilai pada *korpus ekspresi yang sama persis* dengan *uji pada data yang sama*. Perbedaan nilai-*p* sebesar lima sampai dua belas orde besaran antara keduanya karena itu bukan artefak perbedaan sampel, melainkan struktur temuan itu sendiri.

Tabel 4.10 Rangkuman putusan atas keempat hipotesis penelitian.

Hipotesis	Ukuran	Hasil	Putusan
H1 validitas	lolos <i>gate</i> /jalan, kv	97,5% vs 50,0%	diterima ($p = 5,7 \times 10^{-7}$)
	lolos <i>gate</i> /jalan, kv+teks	100% vs 30,0%	diterima ($p = 8,8 \times 10^{-13}$)
	ekspresi hidup, kv	89,4% vs 48,3%	diterima ($p = 3,0 \times 10^{-12}$)
H2 efisiensi	token/jalan, kv vs teks	481 vs 2 436	diterima ($-80,3\%$)
	detik/jalan, kv vs teks	51 vs 181	diterima ($3,5\times$)
H3 mutu sinyal	median $ IC $, kv	0,0103 vs 0,0076	tidak ditolak ($p = 0,21$)
	median $ IC $, kv+teks	0,0111 vs 0,0129	tidak ditolak ($p = 0,64$)
H4 bentuk	lolos <i>gate</i> sepanjang α	50, 55, 100, 100, 100%	diterima (tangga)
<i>Pembandingan rantai acak (bukan hipotesis a priori):</i>			
—	lolos <i>gate</i> , $\mathcal{R}$ vs acak	84,9% vs 57,7%	unggul ($p = 8,9 \times 10^{-22}$)
—	lolos <i>gate</i> , r_{aw} vs acak	45,8% vs 57,7%	tak berbeda ($p = 0,098$)
—	median $ IC $, $\mathcal{R}$ vs acak	0,0103 vs 0,0102	tak berbeda ($p = 0,073$)

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

5.1.1. Jawaban atas rumusan masalah

Rumusan 1 — penurunan dan kriteria pemisah. Kelima formulasi langkah laten dapat diturunkan dari satu bentuk umum. Empat di antaranya, yaitu keluarga relaksasi diskret $\mathcal{R}$, membentuk vektor melalui $z = w^\top W_{\text{in}}$ dengan w berada pada simpleks peluang, sehingga menurut Teorema 2.4.1 hasilnya selalu berada di dalam *convex hull* embedding token nyata. Formulasi resmi LatentMAS memakai proyeksi ridge hM dan tidak memiliki jaminan itu. Keanggotaan *convex hull* karena itu merupakan kriteria kualitatif yang memisahkan keduanya, dan bukan sekadar perbedaan derajat.

Rumusan 2 — validitas. Keluarga $\mathcal{R}$ menghasilkan keluaran yang jauh lebih sering sah. Pada medium `kv`, 97,5% jalan menghasilkan ekspresi yang lolos *gate*, berbanding 50,0% untuk `raw` ($p = 5,7 \times 10^{-7}$, h Cohen = 1,25). Pada medium `kv_and_text`, 100% berbanding 30,0% ($p = 8,8 \times 10^{-13}$). Keunggulan itu bertahan ketika ekspresi dijalankan pada data pasar Indonesia: 89,4% berbanding 48,3% ekspresi hidup ($p = 3,0 \times 10^{-12}$).

Rumusan 3 — mutu sinyal. Keunggulan tersebut *tidak* berlanjut ke mutu sinyal. Sebaran $|IC|$ ekspresi yang berhasil tidak berbeda antara keluarga $\mathcal{R}$ dan `raw`, baik pada jendela seleksi ($p = 0,21$ untuk `kv`, $p = 0,64$ untuk `kv_and_text`) maupun pada jendela holdout, dengan ukuran efek kecil dan arah yang tidak konsisten.

Rumusan 4 — efisiensi. Kanal laten murni memangkas 80,3% token keluaran dan mempercepat 3,5 kali dibanding baseline teks penuh, dengan laju lolos *gate* yang identik.

Rumusan 5 — bentuk hubungan. Hubungan geometri–kinerja berbentuk fungsi tangga berambang: 50%, 55%, 100%, 100%, 100% sepanjang $\alpha = 0; 0,25; 0,5; 0,75; 1$.

Temuan tambahan — rantai acak. Enam ratus ekspresi yang ditarik acak dari tata bahasa DSL yang sama meloloskan *gate* 57,7%. Keluarga $\mathcal{R}$ mengalahkannya telak (84,9%, $p = 8,9 \times 10^{-22}$), sedangkan *raw* tidak dapat dibedakan darinya (45,8%, $p = 0,098$, arah negatif). Pada sumbu mutu sinyal, tidak satu pun sumber berbasis model bahasa mengalahkan penarikan acak ($p = 0,073$ untuk $\mathcal{R}$; $p = 0,47$ untuk medium teks).

5.1.2. Kontribusi utama

Kontribusi penelitian ini adalah sebuah **disosiasi** yang terukur:

Proyeksi langkah laten ke dalam *convex hull* embedding token nyata memperbaiki *validitas* keluaran secara sangat besar, tetapi tidak memperbaiki *mutu* keluaran yang berhasil dihasilkan. Yang diperbaiki adalah kemampuan kanal laten membawa **simbol**, bukan kemampuannya membawa **gagasan**.

Disosiasi ini didukung dari dua arah yang saling bebas. Dari lengan faktor, selisih validitas mencapai $p = 10^{-13}$ sementara selisih mutu sinyal memberi $p = 0,21$ pada korpus yang sama. Dari lengan penalaran umum, nilai- p kontras *raw* melawan keluarga $\mathcal{R}$ turun berorde-orde seiring meningkatnya tuntutan kesetiaan simbol tugas: tidak signifikan pada ARC-Challenge, marginal pada GSM8K, dan 10^{-8} pada HumanEval+.

Konfirmasi ketiga datang dari rantai acak. Pada sumbu validitas, sistem mengalahkan penarikan acak dengan $p = 10^{-22}$; pada sumbu mutu sinyal, ia tidak mengalahkannya sama sekali. Dan dari sumbu keragaman, setelah n disamakan lewat subsampel, seluruh formulasi memberi jumlah sinyal efektif yang sama dalam satu simpangan baku. Tiga sumbu, tiga pengukuran bebas, satu kesimpulan yang sama.

Temuan ini mengoreksi cara membaca LatentMAS. Kegagalan formulasi ri-

dge bukan kegagalan penalaran laten sebagai gagasan, melainkan kegagalan spesifik pada tahap penulisan kembali muatan simbolik — dan tahap itu dapat diperbaiki tanpa pelatihan ulang, hanya dengan mengganti satu persamaan.

5.1.3. Implikasi praktis

Bagi perancang sistem *multi-agent*, dua implikasi langsung. Pertama, komunikasi antar-agen melalui *key-value cache* layak dipakai: ia memangkas biaya token sekitar 80% tanpa menurunkan keandalan, asalkan formulasi langkah latennya berasal dari keluarga relaksasi diskret. Kedua, pemilihan anggota keluarga itu tidak kritis — *soft*, *gumbel*, *sample*, dan *moi* tidak berbeda satu sama lain pada seluruh pengujian — sehingga pilihan dapat didasarkan pada biaya implementasi.

5.2. Keterbatasan

Keterbatasan berikut dinyatakan terbuka karena masing-masing membatasi generalisasi kesimpulan.

Satu model, satu ukuran. Seluruh hasil berasal dari Qwen3-8B. Sifat yang membuat penelitian ini mungkin — embedding masukan dan keluaran yang tidak *tied* — tidak dimiliki semua model. Pada model dengan embedding *tied*, $M \approx I$ dan seluruh kontras yang diukur di sini akan mengecil atau hilang. Kesimpulan ini karena itu berlaku untuk kelas model yang embedding-nya terpisah, dan generalisasinya ke kelas lain belum diuji.

Universe sempit. Universe 37 emiten menaikkan ambang deteksi $|IC|$ menjadi 0,0208 pada jendela seleksi, sekitar sebelas kali lebih tinggi daripada yang akan berlaku pada universe beberapa ribu saham. Konsekuensinya, uji Tingkat 5 memiliki daya yang lebih rendah daripada yang mungkin dicapai pada pasar yang lebih lebar. Tidak ditolaknya H3 karena itu harus dibaca sebagai ketiadaan bukti perbedaan pada daya yang tersedia, bukan sebagai bukti kesetaraan.

Survivorship bias. Keanggotaan LQ45 yang dipakai adalah keanggotaan pada saat data diambil, bukan keanggotaan historis tiap periode. Emiten yang keluar dari indeks sebelum tanggal pengambilan tidak pernah masuk universe. Bias ini

menaikkan tingkat imbal hasil absolut portofolio, tetapi tidak memihak formulasi tertentu karena seluruh formulasi dinilai pada universe yang sama persis.

Metrik portofolio kasar. Simulasi tidak memodelkan *slippage*, batas likuiditas, aturan suspensi, maupun batas auto-reject. Biaya transaksi ditetapkan nol; pada perputaran median yang tercatat, biaya realistis akan melampaui seluruh imbal hasil yang terukur.

Mutu sinyal tidak melampaui penarikan acak. Ini keterbatasan yang paling membatasi klaim praktis penelitian ini, dan sudah dinyatakan pada Subbab 4.10.. Pada ranah pencarian faktor dengan rancangan *single-pass* ini, kemampuan sistem yang terbukti adalah menuliskan ekspresi yang sah, bukan memilih ekspresi yang prediktif. Perlu ditegaskan bahwa keterbatasan ini *tidak* membatalkan temuan utama: disosiasi yang menjadi kontribusi skripsi ini justru bekerja pada sumbu validitas, yaitu satu- satunya sumbu tempat sistem memang mengungguli rantai acak.

Keragaman sinyal rendah. Dari 1 003 ekspresi dengan deret IC harian, jumlah sinyal efektif hanya 36,6 atau 3,7%. Korpus yang tampak besar secara tekstual jauh lebih kecil secara statistik.

Tanpa loop evolusi. Rancangan bersifat *single-pass*. Sistem pencarian faktor produksi umumnya menjalankan banyak putaran dengan umpan balik; hasil penelitian ini tidak dapat langsung dipindahkan ke rancangan semacam itu.

Sel kv_and_text pada lengan penalaran umum. Sel-sel itu hanya dijalankan pada 5 butir soal, jumlah yang secara aritmetika tidak dapat mencapai signifikansi berapa pun besar efeknya. Angkanya dilaporkan pada lampiran sebagai catatan, bukan sebagai bukti.

5.3. Saran

Untuk penelitian lanjutan. Nol, dan paling mendesak: hasil rantai acak menunjukkan bahwa mekanisme yang perlu diperbaiki bukan lagi kanal komunikasinya melainkan *seleksinya*. Rancangan *single-pass* tidak memberi sistem umpan balik apa pun tentang mutu ekspresi yang dihasilkannya, sehingga tidak ada jalan baginya untuk mengungguli penarikan acak pada sumbu itu. Menambahkan satu

putaran umpan balik berbasis IC pada jendela latih yang terpisah adalah eksperimen paling langsung untuk mengujinya. Pertama, pengujian ulang pada model dengan embedding *tied* akan menguji langsung mekanisme yang diusulkan: bila disosiasi ini benar disebabkan jarak ke *convex hull*, maka pada model *tied* ia harus menghilang. Kedua, sumbu interpolasi dapat diperhalus di sekitar $\alpha \in (0,25; 0,50)$ untuk melokalisasi ambangnya, karena seluruh efek terjadi pada rentang itu. Ketiga, universe yang lebih lebar akan menaikkan daya uji Tingkat 5 dan memungkinkan H3 diuji dengan daya yang memadai.

Untuk perancangan sistem. Formulasi langkah laten sebaiknya diperlakukan sebagai keputusan rancangan yang berdiri sendiri, bukan sebagai detail implementasi yang diwarisi dari pustaka. Perbedaan antara memilih `raw` dan memilih anggota keluarga $\mathcal{R}$ pada penelitian ini setara dengan perbedaan antara sistem yang gagal separuh waktu dan sistem yang hampir tidak pernah gagal — dengan biaya komputasi yang justru lebih rendah.

DAFTAR PUSTAKA

- Ainslie, J., Lee-Thorp, J., de Jong, M., Zemlyanskiy, Y., Lebrón, F., & Sanghai, S. (2023). GQA: Training generalized multi-query transformer models from multi-head checkpoints. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 4895–4901.
- Bain, L. J., & Engelhardt, M. (1992). *Introduction to Probability and Mathematical Statistics* (2nd ed.). Boston: PWS-KENT.
- Chen, X., dkk. (2025). *Reasoning beyond language: A comprehensive survey on latent chain-of-thought reasoning*. arXiv:2505.16782.
- Efron, B., & Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. New York: Chapman & Hall.
- Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- Finin, T., Fritzson, R., McKay, D., & McEntire, R. (1994). KQML as an agent communication language. *Proceedings of the 3rd International Conference on Information and Knowledge Management (CIKM)*, 456–463.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232.
- Fu, T., dkk. (2025). *Cache-to-Cache: Direct semantic communication between large language models*. arXiv:2510.03215.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. Cambridge: MIT Press.
- Grinold, R. C., & Kahn, R. N. (2000). *Active Portfolio Management: A Quantitative Approach for Producing Superior Returns and Controlling Risk* (2nd ed.). New York: McGraw-Hill.

- Guo, T., Chen, X., Wang, Y., Chang, R., Pei, S., Chawla, N. V., Wiest, O., & Zhang, X. (2024). *Large language model based multi-agents: A survey of progress and challenges*. arXiv:2402.01680.
- Han, J., Zhang, S., Li, W., Dong, Y., Hu, T., dkk. (2026). *QuantaAlpha: An Evolutionary Framework for LLM-Driven Alpha Mining*. arXiv:2602.07085.
- Hao, S., Sukhbaatar, S., Su, D., Li, X., Hu, Z., Weston, J., & Tian, Y. (2024). *Training large language models to reason in a continuous latent space*. arXiv:2412.06769.
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- Jensen, M. C. (1968). The performance of mutual funds in the period 1945–1964. *The Journal of Finance*, 23(2), 389–416.
- Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6th ed.). Upper Saddle River, NJ: Pearson Prentice Hall.
- Kakushadze, Z. (2016). 101 formulaic alphas. *Wilmott*, 2016(84), 72–81.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3149–3157.
- Kingma, D. P., & Welling, M. (2014). *Auto-encoding variational Bayes*. *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*. arXiv:1312.6114.
- Li, Y., Yang, X., Yang, X., Xu, M., Wang, X., Liu, W., & Bian, J. (2025). *R&D-Agent-Quant: A multi-agent framework for data-centric factors and model joint optimization*. arXiv:2505.15155.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.

- Zhuang, Y., Liu, S., Cheng, S., Zhang, Y., Wang, X., & Zhang, C. (2025). *Mixture of inputs: Text generation beyond discrete token sampling*. arXiv:2505.14827. Dipresentasikan pada *Advances in Neural Information Processing Systems* (NeurIPS 2025).
- Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). *Efficient estimation of word representations in vector space*. arXiv:1301.3781.
- Park, K., Choe, Y. J., & Veitch, V. (2024). *The linear representation hypothesis and the geometry of large language models*. Proceedings of the 41st International Conference on Machine Learning (ICML). arXiv:2311.03658.
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Hoboken, NJ: Pearson.
- Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442.
- Sharpe, W. F. (1994). The Sharpe ratio. *The Journal of Portfolio Management*, 21(1), 49–58.
- Spearman, C. (1904a). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1), 72–101.
- Spearman, C. (1904b). “General intelligence,” objectively determined and measured. *The American Journal of Psychology*, 15(2), 201–292.
- Su, J., Ahmed, M., Lu, Y., Pan, S., Bo, W., & Liu, Y. (2024). RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568, 127063.
- Tandelilin, E. (2010). *Portofolio dan Investasi: Teori dan Aplikasi* (Edisi Pertama). Yogyakarta: Kanisius.
- Tang, Z., Chen, Z., Yang, J., Mai, J., Zheng, Y., Wang, K., Chen, J., & Lin, L. (2025). *AlphaAgent: LLM-driven alpha mining with regularized exploration to counteract alpha decay*. arXiv:2502.16789.

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). *Attention is all you need*. *Advances in Neural Information Processing Systems*, 30.
- Wooldridge, M., & Jennings, N. R. (1995). Intelligent agents: Theory and practice. *The Knowledge Engineering Review*, 10(2), 115–152.
- Wooldridge, M. (2009). *An Introduction to MultiAgent Systems* (2nd ed.). Chichester: Wiley.
- Yang, X., Liu, W., Zhou, D., Bian, J., & Liu, T.-Y. (2020). *Qlib: An AI-oriented quantitative investment platform*. arXiv:2009.11189.
- Yang, A., dkk. (Qwen Team). (2025). *Qwen3 technical report*. arXiv:2505.09388.
- Yu, S., Xue, H., Ao, X., Pan, F., He, J., Tu, D., & He, Q. (2023). Generating synergistic formulaic alpha collections via reinforcement learning. *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (KDD '23).
- Zhang, Z., He, X., Yan, W., Shen, A., Zhao, C., Wang, S., Shen, Y., & Wang, X. E. (2025). *Soft thinking: Unlocking the reasoning potential of LLMs in continuous concept space*. arXiv:2505.15778.
- Zou, J., Qiu, R., Li, G., Yang, X., Tieu, K., Lu, P., Shen, K., Tong, H., Choi, Y., He, J., Zou, J., Wang, M., & Yang, L. (2025). *Latent collaboration in multi-agent systems*. arXiv:2511.20639.

LAMPIRAN A

MATRIKS SEL EKSPERIMEN

Lengan faktor menjalankan 14 sel, masing-masing 20 jalan ($5 \text{ seed} \times 4 \text{ arah}$), seluruhnya dengan rantai `proposal → innovate → construct` dan `max_repair = 3`. Rinciannya ada pada Tabel 4.1.

Lengan penalaran umum menjalankan 7 sel pada 100 butir per tolok ukur (Tabel 4.5), ditambah 5 sel `kv_and_text` yang hanya dijalankan pada 5 butir. Sel terakhir itu **tidak dipakai untuk kesimpulan apa pun**: pada $n = 5$ dengan efek sempurna, nilai- p dua sisi terkecil yang mungkin dari uji McNemar eksak adalah $2 \cdot (1/2)^5 = 0,0625$, sehingga sel tersebut tidak akan pernah signifikan. Angkanya dicatat di sini untuk kelengkapan: pada HumanEval+, `raw/kv+teks` mencapai 0,20 sementara `gumbel`, `sample`, dan `moi` mencapai 1,00 — arah yang sama dengan hasil $n = 100$, tetapi tanpa daya uji.

LAMPIRAN B

PARAMETER DAN ASALNYA

Daftar lengkap ada pada Tabel 3.1. Dua catatan tambahan.

Sapuan β pada m dan i . Enam nilai diuji, yaitu $\beta \in \{0,25; 0,5; 1; 2; 4; 8\}$. Tidak ditemukan pengaruh yang konsisten terhadap kapasitas kanal, sehingga nilai baku paper, $\beta = 1$, dipertahankan. Ini satu-satunya pencarian parameter dalam penelitian ini.

Parameter yang dipatok. Nilai $T = 0,7$, $m = 10$, dan $\lambda = 10^{-5}$ tidak pernah disetel terhadap hasil. Konsekuensinya, hasil penelitian ini tidak dapat dijelaskan sebagai akibat penyetelan yang menguntungkan formulasi tertentu. Konsekuensi lainnya, hasil ini juga bukan kinerja terbaik yang dapat dicapai tiap formulasi.

LAMPIRAN C

INDEKS FIGUR DAN KETERLACAKAN ANGKA

Setiap angka pada Bab IV berasal dari rantai empat lapis, dan lampiran ini mendaftarnya agar tiap tabel dapat ditelusuri kembali ke berkas keluaran eksperimen.

C.1. Rantai keterlacakan

1. **Keluaran mentah.** `results/factor/frontend<sel>.json` (generasi), `results/bench/*.json` (lengan penalaran umum), `results/probe/*.json` (geometri dan kapasitas kanal).
2. **Penilaian pasar.** `results/factor/holdout_daily_pv_idx.lq45-<jendela>q0.` —dibangkitkan `backend/eval/skor_holdout.py` dengan `LAB_PV_FILE` menunjuk panel LQ45.
3. **Agregasi.** `results/idx/analisis_idx.json` —dibangkitkan `scripts/analisis`. Seluruh tabel bab hasil berasal dari berkas tunggal ini, sehingga angka antar-tabel tidak dapat saling bertentangan.
4. **Tabel dan figur.** `scripts/tabel_idx.py` menulis `results/idx/tabel/*.tex`; `scripts/visual_idx.py` menulis `results/visual_idx/*.png`.

C.2. Figur yang dipakai bab hasil

C.3. Figur yang sengaja tidak dipakai

Beberapa figur yang tersedia pada repositori *tidak* dipakai bab hasil, dan alasannya dicatat agar tidak terbaca sebagai kelalaian.

- `v09, v12, v13, v14, v16` membaca medan `ic` dari `frontend*.json`, yang berisi angka pasar A-share. Setelah penelitian berpindah ke LQ45, figur-

Tabel C.1 Figur bab hasil dan sumber datanya.

Figur	Pertanyaan yang dijawab	Sumber
i01_disosiasi	Apakah validitas dan mutu berbeda arah?	analisis_idx.js
i02_sebaran_ic	Bagaimana sebaran $ IC $ vs ambang deteksi?	laporan IDX dua jende
i03_stabilitas	Apakah tanda IC bertahan di holdout?	laporan IDX holdout
i04_efisiensi	Bagaimana biaya token vs keandalan?	analisis_idx.js
v05_geometri_rentang	Seberapa dekat tiap formulasi ke embedding?	probe/b7_probe.*
v07_pencarian_beta_moi	Apakah $\beta = 1$ masuk akal?	probe/channel_c
v08_interpolasi_geometri	Bagaimana bentuk kurva sumbu mix?	probe + pendukung
v17_korupsi_cjk_posisi	Di mana aksara asing muncul?	bench/bench.*.kv
v21_statistik_latent_stop	Apakah <i>early-stop</i> menyala?	pendukung/agent
v24_biaya_percobaan	Berapa percobaan <i>construct</i> per jalan?	pendukung/fakto

figur itu tidak lagi konsisten dengan angka bab hasil dan digantikan i01–i04.

- *Factor lineage tree* tidak dibuat karena rancangan bersifat *single-pass*: tidak ada lintasan hipotesis $\rightarrow$ mutasi $\rightarrow$ umpan balik untuk digambar. Padanan yang benar-benar ada di data adalah v24, yaitu jumlah percobaan *construct* per jalan.
- “Degradasi *parse-rate* per hop” tidak dibuat karena metriknya cacat: hanya agen *construct* yang menulis keluaran terstruktur, sehingga *parsed_ok* agen *proposal* dan *innovate* selalu bernilai salah *menurut rancangan*, bukan karena kegagalan bertahap.

LAMPIRAN D

CARA REPRODUKSI

Seluruh angka bab hasil dapat dibangun ulang tanpa GPU. Tahap pembangunan ekspresi (GPU) sudah selesai dan keluarannya tersimpan; tahap penilaian sampai tabel seluruhnya berjalan di CPU.

```
# 1. bangun panel pasar IDX (unduh sekali)
python scripts/ambil_data_idx.py
python scripts/panel_indeks_idx.py --indeks lq45

# 2. nilai korpus pada dua jendela
bash scripts/skor_idx.sh

# 3. analisis tambahan
python scripts/lantai_acak.py --n 600
python scripts/uji_gate_lintas_pasar.py

# 4. agregasi, tabel, figur
python scripts/analisis_idx.py
python scripts/tabel_idx.py
python scripts/visual_idx.py
```

Variabel lingkungan yang mengendalikan pasar: `LAB_PV_FILE` (panel harga-volume), `LAB_TRADING_DAYS` (konstanta analisis, 241 untuk IDX), `LAB_GATE_SAMPLE_START` dan `LAB_GATE_SAMPLE_END` (jendela sampel *gate*). Tanpa variabel-variabel itu, kode berperilaku persis seperti sebelumnya.